KongohPlus バージョン 0.21.9

ユーザーマニュアル

眞鍋　翔

2025 年 12 月 12 日

目次

1 初期設定 **3**

2 入力ファイル **4**

3 デコンボリューション **5**

4 尤度比 **6**

5 設定 **7**

6 計算原理 **8**

6.1 尤度比 8

6.2 ピーク高の統計学的モデル 10

6.2.1 ガンマ分布の和 (アレル成分のみ) 12

6.2.2 ガンマ分布の和 (スタター成分のみ) 12

6.2.3 ガンマ分布の和 (アレル成分とスタター成分が混在) 12

6.2.4 ピーク高の期待値 15

6.2.5 ドロップアウト 16

6.2.6 ドロップイン 17

6.3 デコンボリューション 19

6.4 実験データを基に決めるパラメータ 21

6.4.1 実験データの準備 21

6.4.2 スタター比 21
6.4.2.1 ピーク高のばらつきに関する統計学的モデル 21
6.4.2.2 アレルとスタター比の相関に関する統計学的モデル . . 22
6.4.2.3 LUS model 23
6.4.2.4 Multi-sequence model 24
6.4.2.5 実験データに基づくパラメータ推定 25
6.4.3 ローカス毎の PCR 増幅効率 28
6.4.3.1 統計学的モデル 28
6.4.3.2 実験データに基づくパラメータ推定 29
6.4.4 ガンマ分布における scale parameter 30
6.4.5 ドロップインモデルのパラメータ 32

1. 初期設定

1. R (バージョン 4.4.0 以上) がインストールされていることを確認してください。R Development Core Team website から利用できます。
2. R を立ち上げてください。

2. 入力ファイル

3. デコンボリューション

4. 尤度比

5. 設定

6. 計算原理

6.1 尤度比

KongohPlus では、DNA 型検査結果の統計学的解析として、尤度比を計算する。ここでの尤度比は、2 つの相反する仮説 (H_1, H_2) の下で、DNA 型検査結果 (crime stain profile: CSP) が得られる度合いを比較したものである。

$$LR = \frac{f(CSP \mid H_1)}{f(CSP \mid H_2)} \tag{6.1}$$

尤度比が 1 を上回れば、DNA 型検査結果は H_1 仮説を支持し、尤度比が 1 を下回れば、DNA 型検査結果は H_2 仮説を支持する。

KongohPlus において、尤度比の分子分母、つまり、ある仮説 (H) が成り立つとしたときの crime stain profile (CSP) の得られやすさは、以下の式で表される。

$$f(CSP \mid H) = \prod_l \sum_i f(CSP_l \mid G_{l,i}, M) Pr(G_{l,i} \mid H) \tag{6.2}$$

記号	意味
CSP_l	ローカス l における、crime stain profile (検出されたピーク高の情報)
$G_{l,i}$	ローカス l における、i 番目の DNA 型の組合せ
M	mass parameter (全パラメータの集合)

$Pr(G_{l,i} \mid H)$ とは、仮説 (H) が成り立つとしたときに、ある DNA 型の組合せ ($G_{l,i}$) が得られる確率である。Balding と Nichols の式 [1] に基づき、アレル頻度と sub-population の影響を補正する θ 値を使って計算される。

$f(CSP_l \mid G_{l,i}, M)$ とは、ある DNA 型の組合せ ($G_{l,i}$) とパラメータ群 (M) の条件下で、ローカス l における各ピークの高さの得られやすさである。詳細は、第 6.2 項 (ピーク高の統計学的モデル) で説明する。

6.2　ピーク高の統計学的モデル

ローカス l における各ピークの高さの得られやすさは、以下の式で表される。

$$f(CSP_l \mid G_{l,i}, M) = \prod_r \prod_a f(O_{l,r,a} \mid G_{l,i}, M) \tag{6.3}$$

記号	意味
CSP_l	ローカス l における、crime stain profile (検出されたピーク高の情報)
$G_{l,i}$	ローカス l における、i 番目の DNA 型の組合せ
M	mass parameter (全パラメータの集合)
$O_{l,r,a}$	ローカス l、r 回目の PCR 検査における、アレル a の位置にあるピークの高さ

$f(O_{l,r,a} \mid G_{l,i}, M)$ は、ある DNA 型の組合せ ($G_{l,i}$) とパラメータ群 (M) の条件下で、ローカス l、r 回目の PCR 検査におけるアレル a の位置にあるピークの高さが $O_{l,r,a}$ となる度合いである。

$O_{l,r,a}$ が、ある単一個人のアレル成分のみに由来する場合、$f(O_{l,r,a} \mid G_{l,i}, M)$ は、以下のガンマ分布から得られる確率密度である。

$$f(O_{l,r,a}|G_{l,i}, M) = gamma(\frac{E_{l,r,a}}{\eta_{allele}}, \eta_{allele}) \tag{6.4}$$

記号	意味
$O_{l,r,a}$	ローカス l、r 回目の PCR 検査における、アレル a の位置にあるピーク高の観察値
$G_{l,i}$	ローカス l における、i 番目の DNA 型の組合せ
M	mass parameter (全パラメータの集合)
$E_{l,r,a}$	ローカス l、r 回目の PCR 検査における、アレル a の位置にあるピーク高の期待値
η_{allele}	アレル成分の scale parameter

$O_{l,r,a-1}$ が、ある単一個人のアレル a から発生した back stutter 成分のみに由来する場合、$f(O_{l,r,a-1} \mid G_{l,i}, M)$ は、以下のガンマ分布から得られる確率密度である。

$$f(O_{l,r,a-1}|G_{l,i}, M) = gamma(\frac{E_{l,r,a-1}}{\eta_{stutter}}, \eta_{stutter}) \tag{6.5}$$

記号	意味
$O_{l,r,a-1}$	ローカス l、r 回目の PCR 検査における、アレル $a-1$ の位置にあるピーク高の観察値
$G_{l,i}$	ローカス l における、i 番目の DNA 型の組合せ
M	mass parameter (全パラメータの集合)
$E_{l,r,a-1}$	ローカス l、r 回目の PCR 検査における、アレル $a-1$ の位置にあるピーク高の期待値
$\eta_{stutter}$	スタター成分の scale parameter

$\eta_{stutter}$ の値は、スタターの種類 (back stutter、forward stutter、double-back stutter、minus 2-nt stutter) に依らず、一定とする。

6.2.1　ガンマ分布の和 (アレル成分のみ)

ガンマ分布は再生性を有する。つまり、2 つのガンマ分布の shape parameter は異なるが scale parameter が同じ場合、2 つのガンマ分布の和もガンマ分布となる。

1 つ目のガンマ分布の shape parameter を k_1 、scale parameter を θ とする。また、2 つ目のガンマ分布の shape parameter を k_2、scale parameter を θ とする。このとき、2 つのガンマ分布の和は、shape parameter が $k_1 + k_2$、scale parameter が θ のガンマ分布となる。

これを、KongohPlus のピーク高のモデルに当てはめる。例えば、2 人の混合資料において、major contributor 由来のピーク高の期待値を $E_{l,r,a,c1}$、minor contributor 由来のピーク高の期待値を $E_{l,r,a,c2}$ とする。このとき、ガンマ分布は以下の式となる。

$$f(O_{l,r,a}|G_{l,i}, M) = gamma(\frac{E_{l,r,a,c1} + E_{l,r,a,c2}}{\eta_{allele}}, \eta_{allele}) \tag{6.6}$$

6.2.2　ガンマ分布の和 (スタター成分のみ)

例えば、ある contributor ($c1$) が a, a' 型であり、アレル a とアレル a' の差が 2 ($a' - a = 2$) の場合、アレル $a + 1$ (または $a' - 1$) の位置には、アレル a の forward stutter とアレル a' の back stutter が混在することになる。スタターのピーク高に対するガンマ分布の shape parameter は、スタターの種類に依らず、$\eta_{stutter}$ で一定である。よって、アレル a の forward stutter 成分に対するガンマ分布と、アレル a' の back stutter 成分に対するガンマ分布の和もガンマ分布となり、以下の式で表される。

$$f(O_{l,r,a+1}|G_{l,i}, M) = gamma(\frac{E_{l,r,a+1,c1} + E_{l,r,a'-1,c1}}{\eta_{stutter}}, \eta_{stutter}) \tag{6.7}$$

6.2.3　ガンマ分布の和 (アレル成分とスタター成分が混在)

2 つのガンマ分布の scale parameter が異なる場合、厳密には、2 つのガンマ分布の和はガンマ分布にならない。ただし、以下に示す考え方でガンマ分布に近似できる。

ガンマ分布 1 (k_1, θ_1) の期待値を μ_1、分散を V_1 とし、ガンマ分布 2 (k_2, θ_2) の期待値を μ_2、分散を V_2 とする。両者が独立であるとき、その和の分布の期待値 μ_0 は $\mu_1 + \mu_2$、分散 V_0 は $V_1 + V_2$ となる。

このとき、和の分布をガンマ分布 (k_0, θ_0) で近似することを考える。ガンマ分布の期待値は $k\theta$、分散は $k\theta^2$ であるため、次の関係が成り立つ。

$$k_0\theta_0 = k_1\theta_1 + k_2\theta_2 \tag{6.8}$$

$$k_0\theta_0^2 = k_1\theta_1^2 + k_2\theta_2^2 \tag{6.9}$$

これを解くと、

$$k_0 = \frac{(k_1\theta_1 + k_2\theta_2)^2}{k_1\theta_1^2 + k_2\theta_2^2} \tag{6.10}$$

$$\theta_0 = \frac{k_1\theta_1^2 + k_2\theta_2^2}{k_1\theta_1 + k_2\theta_2} \tag{6.11}$$

が得られる。

したがって、ガンマ分布 1 (k_1, θ_1) とガンマ分布 2 (k_2, θ_2) の和の分布は、理論上はガンマ分布にならないが、以下の数式の通り、平均と分散を一致させたガンマ分布で表すことができる[1]。

$$gamma(k_0, \theta_0) = gamma(\frac{(k_1\theta_1 + k_2\theta_2)^2}{k_1\theta_1^2 + k_2\theta_2^2}, \frac{k_1\theta_1^2 + k_2\theta_2^2}{k_1\theta_1 + k_2\theta_2}) \tag{6.12}$$

[1]このように、標本モーメント (データから計算される平均や分散など) と理論モーメント (推定したい分布のパラメータを使って表される平均や分散など) を一致させるという方程式を立てて、その方程式を解くことで、未知のパラメータを推定するアプローチを、モーメント法という。

この考え方を、KongohPlus のピーク高のモデルに当てはめる。アレル a と a' の差が 1 ($a+1=a'$) であるとする。このとき、アレル a の位置には、アレル a のアレル成分と、アレル a' の back stutter 成分が混在することになる。

このとき、$f(O_{l,r,a}|G_{l,i},M)$ を求めるには、以下の 2 つのガンマ分布の和を考える必要がある。

$$gamma(\frac{E_{l,r,a}}{\eta_{allele}},\eta_{allele}) \tag{6.13}$$

$$gamma(\frac{E_{l,r,a'-1}}{\eta_{stutter}},\eta_{stutter}) \tag{6.14}$$

和の分布をガンマ分布 (k_0,θ_0) で近似する。ガンマ分布の期待値は $k\theta$、分散は $k\theta^2$ であるため、次の関係が成り立つ。

$$k_0\theta_0 = E_{l,r,a} + E_{l,r,a'-1} \tag{6.15}$$

$$k_0\theta_0^2 = E_{l,r,a}\eta_{allele} + E_{l,r,a'-1}\eta_{stutter} \tag{6.16}$$

これを解くと、

$$k_0 = \frac{(E_{l,r,a} + E_{l,r,a'-1})^2}{E_{l,r,a}\eta_{allele} + E_{l,r,a'-1}\eta_{stutter}} \tag{6.17}$$

$$\theta_0 = \frac{E_{l,r,a}\eta_{allele} + E_{l,r,a'-1}\eta_{stutter}}{E_{l,r,a} + E_{l,r,a'-1}} \tag{6.18}$$

が得られる。

したがって、この場合の和の分布は、以下のガンマ分布で表すことができる。

$$f(O_{l,r,a}|G_{l,i},M) = gamma(\frac{(E_{l,r,a}+E_{l,r,a'-1})^2}{E_{l,r,a}\eta_{allele}+E_{l,r,a'-1}\eta_{stutter}}, \frac{E_{l,r,a}\eta_{allele}+E_{l,r,a'-1}\eta_{stutter}}{E_{l,r,a}+E_{l,r,a'-1}}) \tag{6.19}$$

6.2.4 ピーク高の期待値

ローカス l、r 回目の PCR 検査において、関与者 c に由来するアレル a の成分量の期待値 ($E_{l,r,a,c}$) は、以下の式で表される。

$$E_{l,r,a,c} = \frac{\hat{A}_l R_r T_c D_c^{(S_a - S_{base})/S_{base}}}{1 + BS\hat{R}_{l,a} + FS\hat{R}_{l,a} + DS\hat{R}_{l,a} + M2\hat{S}R_{l,a}} \tag{6.20}$$

記号	扱い	意味
$\hat{A}_l$	固定値	ローカス l の PCR 増幅効率 (全体平均を 1 としたときの相対量)
R_r	推定値	複数回 PCR における、ピーク高の変動 (1 回目の PCR を 1 としたときの相対量)
T_c	推定値	関与者 c のヘテロ接合体 1 本あたりのピーク高
D_c	推定値	関与者 c の DNA 分解の程度
S_a	固定値	アレル a のサイズ
S_{base}	固定値	対象とするキットにおける、アレルの最小サイズ
$BS\hat{R}_{l,a}$	固定値	ローカス l、アレル a の back stutter ratio
$FS\hat{R}_{l,a}$	固定値	ローカス l、アレル a の forward stutter ratio
$DS\hat{R}_{l,a}$	固定値	ローカス l、アレル a の double-back stutter ratio
$M2\hat{S}R_{l,a}$	固定値	ローカス l、アレル a の minus 2-nt stutter ratio

上表の推定値については、デコンボリューションにより推定される (詳細は、第 6.3 項 (デコンボリューション) を参照)。また、固定値については、実験データを基に事前に設定しておくものである (詳細は、第 6.4 項 (実験データを基に決めるパラメータ) を参照)。

続いて、関与者 c に由来するアレル a から発生した各種スタター成分量の期待値は、それぞれ以下の式で表される。

- back stutter 成分

$$E_{l,r,a-1,c} = \frac{BS\hat{R}_{l,a}\hat{A}_l R_r T_c D_c^{(S_a - S_{base})/S_{base}}}{1 + BS\hat{R}_{l,a} + FS\hat{R}_{l,a} + DS\hat{R}_{l,a} + M2\hat{S}R_{l,a}} \tag{6.21}$$

- forward stutter 成分

$$E_{l,r,a+1,c} = \frac{FS\hat{R}_{l,a}\hat{A}_l R_r T_c D_c^{(S_a - S_{base})/S_{base}}}{1 + BS\hat{R}_{l,a} + FS\hat{R}_{l,a} + DS\hat{R}_{l,a} + M2\hat{S}R_{l,a}} \tag{6.22}$$

- double-back stutter 成分

$$E_{l,r,a-2,c} = \frac{DS\hat{R}_{l,a}\hat{A}_l R_r T_c D_c^{(S_a - S_{base})/S_{base}}}{1 + BS\hat{R}_{l,a} + FS\hat{R}_{l,a} + DS\hat{R}_{l,a} + M2\hat{S}R_{l,a}} \tag{6.23}$$

- minus 2-nt stutter 成分

$$E_{l,r,a-0.2(or\ 0.8),c} = \frac{M2\hat{S}R_{l,a}\hat{A}_l R_r T_c D_c^{(S_a - S_{base})/S_{base}}}{1 + BS\hat{R}_{l,a} + FS\hat{R}_{l,a} + DS\hat{R}_{l,a} + M2\hat{S}R_{l,a}} \tag{6.24}$$

6.2.5 ドロップアウト

アレル a がドロップアウトしている場合、ピーク高の観察値 $O_{l,r,a}$ は得られていない。このため、$f(O_{l,r,a} \mid G_{l,i}, M)$ の値は、前述までのガンマ分布 (式 (6.4)、式 (6.5)、式 (6.6)、式 (6.19)) を使って得ることができない。

そこで、アレル a がドロップアウトしている場合は、$O_{l,r,a}$ がローカス l における検出閾値 (AT_l) を下回っていると考える。$O_{l,r,a}$ が AT_l 未満となる確率は、アレル a がドロップアウトしている確率であり、以下の式で表される。

$$Pr(O_{l,r,a} < AT_l | G_{l,i}, M) = \int_0^{AT_l} Pr(O_{l,r,a} = x | G_{l,i}, M) dx \tag{6.25}$$

6.2.6　ドロップイン

アレル a がドロップインによるものである場合、第 6.2.4 項 (ピーク高の期待値) で説明した方法でピーク高の期待値 $E_{l,r,a}$ を得ることはできない。よって、前述までのガンマ分布 (式 (6.4)、式 (6.5)、式 (6.6)、式 (6.19)) とは別に、ドロップイン用のガンマ分布をモデルとして立てる必要がある。

アレル a がドロップインし、かつ高さが $O_{l,r,a}$ となる度合いは、以下の式で表される。

$$f(O_{l,r,a}) = f(O_{l,r,a}|C) \times Pr(C) = gamma(\xi_{dropin}, \eta_{dropin}) \times \frac{F_{dropin}}{P_{dropin \geq AT_l}} \tag{6.26}$$

記号	扱い	意味
ξ_{dropin}	固定値	ドロップインのピーク高のガンマ分布における、shape parameter
η_{dropin}	固定値	ドロップインのピーク高のガンマ分布における、scale parameter
F_{dropin}	固定値	実験データから得られた、ドロップインの発生頻度
$P_{dropin \geq AT}$	固定値	ドロップインのピーク高が、ローカス l の AT 以上となる確率[a]

[a] 式 (6.26) における、AT 以上の area under the curve

F_{dropin} は、実験データを基に、以下の式で計算される。

$$F_{dropin} = n_{dropin} / (n_{sample} \times n_{marker}) \tag{6.27}$$

記号	扱い	意味
n_{dropin}	固定値	ドロップインの発生数
n_{sample}	固定値	実験データのサンプル数
n_{marker}	固定値	ローカス数

6.3 デコンボリューション

デコンボリューションの目的は、検出されたピークとその高さの情報を基に、各関与者がもちうる DNA 型の組合せ ($G_{l,i}$) に重みをつけることである。これを行うには最尤推定、つまり、ある仮説 H の下で、式 (6.2) の値が最大となるようなパラメータの条件 (式 (6.2) における M) を探す必要がある。

ここで対象となるパラメータは、以下の 3 つである。

記号	意味
R_r	複数回 PCR における、ピーク高の変動 (1 回目の PCR を 1 としたときの相対量)
T_c	関与者 c のヘテロ接合体 1 本あたりのピーク高
D_c	関与者 c の DNA 分解の程度

KongohPlus では、最尤推定の方法として、Generalized Simulated Annealing (GSA) 法 [9] を採用している。GSA 法は、従来の Simulated Annealing (SA) 法を一般化した最適化手法であり、探索過程の柔軟性を高めることで、より広い範囲から効率的に最適解を探索できるよう設計されている。

KongohPlus における GSA 法の基本的な処理の流れは、以下の通りである。

1. 各パラメータ (M) の初期値を設定し、尤度 (式 (6.2)) を計算して「現在の尤度」とする。
2. 各パラメータ (M) の値をランダムに変化させ、再度尤度を計算して「新しい尤度」とする。
3. 「新しい尤度」が「現在の尤度」より大きい場合 (尤度が改善した場合) には、「現在の尤度」を「新しい尤度」に更新する。
4. 「新しい尤度」が小さい場合でも、確率的にその解を採用する場合がある。この確率は、温度パラメータと尤度差に基づいて決定される[2]。

[2]GSA 法では温度パラメータにより受理確率が制御される。初期段階では温度が高いため、劣った解 (尤度が小さい解) も比較的高い確率で採用されるが、探索が進むにつれて温度が低下し、受理確率も

5. ステップ 2 から 4 の過程を繰り返し、尤度が収束するまで最適化を続ける。

既定の設定では、ステップ 2 から 4 の過程は、最低 500 回、最大 5000 回繰り返される。尤度の改善が 500 回連続してみられない場合、収束したと判断して処理を終了する。一方、改善が継続している場合には探索が続行され、最大で 5000 回の試行が行われた時点で最終的に終了する。

また、KongohPlus では、初期値を変更して処理全体を複数回試行することで、局所解への収束を避け、より安定した最尤推定を行う。既定の設定では、ステップ 1 から 5 までの処理全体を最低 3 回、最大 10 回繰り返し実行する。各試行でより高い対数尤度が得られた場合には、その値を更新して探索を続行する。試行の中で、最大尤度の値が 3 回 (差が 0.001 以内) 得られた時点で、結果が安定したと判断し処理を終了する。一方、10 回の試行を終えても最大尤度の値が 3 回未満 (例えば 2 回) しか得られなかった場合には、結果の信頼性が十分でない可能性があるとして警告を表示する。

> **警告例:**
> *A total of 10 MLE runs were performed, of which 2 converged under 2 contributor(s). This number is below the specified threshold of 3 converged MLE runs, which may compromise the reliability of the results.*

なお、各パラメータが取り得る値の最小値および最大値は、以下の通り既定されている。

パラメータ	最小値	最大値
R_r	0.2	5
T_c	1	32000
D_c	0.001	1[a]

[a] 変更不可

小さくなる。詳細は文献 [9] を参照のこと。

6.4　実験データを基に決めるパラメータ

6.4.1　実験データの準備

6.4.2　スタター比

スタター比 (stutter ratio: SR) とは、アレルピークの高さに対するスタターピークの高さの割合を表す指標である。KongohPlus における解析で考慮できるスタター比は、back stutter ratio ($BSR_{l,a}$)、forward stutter ($FSR_{l,a}$)、double-back stutter ($DSR_{l,a}$)、minus 2-nt stutter ($M2SR_{l,a}$) の 4 つである。以降は特に断りのない限り、各種スタター比を総称して $SR_{l,a}$ と表記する。スタター比はプロファイル毎にばらつきを示すが、ここでは各ローカスのアレル毎に「平均的なスタター比 ($\hat{SR}_{l,a}$)」を推定することを目的とする。

6.4.2.1　ピーク高のばらつきに関する統計学的モデル

KongohPlus では、$SR_{l,a}$ が以下に示す対数正規分布に従うと仮定する。

$$SR_{l,a} \sim LN(\mu_{l,a}, \frac{\sigma_l^2}{h_{l,a}}) \tag{6.28}$$

記号	意味
$\mu_{l,a}$	ローカス l、アレル a における stutter ratio の対数平均
$h_{l,a}$	ローカス l、アレル a におけるアレル成分量とスタター成分量の合計値[a]
σ_l^2	ローカス l、アレル a における、$h_{l,a} = 1$ の場合の stutter ratio の分散 (対数スケール)

[a] total allelic product [7] のこと

対数スケールの stutter ratio の分散は $\frac{\sigma_l^2}{h_{l,a}}$ であり、$h_{l,a}$ が減少するほど stochastic effect によりばらつきが大きくなることを示している。σ_l^2 については、実験データを基に推定するパラメータである。

6.4.2.2　アレルとスタター比の相関に関する統計学的モデル

スタター比は一般に、アレルの数字が大きくなるほど高くなる傾向にある。ただし、アレルの塩基配列が単純なリピート構造を示さない場合、スタター比は必ずしもアレルの数字と相関せず、longest uninterrupted stretch (LUS) [4] 等によってアレルの数字を補正する必要がある。また、minus 2-nt stutter は、アレルの数字に依らず、スタター比の期待値はほぼ一定になる。さらに、ローカスによっては、forward stutter、double-back stutter のデータが不十分なため、複数のローカスを合わせたモデルが必要となる。

以上の点を踏まえ、KongohPlus では、アレルとスタター比との関係について、以下の 5 つのモデルを実装している。

モデル	説明
Linear (Allele)	スタター比は、アレルの数字が大きくなるほど高くなる
Linear (Corrected Allele)	スタター比は、アレルの補正値が大きくなるほど高くなる
Uniform	スタター比は、アレルに依らず一定
Uniform (Multiple loci)	スタター比は、アレルに依らず一定 (複数のローカスのデータを統合)
Not consider	スタター比を考慮しない

Linear (Allele) モデルでは、アレルとスタター比の対数平均との関係は以下の式で表される。

$$\mu_{l,a} = log_e(\beta_{0,l} + \beta_{1,l} \times a) \tag{6.29}$$

$\beta_{0,l}$ は切片、$\beta_{1,l}$ は傾きを表す。これらは、実験データを基に推定するパラメータである。

Uniform モデル、および Uniform (Multiple loci) モデルについては、スタター比はアレルに依らず一定であることが前提なので、傾きや切片は設けず、式 (6.28) におけ

る $\mu_{l,a}$ を実験データを基に直接推定する。

Linear (Corrected Allele) モデルでは、ユーザーが各アレルの補正値を設定する必要がある。GlobalFiler キットに搭載されている既定のローカスについては、D8S1179、D21S11、D2S441、TH01、FGA、D1S1656、D12S391、D2S1338 で LUS model [3, 6]、SE33 で Multi-sequence model [8, 6] に基づいてアレルの補正値を決定している。以下、LUS model と Multi-sequence model について説明する。

6.4.2.3 LUS model

LUS とは、longest uninterrupted stretch の略で、STR の塩基配列において、リピート構造の繰り返し回数の最大値を指す [4]。多くの STR では、アレルの数字は繰り返し回数と一致するが、一部の STR では必ずしも一致せず、複数のリピート構造から成る複雑な塩基配列の場合もある。こういった STR では、アレルの数字よりも、LUS の方がスタター比のデータが示す傾向を説明しやすい。

LUS でアレルの数字を補正する場合、スタター比の対数平均は、以下の式で表される。

$$\mu_{l,a} = log_e(\beta_{0,l} + \beta_{1,l} \times wLUS_{l,a}) \tag{6.30}$$

$wLUS_{l,a}$ は、ローカス l、アレル a における LUS の重みづけ平均を示し、以下の式で表される。

$$wLUS_{l,a} = \frac{\sum_{i=1}^{N} n_i LUS_i}{\sum_{i=1}^{N} n_i} \tag{6.31}$$

n_i は、ある遺伝的集団において、同一アレルにおける i 番目の塩基配列の観察数を示し、LUS_i は、i 番目の塩基配列における LUS の値を示す。

例えば、NIST 1036 人の population data [5] において、D3S1358 のアレル 15 については以下のデータが得られている。

塩基配列	観察数 (n_i)	LUS_i
TCTA [TCTG]2 [TCTA]12	429	12
TCTA TCTG [TCTA]13	173	13
TCTA [TCTG]3 [TCTA]11	27	11
TCTA [TCTG]2 [TCTA]8 TCTG [TCTA]3	1	8
TCTA [TCTG]3 [TCTA]5 TCTG [TCTA]5	1	5

このとき、D3S1358 のアレル 15 に対する $wLUS_{l,a}$ は、以下の通り計算される。

$$wLUS_{l,a} = \frac{429 \cdot 12 + 173 \cdot 13 + 27 \cdot 11 + 1 \cdot 8 + 1 \cdot 5}{429 + 173 + 27 + 1 + 1} \approx 12.2 \tag{6.32}$$

6.4.2.4 Multi-sequence model

SE33 のように、アレルの塩基配列内にリピート構造が複数存在する複雑な STR では、LUS でもスタター比のデータを説明しにくい。そこで、各リピート構造のうち、繰り返し回数が一定の基準を上回ったものについて、その繰り返し回数を合計した数字をアレルの補正値とする方法として、Multi-seq model [8] が編み出されている。

Multi-seq model にしたがってアレルの数字を補正する場合、スタター比の対数平均は、以下の式で表される。

$$\mu_{l,a} = log_e(\beta_{0,l} + \beta_{1,l} \times wCA_{l,a}) \tag{6.33}$$

$wCA_{l,a}$ は、ローカス l、アレル a におけるアレルの補正値の重みづけ平均を示し、以下の式で表される。

$$wCA_{l,a} = \frac{\sum_{i=1}^{N} n_i CA_i}{\sum_{i=1}^{N} n_i} \tag{6.34}$$

n_i は、ある遺伝的集団において、同一アレルにおける i 番目の塩基配列の観察数を

示し、CA_i は、i 番目の塩基配列におけるアレルの補正値を示す。

CA_i は、以下の式で計算される。

$$CA_i = \sum_j max(US_{i,j} - x_l, 0) \tag{6.35}$$

$US_{i,j}$ は、i 番目の塩基配列における j 番目のリピート構造の繰り返し回数を示し、x_l はスタター比に影響する最小の繰り返し回数を示す。

例えば、NIST 1036 人の population data [2] において、SE33 のアレル 22 については以下のデータが得られている。

塩基配列	観察数 (n_i)	CA_i ($x_l = 7$)
CT [CTTT]3 C [CTTT]22 CT [CTTT]3 CT [CTTT]2	24	15
CT [CTTT]3 CCTT C [CTTT]21 CT [CTTT]3 CT [CTTT]2	4	14
CT [CTTT]2 CCTT C [CTTT]12 TT [CTTT]10 CT [CTTT]5	1	8
CT [CTTT]2 C [CTTT]23 CT [CTTT]3 CT [CTTT]2	1	16

このとき、SE33 のアレル 22 に対する $wCA_{l,a}$ は、以下の通り計算される。

$$wCA_{l,a} = \frac{24 \cdot 15 + 4 \cdot 14 + 1 \cdot 8 + 1 \cdot 16}{24 + 4 + 1 + 1} \approx 14.66667 \tag{6.36}$$

6.4.2.5　実験データに基づくパラメータ推定

本項では、これまでに述べたスタター比に関する統計学的モデルを前提に、実験データから各ローカス、各アレルの「平均的なスタター比 ($\hat{SR}_{l,a}$)」を推定する方法について述べる。

実験的に取得した各プロファイルについて、ローカス l、アレル a のスタター比 $BSR_{l,a}^{(obs)}, FSR_{l,a}^{(obs)}, DSR_{l,a}^{(obs)}, M2SR_{l,a}^{(obs)}$ (観測値を表すために (obs) と付記) は次の各式で計算される。

$$BSR_{l,a}^{(obs)} = \frac{O_{l,a-1}}{O_{l,a}} \tag{6.37}$$

$$FSR_{l,a}^{(obs)} = \frac{O_{l,a+1}}{O_{l,a}} \tag{6.38}$$

$$DSR_{l,a}^{(obs)} = \frac{O_{l,a-2}}{O_{l,a}} \tag{6.39}$$

$$M2SR_{l,a}^{(obs)} = \frac{O_{l,a-0.2(or\ 0.8)}}{O_{l,a}} \tag{6.40}$$

記号	意味
$O_{l,a}$	ローカス l、アレル a のピーク高
$O_{l,a-1}$	ローカス l、アレル a に由来する back stutter のピーク高
$O_{l,a+1}$	ローカス l、アレル a に由来する forward stutter のピーク高
$O_{l,a-2}$	ローカス l、アレル a に由来する double-back stutter のピーク高
$O_{l,a-0.2(or\ 0.8)}$	ローカス l、アレル a に由来する minus 2-nt stutter のピーク高

また、アレル成分量とスタター成分量の合計値 ($h_{l,a}^{(obs)}$) についても、実験データから取得する必要がある。計算式は、以下の通りである。

$$h_{l,a}^{(obs)} = O_{l,a-2} + O_{l,a-1} + O_{l,a-0.2(or\ 0.8)} + O_{l,a} + O_{l,a+1} \tag{6.41}$$

なお、実験的に取得したプロファイルがあるローカスでヘテロ接合体の場合は、アレル成分とスタター成分が混在したり、スタター成分同士が混在したりする場合がある。そのようなデータは、「平均的なスタター比 ($\hat{SR}_{l,a}$)」の推定には使用しない。具

体的には、以下の表で ✓ マークが付いていないスタター比のデータについては、「平均的なスタター比 ($\hat{SR}_{l,a}$)」の推定には使用しない。

$a' - a$	アレル	$BSR_{l,a}^{(obs)}$	$FSR_{l,a}^{(obs)}$	$DSR_{l,a}^{(obs)}$	$M2SR_{l,a}^{(obs)}$
1	a				
1	a'				
2	a				
2	a'		✓		✓
3	a	✓		✓	✓
3	a'	✓	✓		✓
0.2 or 0.8	a				
0.2 or 0.8	a'		✓	✓	
1.2 or 1.8	a	✓		✓	
1.2 or 1.8	a'	✓	✓		

実験データ ($BSR_{l,a}^{(obs)}$、$FSR_{l,a}^{(obs)}$、$DSR_{l,a}^{(obs)}$、$M2SR_{l,a}^{(obs)}$、$h_{l,a}^{(obs)}$) を取得したら、これまでに述べた統計学的モデルにおけるパラメータ σ_l^2 (式 (6.28))、$\beta_{0,l}$ および $\beta_{1,l}$ (Linear (Allele) モデルと Linear (Corrected Allele) モデル)、$\mu_{l,a}$ (Uniform モデルと Uniform (Multiple loci) モデル) を Generalized Simulated Annealing (GSA) 法 [9] により推定する (詳細は、第 6.3 項 (デコンボリューション) を参照)。

なお、各パラメータが取り得る値の最小値および最大値は、以下の通り既定されている。

パラメータ	最小値	最大値
σ_l^2	1	10000
$\beta_{0,l}$	-1	1
$\beta_{1,l}$	0	1
$\mu_{l,a}$	0.001	1

各パラメータが推定できれば、Linear (Allele) モデルと Linear (Corrected Allele) モデルの場合は、式 (6.29)、式 (6.30)、あるいは式 (6.33) を用いて、アレル毎に $\mu_{l,a}$

を計算する。計算された値が、「平均的なスタター比 ($\hat{SR}_{l,a}$)」となる。

Uniform モデルと Uniform (Multiple loci) モデルについては、simulated annealing 法により推定された $\mu_{l,a}$ そのものが、「平均的なスタター比 ($\hat{SR}_{l,a}$)」となる。

6.4.3　ローカス毎の PCR 増幅効率

ローカス l の PCR 増幅効率 (A_l) は、全ローカスの平均増幅効率を 1 としたときに、そのローカスが相対的に何倍の増幅効率をもつかを表す指標である。増幅効率はプロファイル毎にばらつきを示すが、ここでは各ローカスにおける「平均的な増幅効率 ($\hat{A}_l$)」を推定することを目的とする。

6.4.3.1　統計学的モデル

KongohPlus では、全ローカスの増幅効率が合計で 1 となるように正規化した値 (A_l^*) を定義する。正規化は、各ローカスにおける「平均的な増幅効率 ($\hat{A}_l$)」を推定する際に、そのままのスケールでは扱いにくいため行う。

$$A_l^* = \frac{A_l}{\sum_{l=1}^{L} A_l} \tag{6.42}$$

KongohPlus では、この正規化された増幅効率ベクトル $(A_1^*, A_2^*, ..., A_L^*)$ がディリクレ分布に従うと仮定する。

$$(A_1^*, A_2^*, ..., A_L^*) \sim Dir(\alpha_1, \alpha_2, ..., \alpha_L) \tag{6.43}$$

パラメータ $\alpha_1, \alpha_2, ..., \alpha_L$ は、実験データを基に推定するパラメータである。

各ローカスに対応する $\alpha_l (l = 1, 2, ..., L)$ が推定できれば、正規化された増幅効率 A_l^* の「平均的な値」として、次の式により推定値を求める。

$$\hat{A_l^*} = \frac{\alpha_l + 1}{\sum_{l=1}^{L} (\alpha_l + 1)} \tag{6.44}$$

これは、ラプラス補正を施した事後平均に相当する。

最後に、各ローカスにおける「平均的な増幅効率 ($\hat{A}_l$)」は次の式で推定される。

$$\hat{A}_l = \hat{A}_l^* \times L \tag{6.45}$$

6.4.3.2　実験データに基づくパラメータ推定

実験的に取得した各プロファイルについて、ローカス l の PCR 増幅効率 $A_l^{(obs)}$ (観測値を表すために (obs) と付記) は次の式で計算される。

$$A_l^{(obs)} = \frac{T_l}{\bar{T}} \tag{6.46}$$

ここで T_l はローカス l における全アレルピークとスタターピークの高さの合計であり、$\bar{T}$ は全ローカスの平均値で次の式で計算される。

$$\bar{T} = \frac{1}{L}\sum_{l=1}^{L} T_l \tag{6.47}$$

続いて、全ローカスの効率が合計で 1 となるように正規化した値 ($A_l^{*(obs)}$) を計算する。正規化は、各ローカスにおける「平均的な増幅効率 ($\hat{A}_l$)」を推定する際に、そのままのスケールでは扱いにくいため行う。

$$A_l^{*(obs)} = \frac{A_l^{(obs)}}{\sum_{l=1}^{L} A_l^{(obs)}} \tag{6.48}$$

実験データとして $A_l^{*(obs)}$ を取得したら、式 (6.43) におけるパラメータ $\alpha_1, \alpha_2, ..., \alpha_L$ を Generalized Simulated Annealing (GSA) 法 [9] により推定する (詳細は、第 6.3 項 (デコンボリューション) を参照)。なお、パラメータ $\alpha_1, \alpha_2, ..., \alpha_L$ が取り得る値の最小値は 0.01、最大値は 100 と既定されている。

各ローカスに対応する $\alpha_l (l = 1, 2, ..., L)$ が推定できれば、式 (6.44) および式 (6.45) に基づき、「平均的な増幅効率 ($\hat{A}_l$)」を得る。

6.4.4　ガンマ分布における scale parameter

第 6.2 項 (ピーク高の統計学的モデル) で述べた通り、KongohPlus では、ピーク高はガンマ分布にしたがうことを前提とする。式 (6.4) における η_{allele}、および式 (6.5) における $\eta_{stutter}$ は、実験的に取得したプロファイルを基に推定する。

実験的に取得したプロファイルは、以下の条件を満たすことを前提とする。

- 単一個人由来であること ($c = 1$)。
- DNA の分解がないこと。
- 各サンプルにつき、PCR は 1 回のみ実施されていること ($r = 1$)。複数回実施した場合は、サンプル名を変更する必要あり。

このとき、式 (6.20)、(6.21)、(6.22)、(6.23)、(6.24) は、それぞれ以下の式となる。

- アレル成分

$$E_{l,a} = \frac{\hat{A}_l \bar{T}}{1 + BS\hat{R}_{l,a} + FS\hat{R}_{l,a} + DS\hat{R}_{l,a} + M2\hat{S}R_{l,a}} \tag{6.49}$$

- back stutter 成分

$$E_{l,a-1} = \frac{BS\hat{R}_{l,a}\hat{A}_l \bar{T}}{1 + BS\hat{R}_{l,a} + FS\hat{R}_{l,a} + DS\hat{R}_{l,a} + M2\hat{S}R_{l,a}} \tag{6.50}$$

- forward stutter 成分

$$E_{l,a+1} = \frac{FS\hat{R}_{l,a}\hat{A}_l \bar{T}}{1 + BS\hat{R}_{l,a} + FS\hat{R}_{l,a} + DS\hat{R}_{l,a} + M2\hat{S}R_{l,a}} \tag{6.51}$$

- double-back stutter 成分

$$E_{l,a-2} = \frac{DS\hat{R}_{l,a}\hat{A}_l \bar{T}}{1 + BS\hat{R}_{l,a} + FS\hat{R}_{l,a} + DS\hat{R}_{l,a} + M2\hat{S}R_{l,a}} \tag{6.52}$$

- minus 2-nt stutter 成分

$$E_{l,a-0.2(or\ 0.8)} = \frac{M2\hat{S}R_{l,a}\hat{A}_l\bar{T}}{1 + BS\hat{R}_{l,a} + FS\hat{R}_{l,a} + DS\hat{R}_{l,a} + M2\hat{S}R_{l,a}} \tag{6.53}$$

$\hat{A}_l$ は、第 6.4.3 項 (ローカス毎の PCR 増幅効率) での説明に基づき推定された平均的な PCR 増幅効率、$BS\hat{R}_{l,a}$、$FS\hat{R}_{l,a}$、$DS\hat{R}_{l,a}$、$M2\hat{S}R_{l,a}$ は、第 6.4.2 項 (スタター比) での説明に基づき推定された平均的なスタター比である。

$\bar{T}$ は 1 ローカスあたりのピーク高の平均値であり、実験的に取得したプロファイルにおける実際のピーク高を用いて計算される。計算式は、式 (6.47) の通りである。

実験的に取得したプロファイルは単一個人由来であることが前提であるため、実際に得られた各ピークの成分は、アレル成分のみの場合、スタター成分のみの場合、スタター成分同士が混在している場合 (一方のアレルの forward stutter ともう一方のアレルの back stutter が混在している場合など)、一方のアレル成分ともう一方のアレルのスタター成分が混在している場合の 4 通りとなる。それぞれの場合において、ピーク高の得られやすさを表す確率密度関数は、以下の表の通りとなる。

ピークの構成成分	確率密度関数
アレル成分のみ	式 (6.4)[a]
スタター成分のみ	式 (6.5)[a]
スタター成分同士が混在	式 (6.7)[a]
一方のアレル成分ともう一方のアレルのスタター成分が混在	式 (6.19)[a, b]

[a] 実験的に取得したプロファイルは、PCR の回数は 1 回が前提なので、$r = 1$ である

[b] スタター成分が back stutter ではない場合は、$E_{l,r,a'-1}$ を該当のスタター成分におけるピーク高の期待値に置き換える

実験的に取得したプロファイルでみられた各ピークについて、そのピーク成分に応じて適切な確率密度関数に当てはめる。そして、それぞれの確率密度の総積が最大となるような η_{allele}、$\eta_{stutter}$ を Generalized Simulated Annealing (GSA) 法 [9] により推定する (詳細は、第 6.3 項 (デコンボリューション) を参照)。

なお、各パラメータが取り得る値の最小値および最大値は、以下の通り既定されている。

パラメータ	最小値	最大値
η_{allele}	0.01	400
$\eta_{stutter}$	0.01	400

6.4.5 ドロップインモデルのパラメータ

第 6.2.6 項 (ドロップイン) で述べた通り、アレル a がドロップインし、かつ高さが $O_{l,r,a}$ となる度合いは、式 (6.26) に基づいて推定される。

パラメータ F_{dropin} については、実験的に取得したネガティブコントロールのデータから、ネガティブコントロールのサンプル数 (n_{sample})、ローカス数 (n_{marker})、およびドロップインの発生数 (n_{dropin}) を得て、式 (6.27) により計算する。

パラメータ ξ_{dropin}、η_{dropin} については、実験データより得られたドロップインのピーク高を基に、Generalized Simulated Annealing (GSA) 法 [9] により推定する (詳細は、第 6.3 項 (デコンボリューション) を参照)。

なお、各パラメータが取り得る値の最小値および最大値は、以下の通り既定されている。

パラメータ	最小値	最大値
ξ_{dropin}	0.01	100
η_{dropin}	0.01	100

参考文献

[1] David J. Balding and Richard A. Nichols. DNA profile match probability calculation: How to allow for population stratification, relatedness, database selection and single bands. *Forensic Science International*, 64(2):125–140, February 1994.

[2] Lisa A. Borsuk, Katherine B. Gettings, Carolyn R. Steffen, Kevin M. Kiesler, and Peter M. Vallone. Sequence-based U.S. population data for the SE33 locus. *Electrophoresis*, 39(21):2694–2701, November 2018.

[3] Jo-Anne Bright, Duncan Taylor, James M. Curran, and John S. Buckleton. Developing allelic and stutter peak height models for a continuous method of DNA interpretation. *Forensic Science International. Genetics*, 7(2):296–304, February 2013.

[4] Clare Brookes, Jo-Anne Bright, SallyAnn Harbison, and John Buckleton. Characterising stutter in forensic STR multiplexes. *Forensic Science International: Genetics*, 6(1):58–63, January 2012.

[5] Katherine Butler Gettings, Lisa A. Borsuk, Carolyn R. Steffen, Kevin M. Kiesler, and Peter M. Vallone. Sequence-based U.S. population data for 27 autosomal STR loci. *Forensic Science International: Genetics*, 37:106–115, November 2018.

[6] Sho Manabe, Koji Fujii, Takashi Fukagawa, Natsuko Mizuno, Kazumasa Sekiguchi, Kana Inoue, Masaki Hashiyada, Atsushi Akane, and Keiji Tamaki. Evaluation of probability distribution models for stutter ratios in the typing system of GlobalFiler and 3500xL Genetic Analyzer. *Legal Medicine (Tokyo, Japan)*, 52:101906, September 2021.

[7] Duncan Taylor, Jo-Anne Bright, and John Buckleton. The interpretation of single source and mixed DNA profiles. *Forensic Science International: Genetics*, 7(5):516–528, September 2013.

[8] Duncan Taylor, Jo-Anne Bright, Catherine McGoven, Christopher Hefford, Tim Kalafut, and John Buckleton. Validating multiplexes for use in conjunction with modern interpretation strategies. *Forensic Science International: Genetics*, 20:6–19, January 2016.

[9] Yang Xiang, Sylvain Gubian, Brian Suomela, and Julia Hoeng. Generalized Simulated Annealing for Global Optimization: The GenSA Package. *The R Journal*, 5(1):13–28, June 2013.