KongohPlus ver. 1.0.0

ユーザーマニュアル

2026 年 10 月 22 日

目次

1. KongohPlus の概要 6

2. 初期設定 7

2.1. レポート出力を有効にするための設定 7

3. クイックガイド 8

4. 入力ファイル 18

4.1. 遺留資料の DNA プロファイル（crime stain profile） 18

4.2. アレル頻度（allele frequency） 19

4.3. 対照資料の DNA プロファイル（reference profile） 20

5. Deconvolution 21

6. Probabilistic Genotyping 24

7. 尤度比 27

8. 設定 28

8.1. 検査キットの登録 28

8.2. アレルの登録 32

8.3. Stutter ratio の推定 37

8.4. ローカス固有の PCR 増幅効率の推定 46

8.5. ガンマ分布の scale parameter の推定 55

8.6. Drop-in パラメータの推定 64

8.7. Analysis method の設定 71

9. その他の機能 78

9.1. レポート出力 78

9.2. Hd true test 81

10. 計算原理 85

10.1. Deconvolution 85

10.2. DNA 型の確率計算 87

10.2.1. DNA 型の組合せ 87

10.2.2. アレル頻度 88

10.2.3. Drop-out したアレルの扱い 88

10.3. ピーク高の統計学的モデル 89

10.3.1. ピーク高の期待値 90
10.3.2. 観察ピーク高の得られやすさ 92
10.3.3. ガンマ分布 93
10.3.4. Drop-out の統計学的モデル 96
10.3.5. Drop-in の統計学的モデル 97
10.4. 最尤推定 98
10.4.1. 最尤推定の概要 98
10.4.2. 多スタート法 98
10.4.3. 安定性の評価 98
10.4.4. 設定 99
10.5. Probabilistic Genotyping 99
10.6. 尤度比 100
10.6.1. 例 1： 既知の contributor が存在しない場合 101
10.6.2. 例 2： 既知の contributor が存在する場合 102
10.7. laboratory-specific parameter の設定方法 103

10.7.1. stutter ratio 104

10.7.2. ローカス固有の PCR 増幅効率 111

10.7.3. ガンマ分布の scale parameter 112

10.7.4. drop-in に関するパラメータ 113

11. 参考文献 115

1. KongohPlus の概要

KongohPlus は、犯罪現場等に遺留されている資料の DNA プロファイルを対象とした尤度比解析を行うための probabilistic genotyping software [1] の 1 つです。本ソフトウェアは、ピーク高情報を利用した統計モデルに基づき、複数の仮説の下で DNA プロファイルが観察される確率を計算し、その比として尤度比を算出します。

KongohPlus は、法科学分野における DNA 鑑定を対象として設計されており、遺留資料の DNA プロファイルの解釈を支援することを目的としています。解析には、DNA 量、混合比、DNA 分解、スタター、ドロップアウト、ドロップインなど、ピーク高に影響を及ぼす要因を考慮した統計モデルを用います。また、利用者が解析条件や laboratory-specific parameter を設定できるよう設計されており、実際の検査環境に応じた解析を行うことができます。

本マニュアルでは、KongohPlus のインストール方法、各種設定、解析手順、および解析結果の見方について説明します。また、ソフトウェアの背景となる統計モデルや計算原理についても解説しています。

2. 初期設定

1. R（バージョン 4.5.2 以上）がインストールされていることを確認してください。R は R Development Core Team のウェブサイトから入手できます。
2. R を起動してください。
3. 必要なパッケージをインストールするため、R 上で以下のコマンドを実行してください。

```
install.packages('https://github.com/manabe0322/KongohPlus/releases/download/
    v1.0.0/KongohPlus_v1.0.0.zip', repos = NULL, type = 'win.binary')
install.packages(c("shiny", "cmaes", "combinat", "data.table", "dplyr", "DT",
    "ggplot2", "gridExtra", "gtools", "htmltools", "knitr", "magrittr",
    "parallel", "Rcpp", "rhandsontable", "rmarkdown", "shinyFeedback",
    "shinyFiles", "shinyjs", "shinythemes", "stringr", "waiter"))
```

2.1. レポート出力を有効にするための設定

　この機能を使用するには、**RStudio からソフトウェアを起動する**か、**Pandoc を手動でインストール**してください。

Pandoc のインストール方法（Windows）

1. Pandoc の公式サイト（https://pandoc.org/installing.html）にアクセスします。
2. **"Download the latest installer"** をクリックします。
3. **Windows installer (*.msi)** をダウンロードします。
4. ダウンロードしたインストーラーを実行し、画面の指示に従ってインストールしてください。

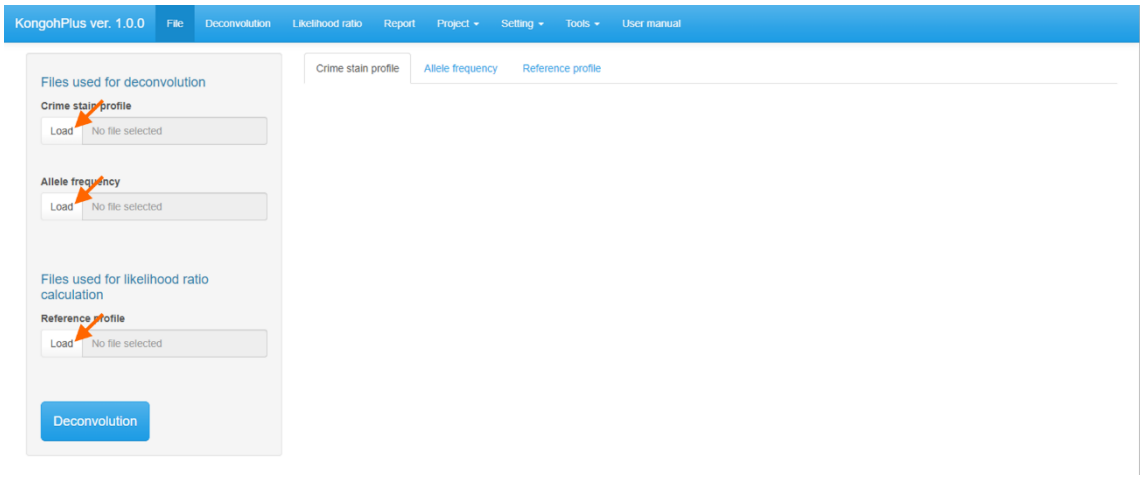
3. クイックガイド

1. R のコンソール画面に以下のコマンドを入力し、ソフトウェアを起動します。

```
library(KongohPlus)

KongohPlus()
```

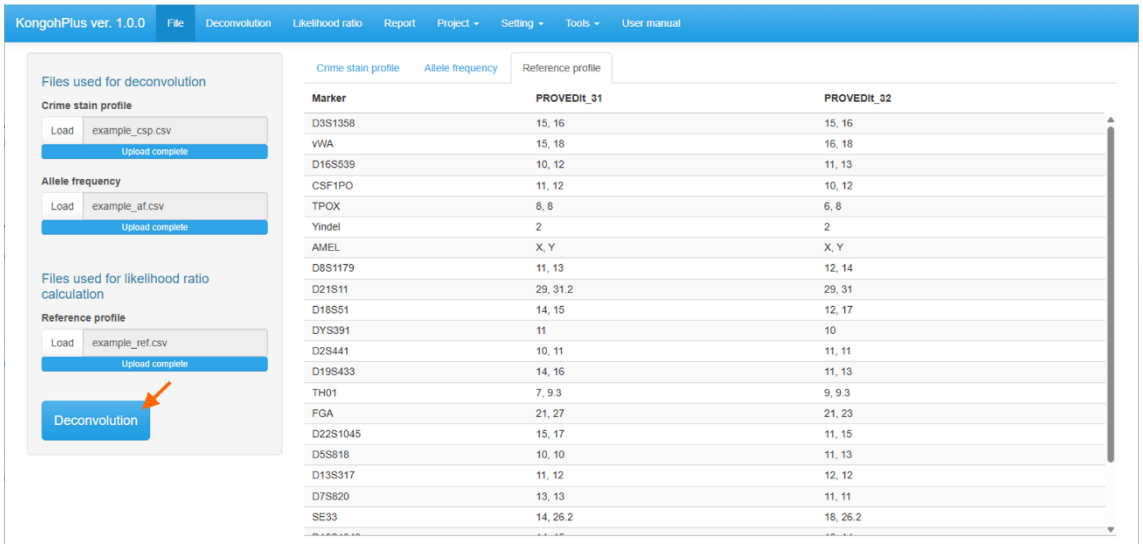
2. 解析に必要なファイルを **“Load”** ボタンから入力します。



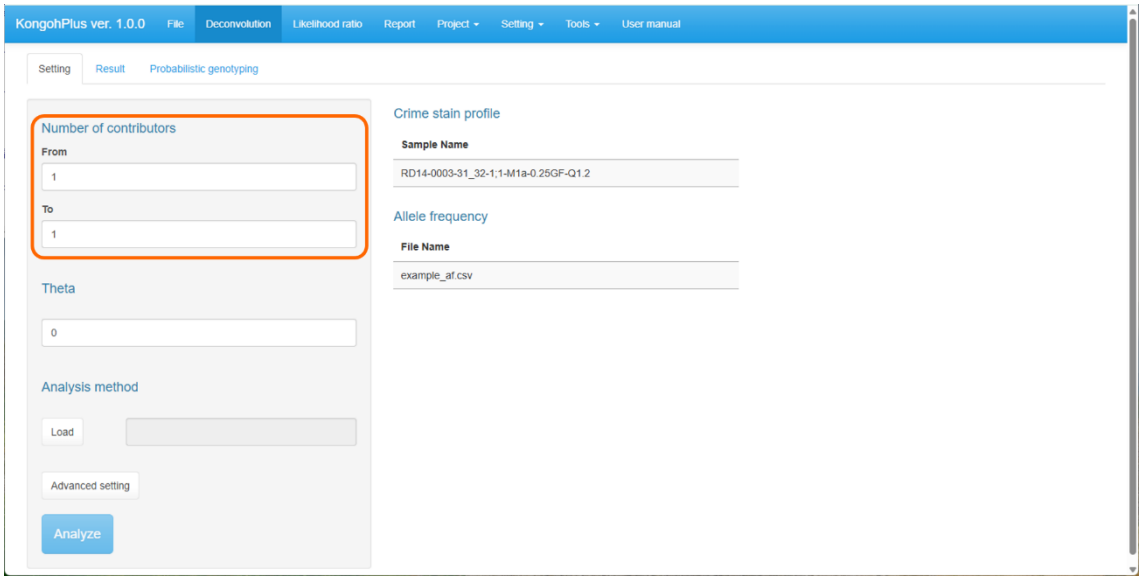
Note:

- Deconvolution には、遺留資料の DNA プロファイル（crime stain profile）、アレル頻度の各ファイルが必要です。
- 尤度比（Likelihood ratio）の計算には、上記 2 ファイルに加え、対照資料の DNA プロファイル（reference profile）のファイルが必要です。
- 各ファイルのフォーマットについては、第 4 項を参照してください。

3. **“Deconvolution”** をクリックします。



4. 関与人数を設定します。

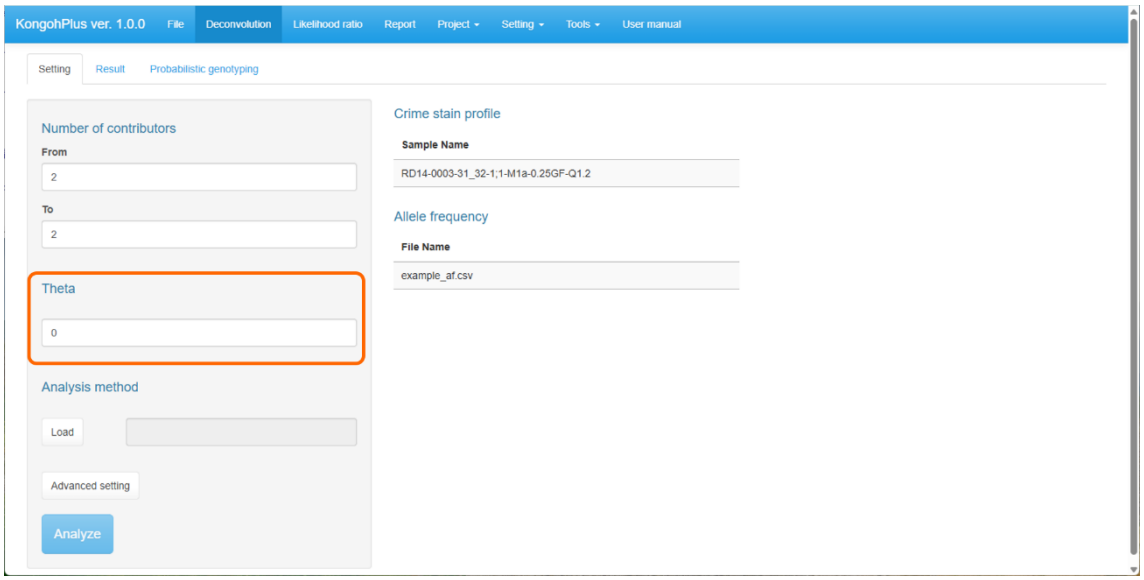


Note:

- 想定する関与人数の下限（From）と上限（To）を設定できます。例えば、From を 2、To を 3 にした場合、2 人と仮定した場合、3 人と仮定した場合それぞれについて、Deconvolution が実施されます。
- ただし、本機能は、Taylor らの報告 [2] のように複数の関与人数の候補を重み付

けして 1 つの尤度比に統合する解析ではありません。

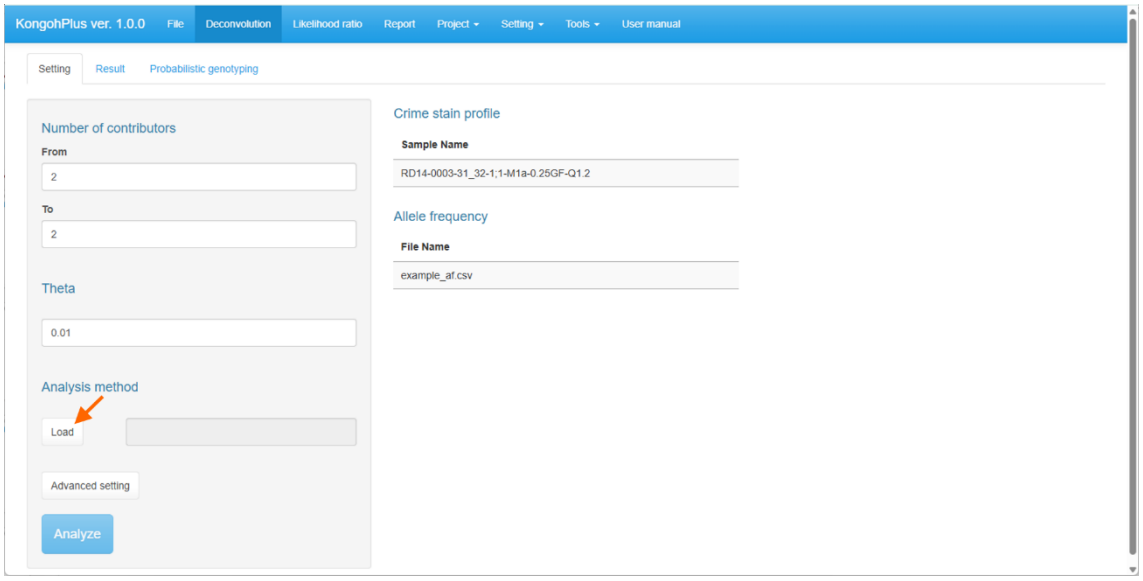
5. Theta を設定します。



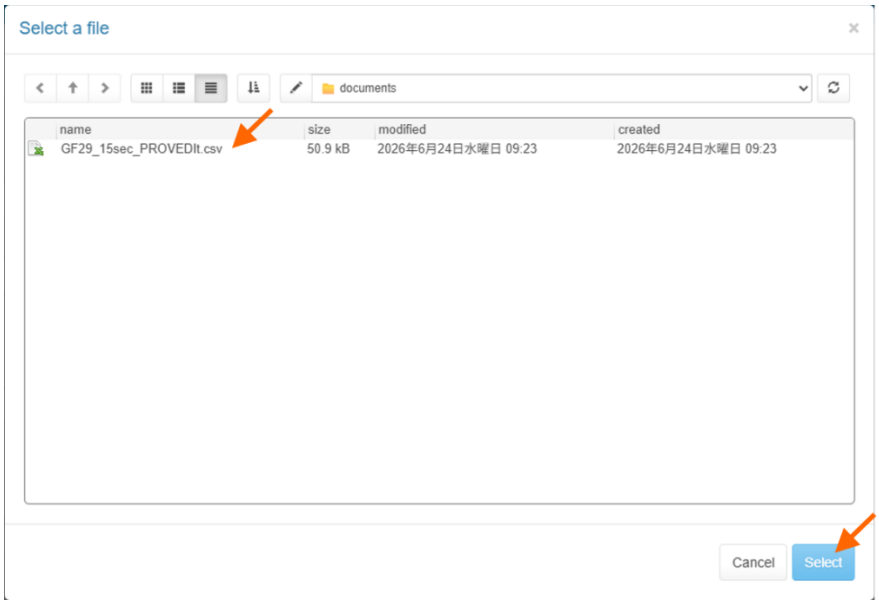
Note:

- Theta は、集団内の亜集団構造（sub-population effect）を考慮して DNA 型頻度を計算するためのパラメータです。

6. Analysis method を **“Load”** ボタンから指定します。



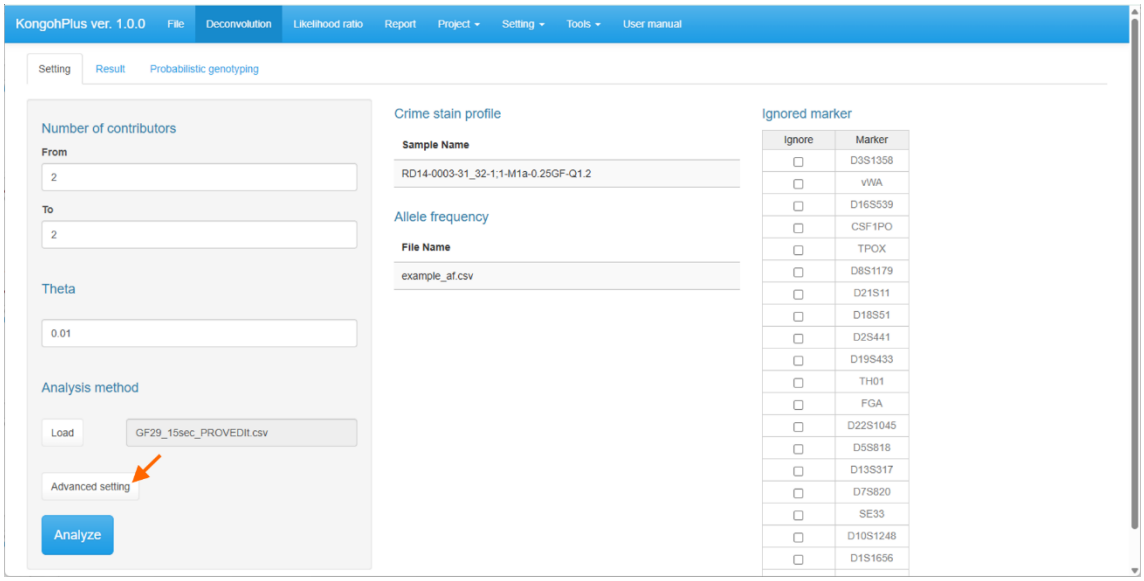
7. Analysis method を選択して、**”Select”** ボタンをクリックします。



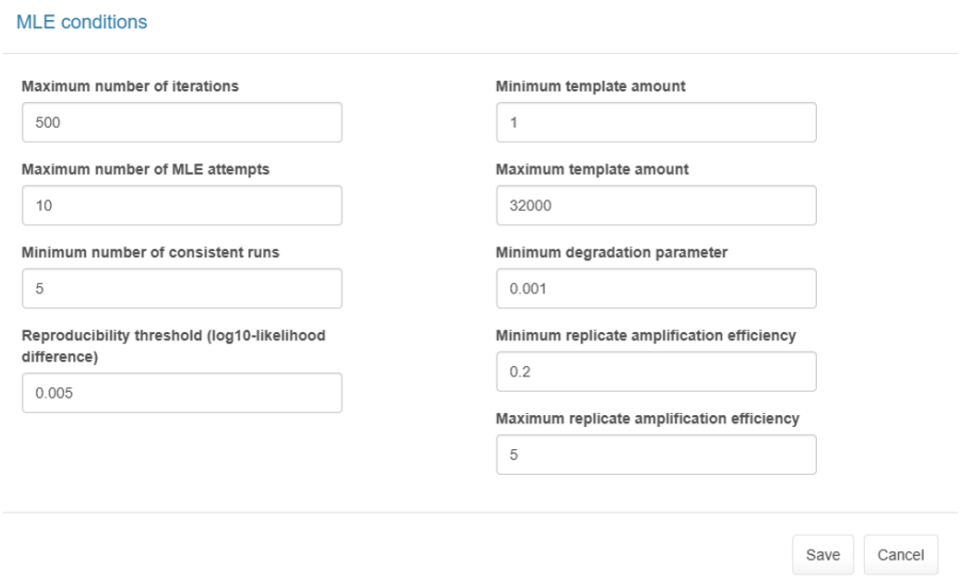
Note:

- Analysis method は、事前に作成しておく必要があります。詳細は、第 8 項を参照してください。

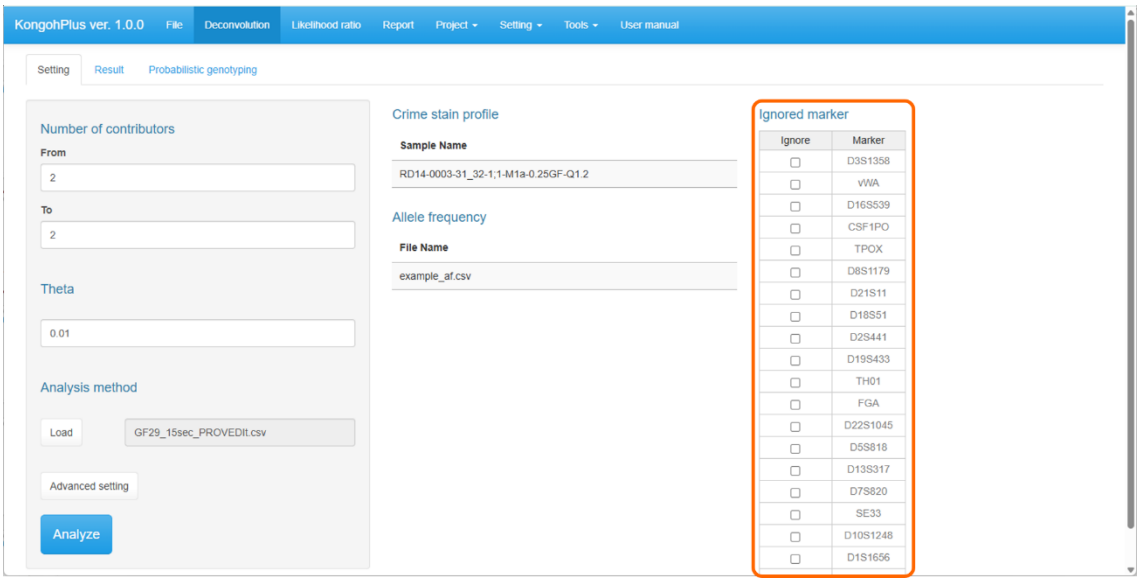
8. 必要に応じて、高度な設定を行います。**”Advanced setting”** をクリックします。



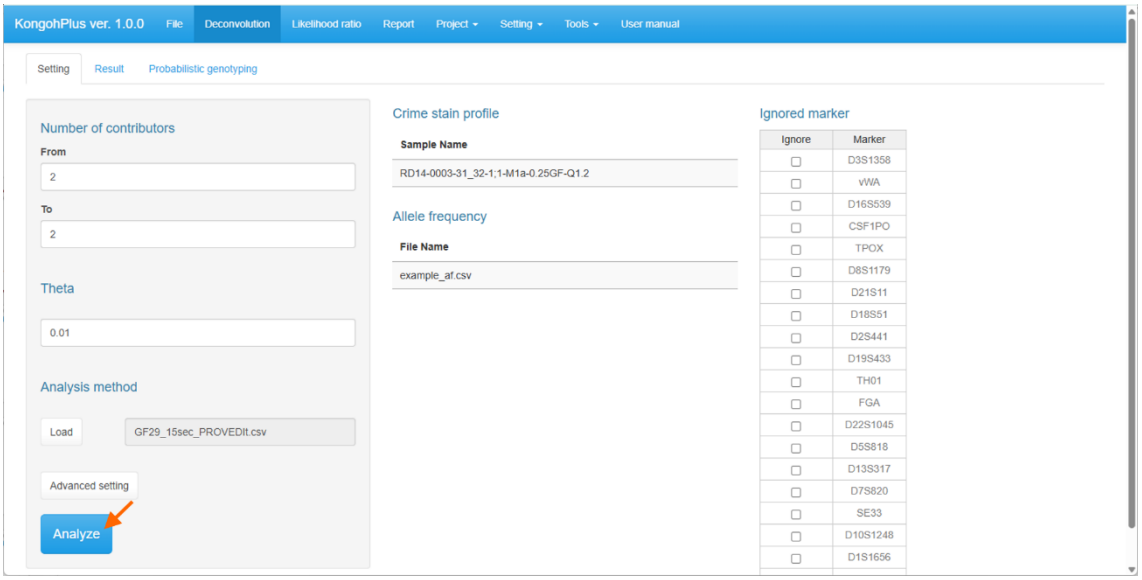
9. ここでは、Deconvolution の過程で実行される最尤推定の条件を設定します（詳細は、第 10.4 項を参照）。各項目の値を確認し、**”Save”** をクリックします。



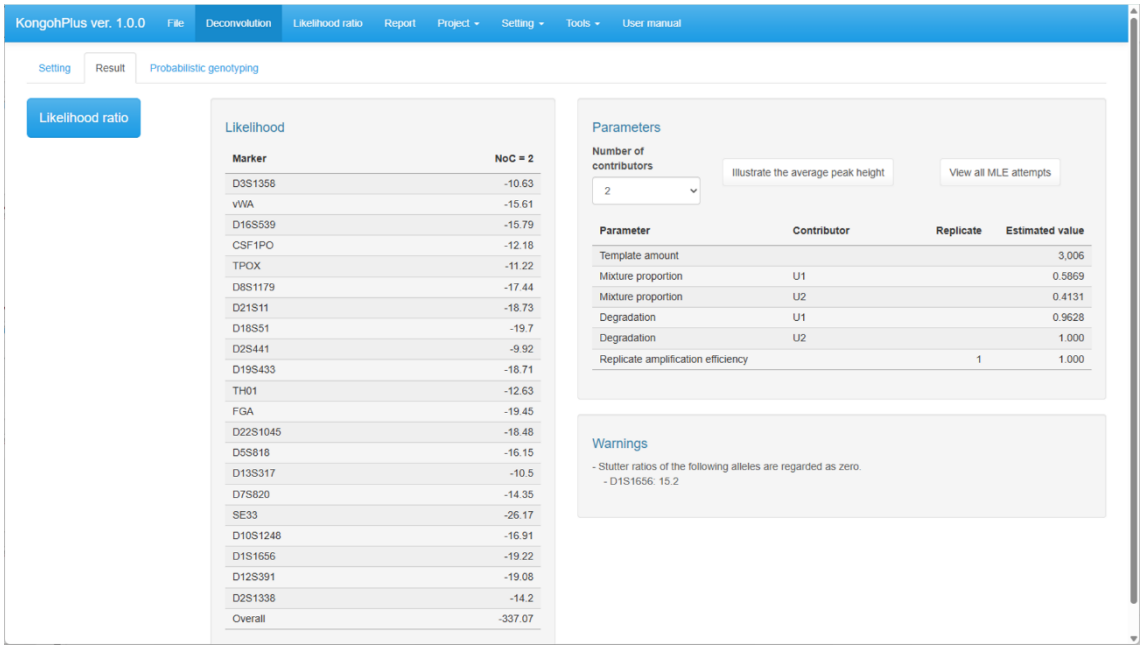
10. 解析から除外したい Marker があれば、チェックします。



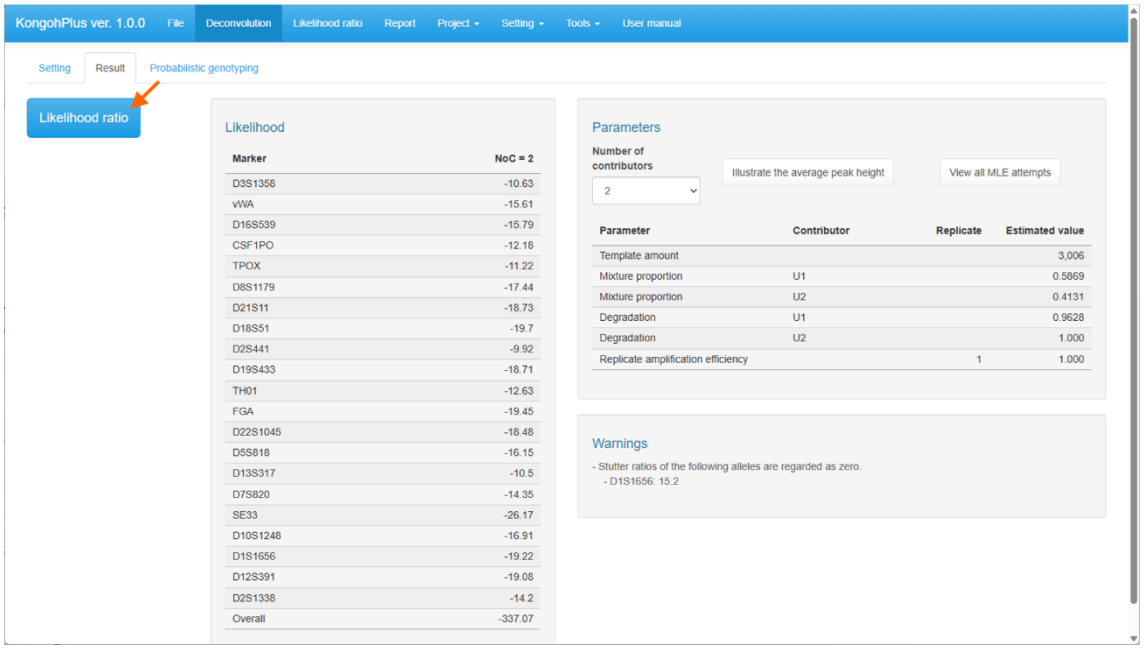
11. **“Analyze”** ボタンをクリックすると、Deconvolution が開始されます。



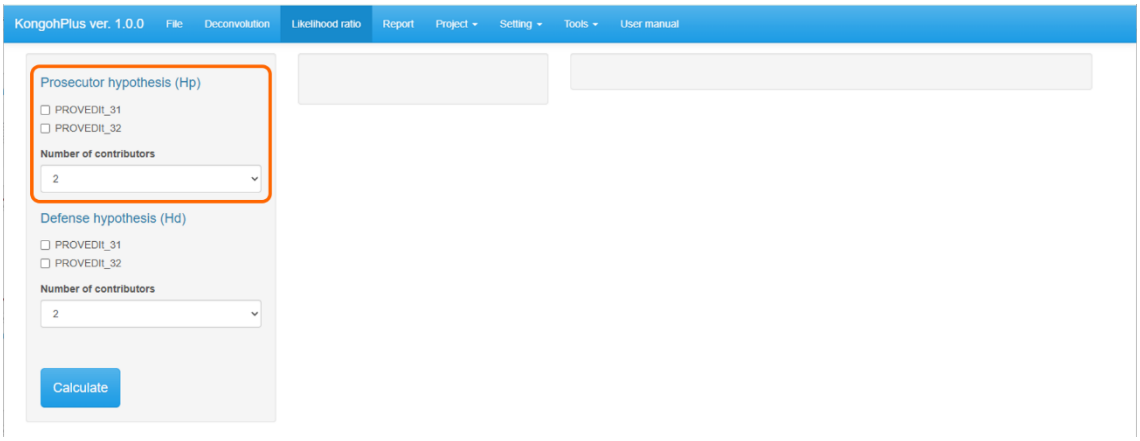
12. Deconvolution 終了後、以下のような解析結果が表示されます。詳細は、第 5 項を参照してください。



13. 続いて、尤度比の計算に移ります。**“Likelihood ratio”** ボタンをクリックします。



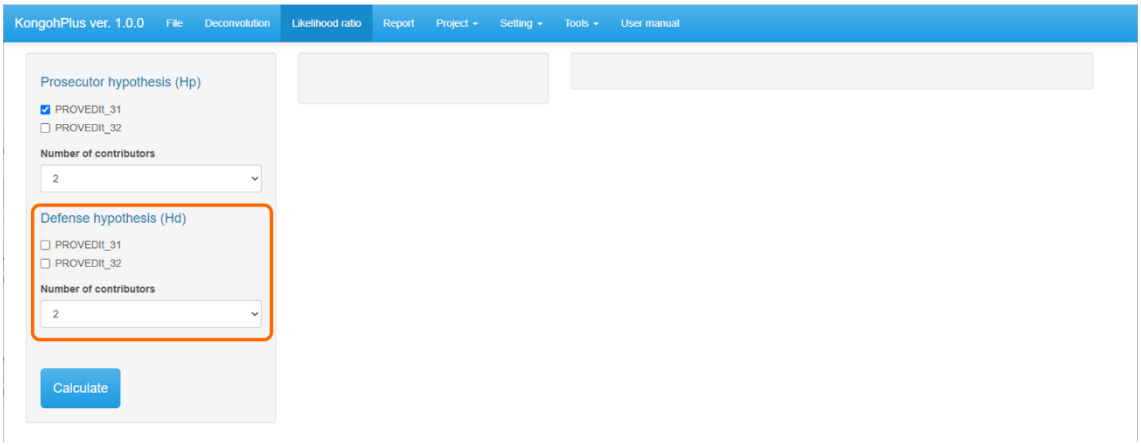
14. Prosecutor hypothesis（尤度比の分子側の仮説）を指定します。



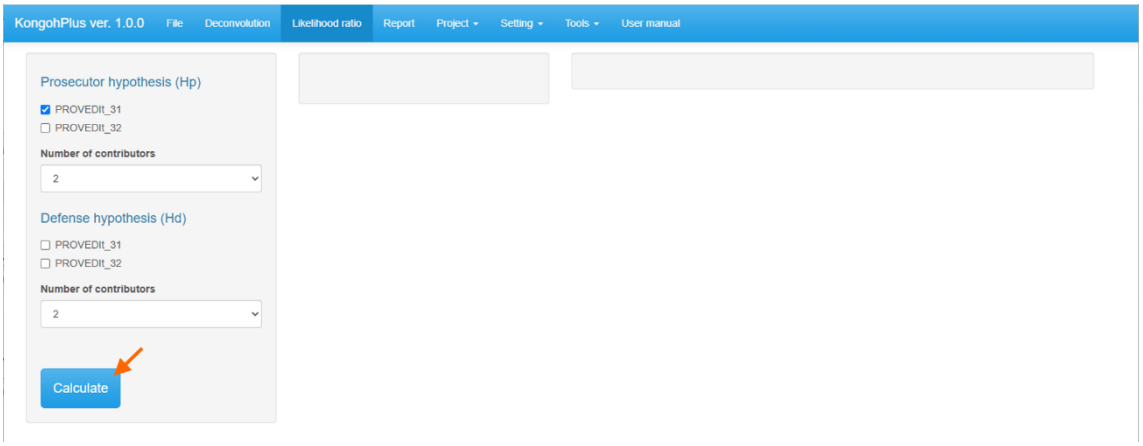
Note:

- 関与者と仮定する個人にチェックします。
- 仮定する関与人数を選択します。

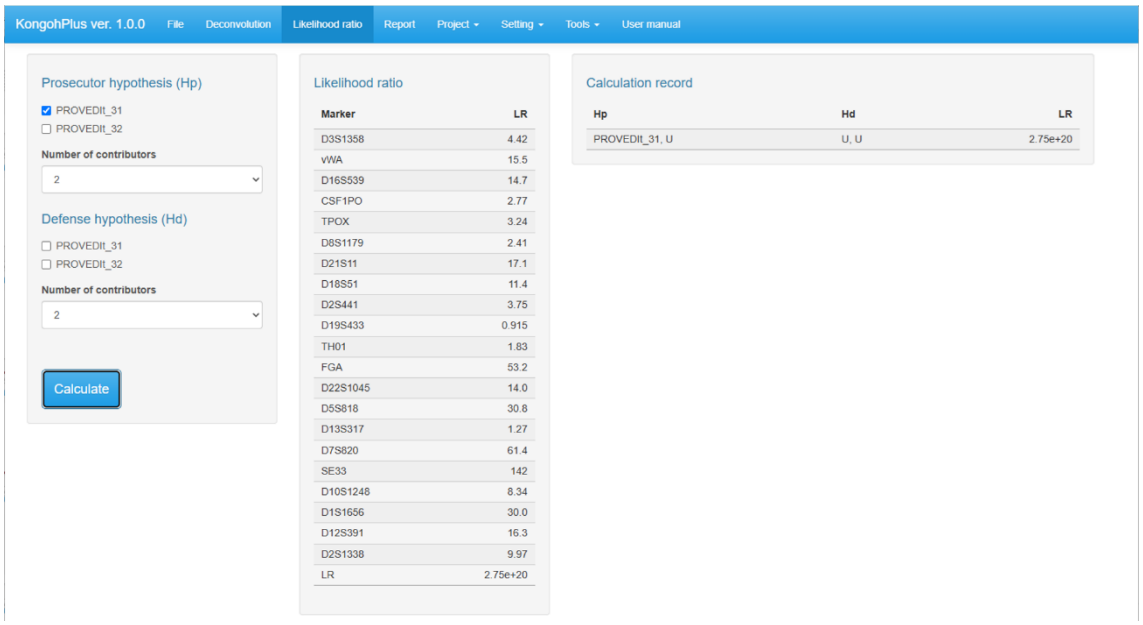
15. Defense hypothesis（尤度比の分母側の仮説）を指定します。



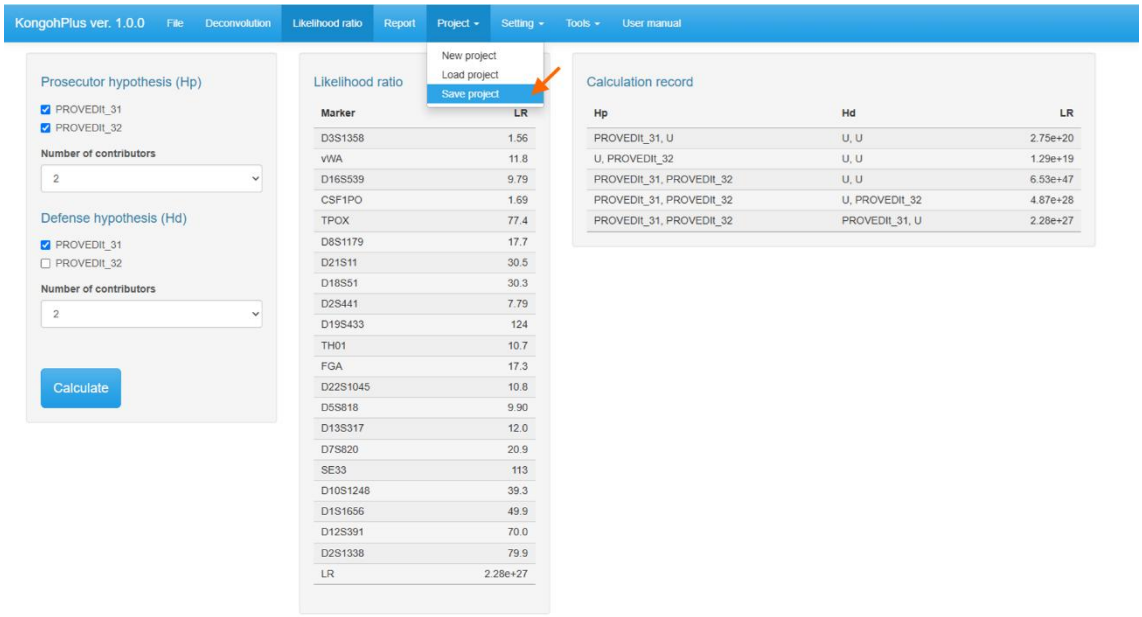
16. **“Calculate”** ボタンをクリックします。



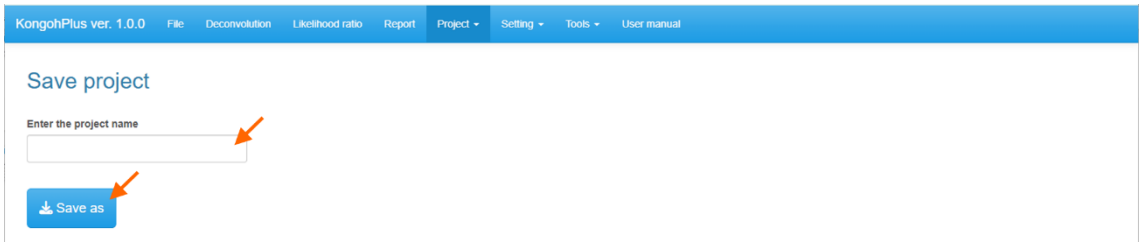
17. 計算終了後、尤度比の結果を確認します。詳細は、第 7 項を参照してください。



18. 解析結果を保存するため、**”Project” ▶ “Save project”** と進んでください。



19. プロジェクト名を入力後、**”Save as”** をクリックしてください。



Note:

- 保存したプロジェクトは、**”Project” ▶ “Load project”** から読み込むことができます。

4. 入力ファイル

本項では、Deconvolution および Likelihood ratio の解析に必要となる入力ファイルの形式について示します。

4.1. 遺留資料の DNA プロファイル（crime stain profile）

遺留資料の DNA プロファイル（crime stain profile）については、以下の表に示すようなデータを **.csv 形式** でご準備ください。

SampleName	Marker	Allele1	Allele2	Allele3	Allele4	…	Height1	Height2	Height3	Height4	…
example	D3S1358	14	15	16		…	305	3865	2317		…
example	vWA	14	15	16	17	…	101	1552	1086	178	…
example	D16S539	9	10	11	12	…	66	1454	782	1372	…
…	…	…	…	…	…	…	…	…	…	…	…

Note:

- **“Tools” ▶ “Example files”** から、ファイル形式の一例をダウンロードできます。
- 解析に使用されるデータは常染色体 STR のみですが、性染色体マーカーのデータが含まれていても問題ありません。
- 常染色体 STR の Allele と Height は全て数字である必要があります。Off-ladder (OL) や Outside Marker Range (OMR) のアレルについては、適切なアレルの数字を割り当てるか、プルアップやノイズと考えられる場合は削除してください。
- PCR を複数回実施した場合は、それぞれのプロファイルに異なる SampleName を設定し、同一の .csv ファイルに縦方向に連結してください。

4.2. アレル頻度（allele frequency）

アレル頻度（allele frequency）については、以下の表に示すようなデータを **.csv 形式** でご準備ください。

Allele	D3S1358	vWA	D16S539	CSF1PO	TPOX	…
10			602	648	100	…
11			562	620	1072	…
12	6		517	1267	114	…
13	3	1	209	208	3	…
14	79	586	26	52	2	…
15	1192	78	3	14		…
…	…	…	…	…	…	…

Note:

- **“Tools” ▶ “Example files”** から、ファイル形式の一例をダウンロードできます。
- 各マーカー列には、population database における各アレルの観察数を入力してください。観察数がゼロの場合は、空欄にしてください。

4.3. 対照資料の DNA プロファイル（reference profile）

対照資料の DNA プロファイル（reference profile）については、以下の表に示すようなデータを **.csv 形式** でご準備ください。

SampleName	Marker	Allele1	Allele2
victim	D3S1358	15	16
victim	vWA	15	18
victim	D16S539	10	10
…	…	…	…
suspect	D3S1358	15	16
suspect	vWA	16	18
suspect	D16S539	11	13
…	…	…	…

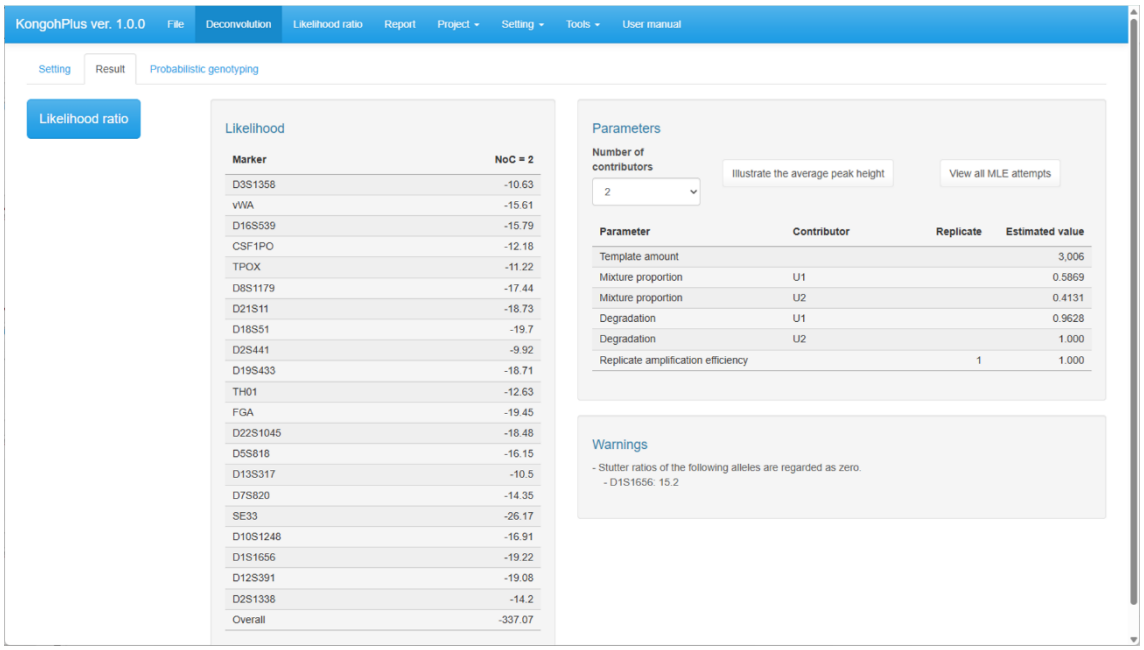
Note:

- **“Tools” ▶ “Example files”** から、ファイル形式の一例をダウンロードできます。
- 解析に使用されるデータは常染色体 STR のみですが、性染色体マーカーのデータが含まれていても問題ありません。
- 常染色体 STR の Allele は全て数字である必要があります。Off-ladder (OL) や Outside Marker Range (OMR) のアレルについては、適切なアレルの数字を割り当ててください。
- ホモ接合体のマーカーについては、同じ数字を 2 つ入力してください。

5. Deconvolution

本項では、Deconvolution の解析結果の確認画面について示します。

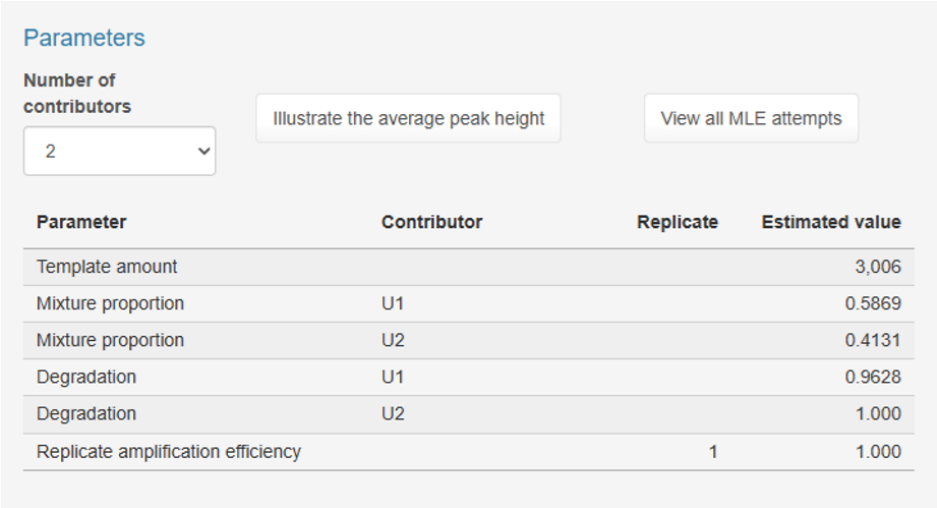
Deconvolution 終了後、以下のような解析結果が表示されます。画面中央にローカス毎の尤度と総合尤度が示されています。画面右上には、パラメータの推定結果が示されています。また、警告があれば画面右下に表示されます。



Note:

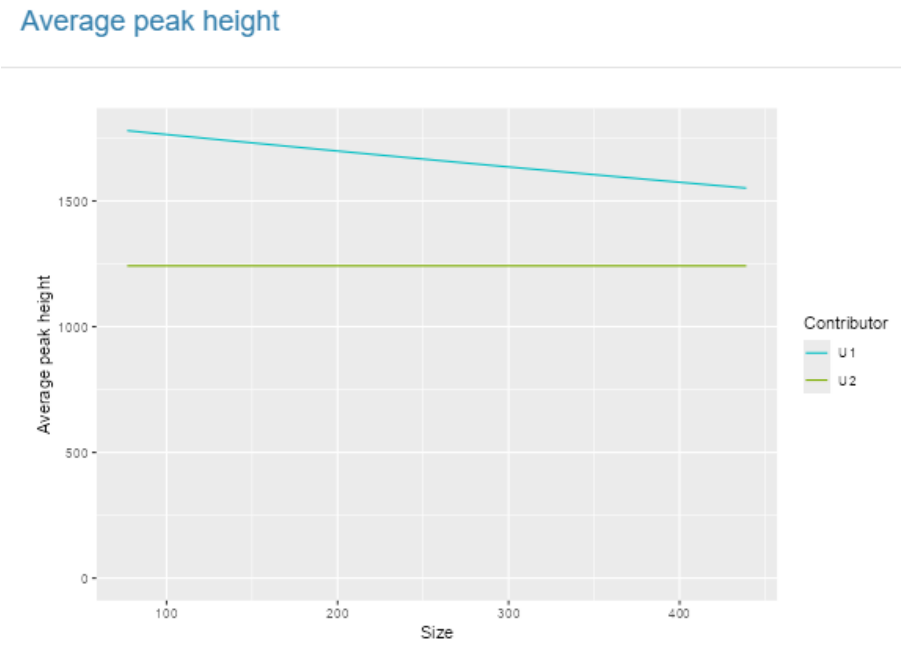
- Stutter ratio が登録されていないアレルが認められた場合には、そのアレルに対する Stutter ratio はゼロであるものとして解析されたことが警告されます。
- 尤度の値の安定性が不十分な場合には、警告が表示されます（詳細は、第 10.4 項を参照）。

画面右上のパラメータの推定結果を拡大して示します。Deconvolution により推定されるパラメータについては、第 10.3.1 項に示す case-specific parameter（プロファイル毎に推定されるパラメータ）をご確認ください。



Parameter	Contributor	Replicate	Estimated value
Template amount			3,006
Mixture proportion	U1		0.5869
Mixture proportion	U2		0.4131
Degradation	U1		0.9628
Degradation	U2		1.000
Replicate amplification efficiency		1	1.000

“Illustrate the average peak height” をクリックすると、各関与者のヘテロ接合体 1 本あたりの平均的なピーク高と、フラグメントサイズとの関係が図示されます。これにより、各パラメータの推定結果を視覚的に捉えることができます。



“View all MLE attempts” をクリックすると、Deconvolution 結果の安定性を確認できます。KongohPlus では、Deconvolution を複数回実行し（既定では最大 10 回）、対数尤度 Log10 (likelihood) の値が所定の回数（既定では 5 回）安定した時点で解析を終了します（詳細は、第 10.4 項を参照）。

下図は、5 回連続で安定した結果が得られた例です。安定した結果の列は青色で示されます。対数尤度 Log10 (likelihood) の値が最も大きい結果の列は水色で示され、この結果が Deconvolution の結果として採用されます。


All MLE attempts

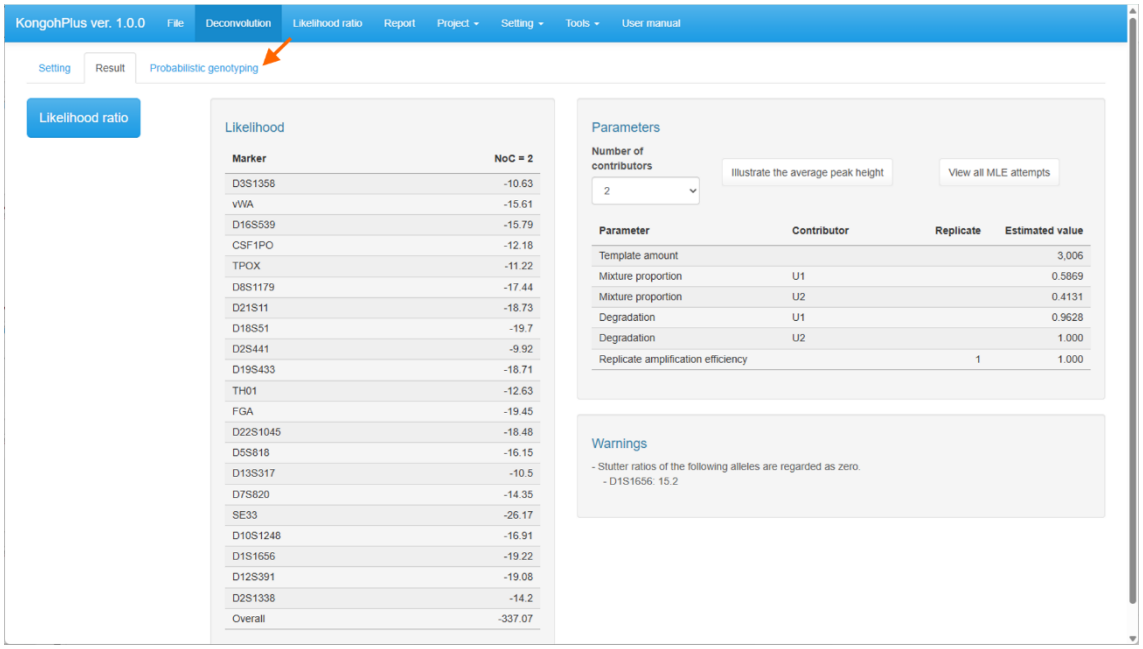
: Selected maximum likelihood : Close to the maximum likelihood

Parameter	MLE 1	MLE 2	MLE 3	MLE 4	MLE 5
Log10 (likelihood)	-337.070	-337.070	-337.070	-337.070	-337.070
Template amount	3,006.00	3,006.06	3,006.16	3,006.25	3,006.18
Mixture proportion	0.586856	0.586896	0.586892	0.586905	0.586886
Mixture proportion	0.413144	0.413104	0.413108	0.413095	0.413114
Degradation	0.962845	0.962766	0.962770	0.962738	0.962788
Degradation	0.999999	0.999999	1.00000	0.999999	1.00000
Replicate amplification efficiency	1.00000	1.00000	1.00000	1.00000	1.00000

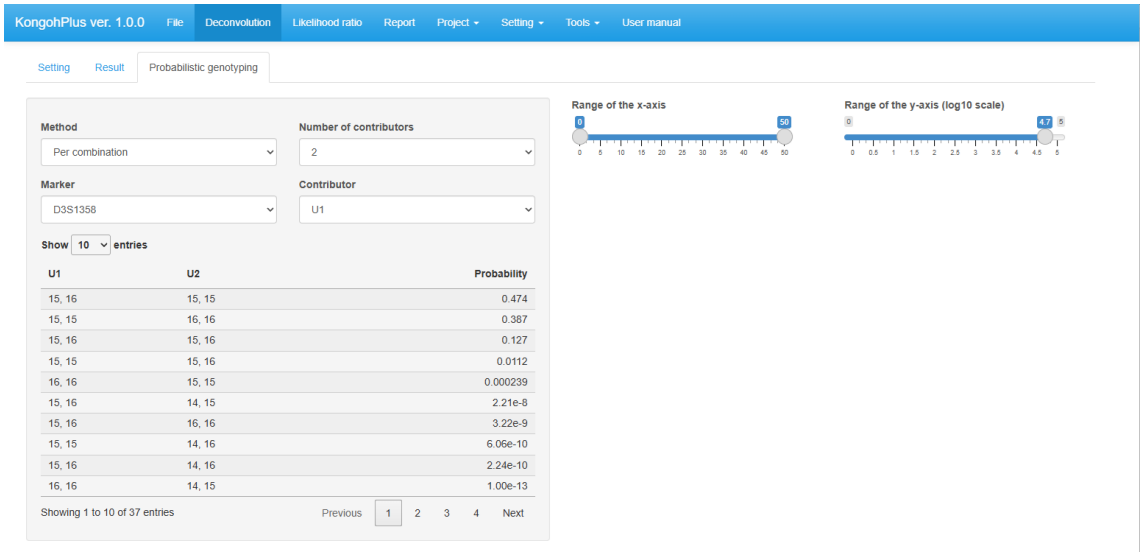
6. Probabilistic Genotyping

本項では、probabilistic genotyping の結果の確認画面について示します。

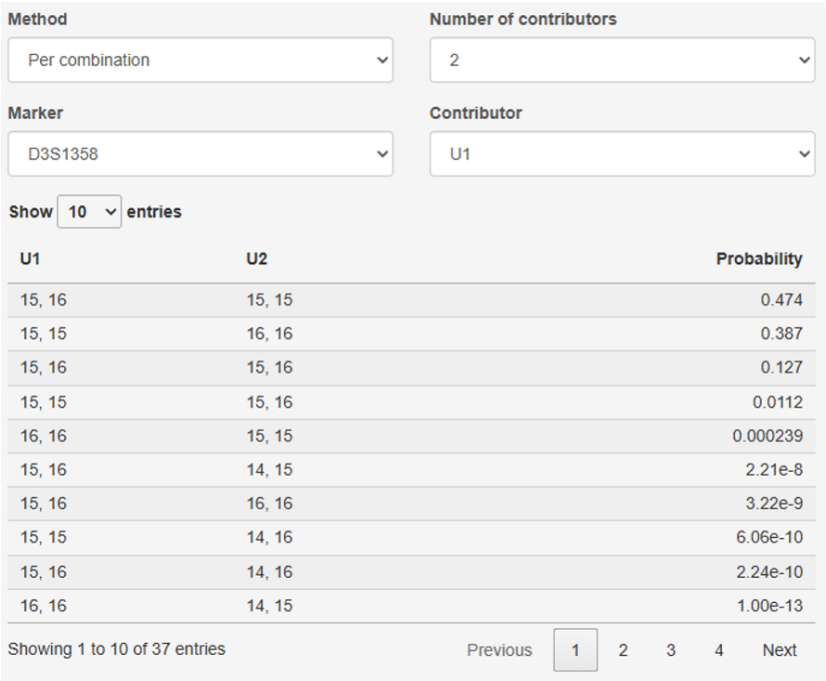
Deconvolution が終了すると、probabilistic genotyping（各関与者が持ち得る DNA 型の候補に対する確率的な重みづけ）の結果を確認できるようになります。下図の **“Probabilistic genotyping”** タブをクリックします。



すると、以下の画面が表示されます。



画面左側に、各関与者の DNA 型の候補とそれぞれの確率が示されます。



以下の項目を変更することで、表示内容を切り替えることができます。

Method

- **Per combination:** 全関与者の DNA 型の組合せに対して、確率を示します。
- **Per contributor:** 関与者 1 人あたりの DNA 型に対して、確率を示します。

Number of contributors

- 前提とする関与人数を選択できます。

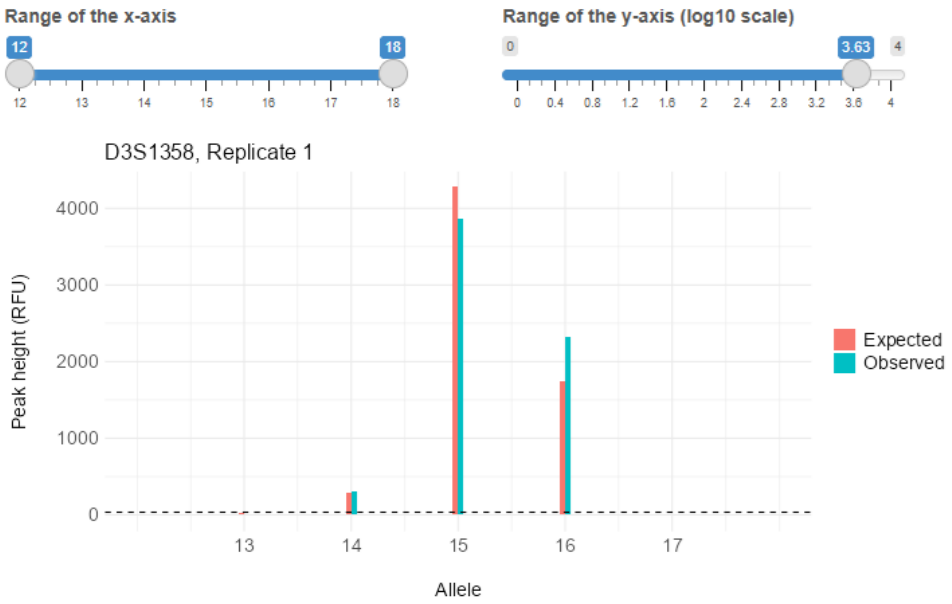
Marker

- 結果を表示したいマーカーを選択できます。

Contributor

- 結果を表示したい関与者を選択できます。**Method** で **Per contributor** を選択した場合のみ有効です。

また、probabilistic genotyping の結果表の各行を選択すると、その DNA 型を前提とした場合のピーク高の期待値と実際の観察値との比較結果が画面右側に表示されます。

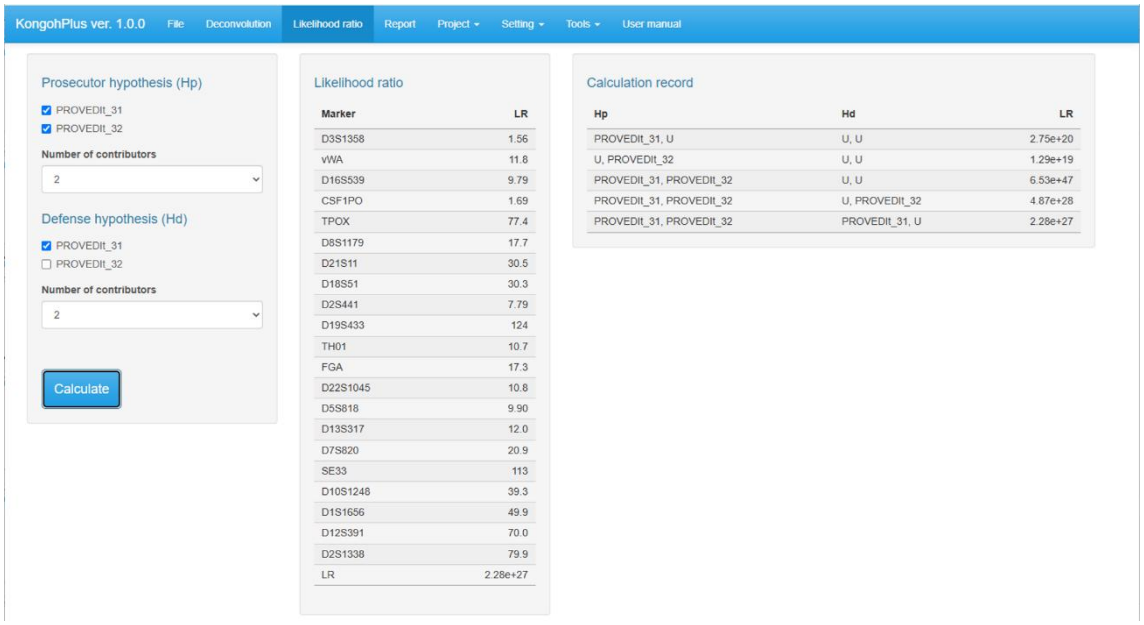


Note:

- Method で Per contributor を選択した場合は、対象とする関与者 1 人あたりのピーク高の期待値が示されます。
- PCR を複数回実施した場合は、それぞれのプロファイルについて、ピーク高の期待値と観察値の比較結果が表示されます。

7. 尤度比

本項では、尤度比の計算結果の確認画面について示します。



Note:

- 尤度比の計算は、仮説を変更しながら、何度でも行うことができます。
- 全ての計算結果は、画面右の **“Calculation record”** に記録されます。
- 画面中央には、**“Calculation record”** で選択した行の尤度比が表示されます。
- **“Calculation record”** の Hp および Hd に表示されている個人は、mixture proportion の多い順になります。例えば、上図の Hp における「PROVEDIt_31, U」は、”PROVEDIt_31” という名前の人物が major contributor、U（unknown contributor の略）が minor contributor と推定されたことを意味します。

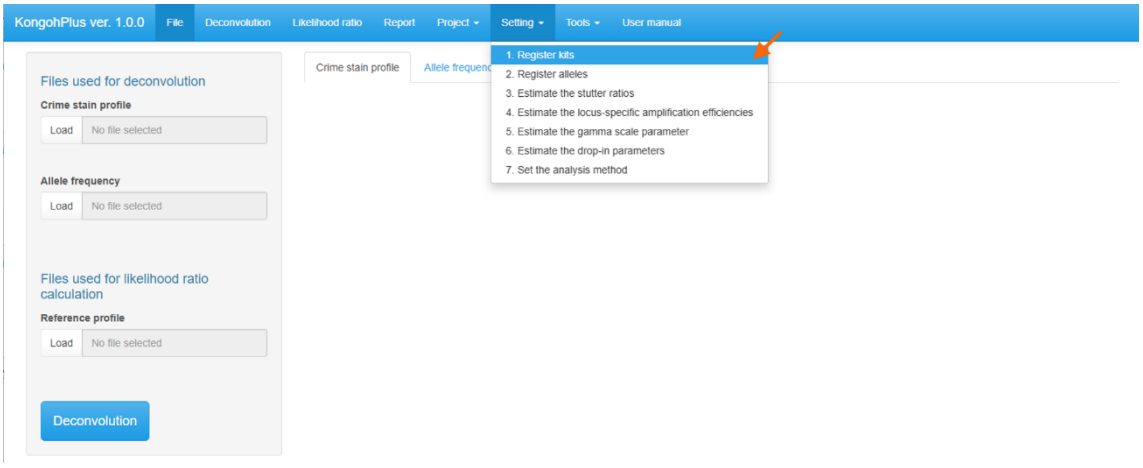
8. 設定

本項では、KongohPlus で解析を行うために必要となる設定項目について説明します。

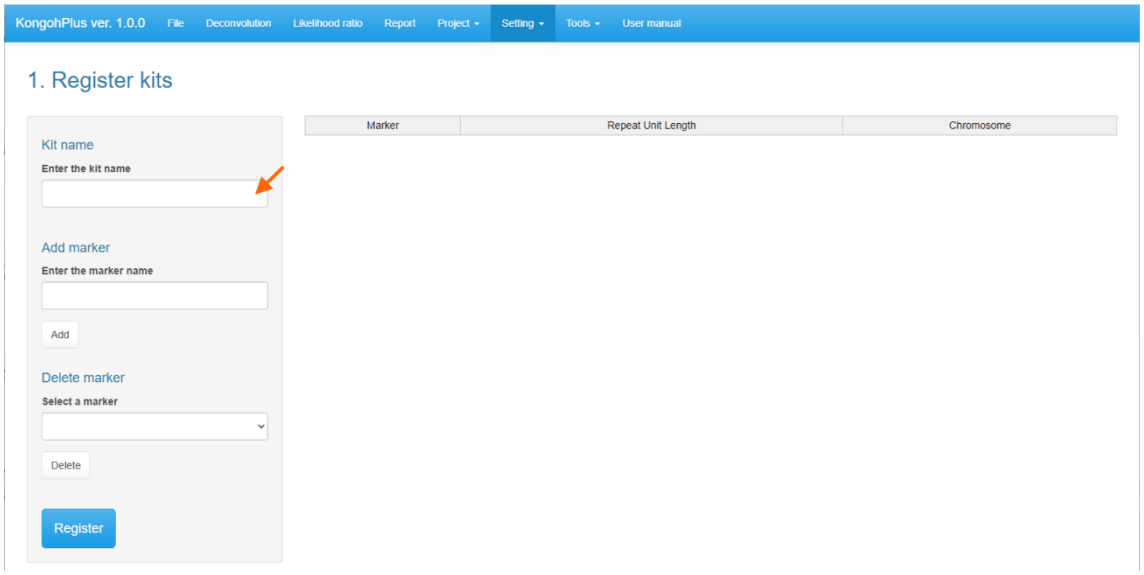
8.1. 検査キットの登録

解析対象となるプロファイルの検査キットが登録されていない場合、最初に検査キットに含まれるマーカーの情報を登録する必要があります。本項では、その手順について説明します。

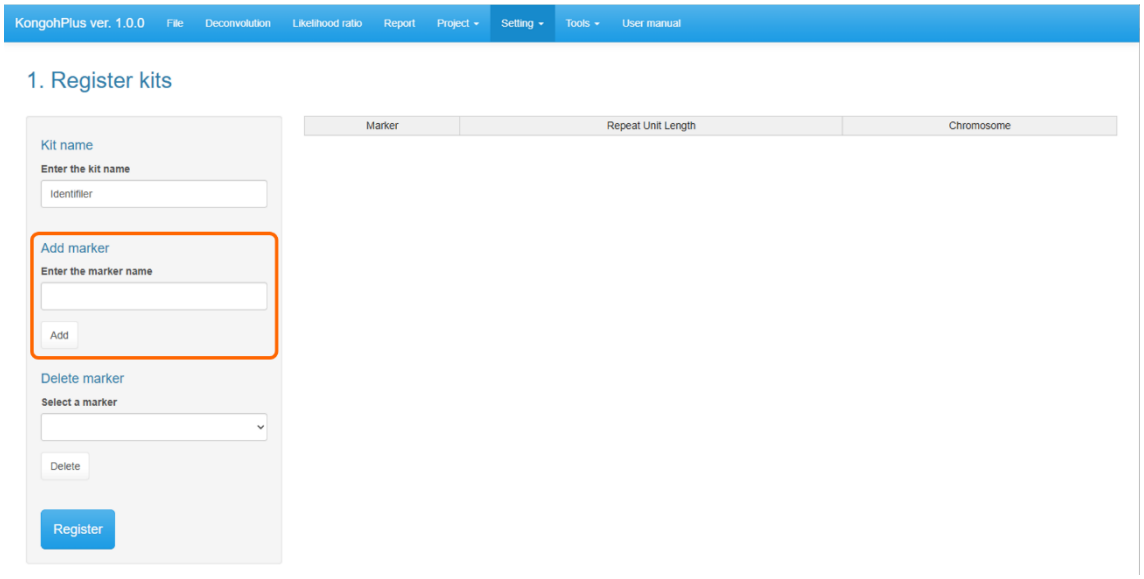
1. **“Setting” ▶ “1. Register kits”** をクリックします。



2. キット名を入力します。



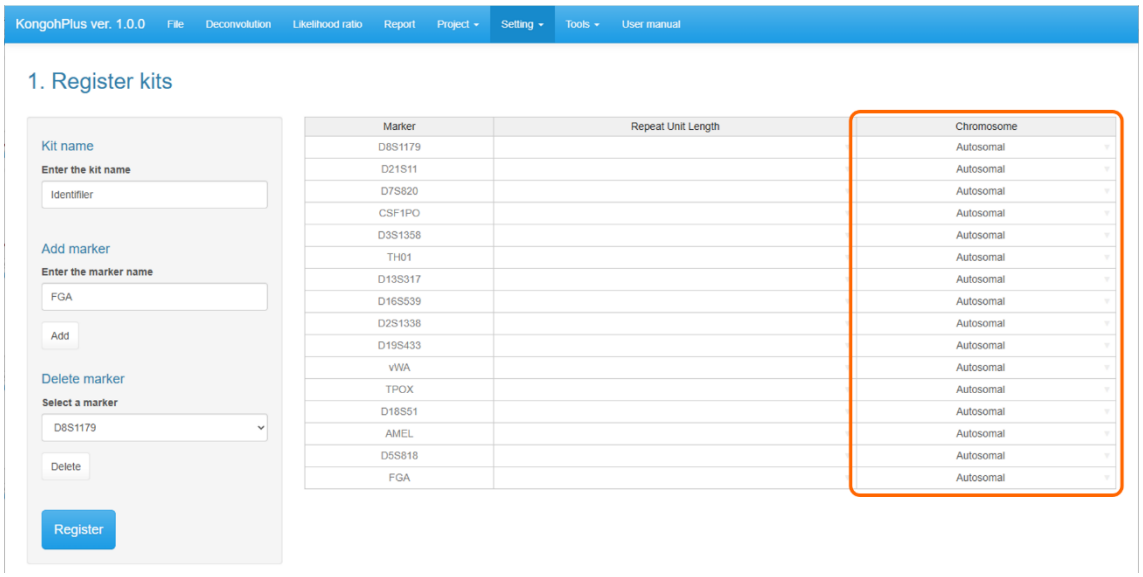
3. **”Add marker”** でマーカー名を入力し、**”Add”** をクリックします。



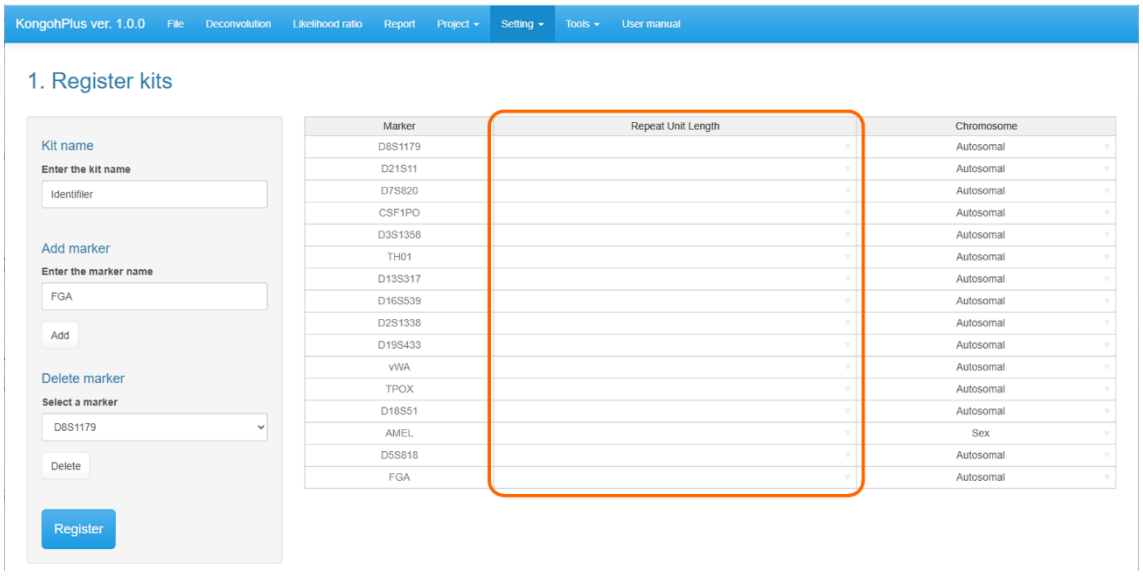
Note:

- 全マーカーを登録するまで繰り返します。
- 間違って登録したマーカーは、**”Delete marker”** から削除することができます。

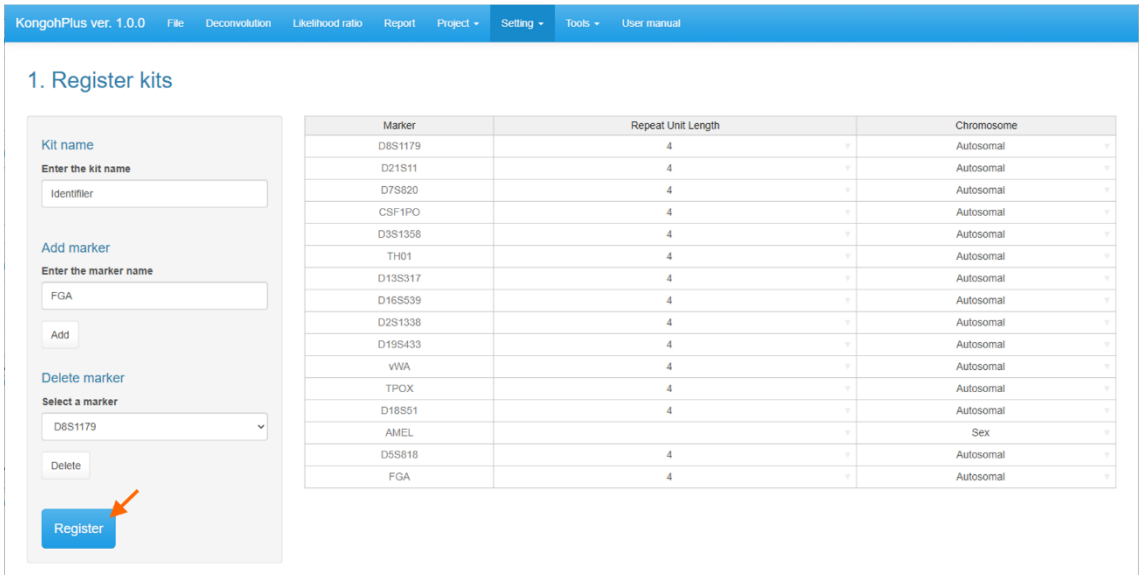
4. 常染色体上の STR（Autosomal）か、性染色体マーカー（Sex）かを選択します。



5. 常染色体上の STR（Autosomal）について、繰り返し単位あたりの塩基数（Repeat Unit Length）を選択します。



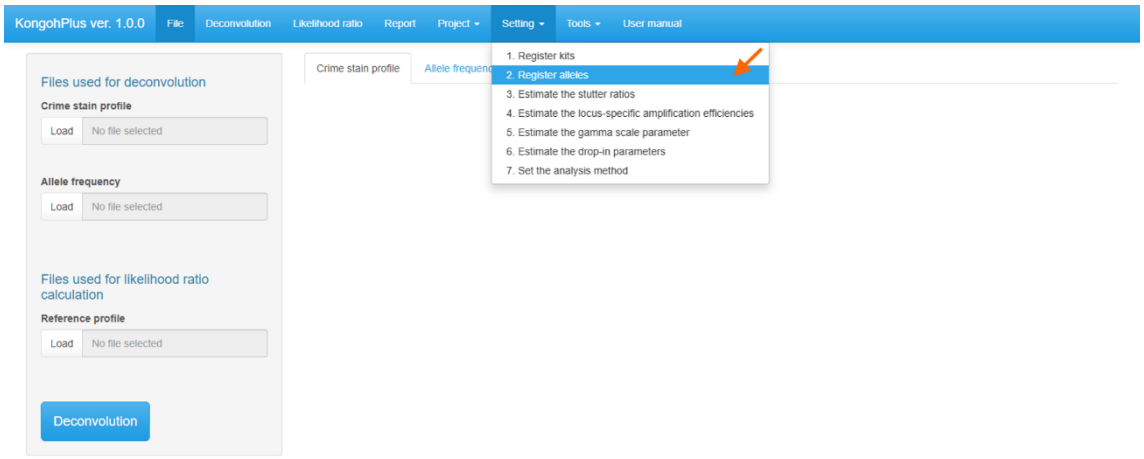
6. Register をクリックします。



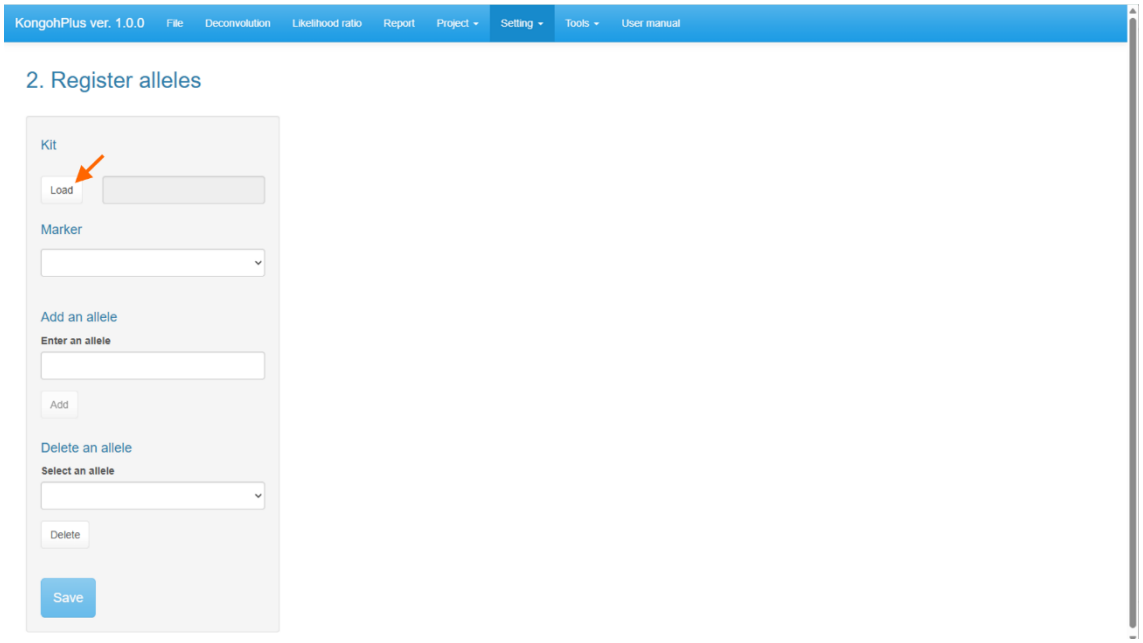
8.2. アレルの登録

本項では、検査キットに含まれる各マーカーのアレル情報を登録する手順について説明します。アレル情報には、DNA 分解の程度を推定するために必要なフラグメントサイズが含まれます。また、登録したアレルには stutter ratio を設定することができます。そのため、解析対象となり得るアレルをできるだけ網羅的に登録することを推奨します。

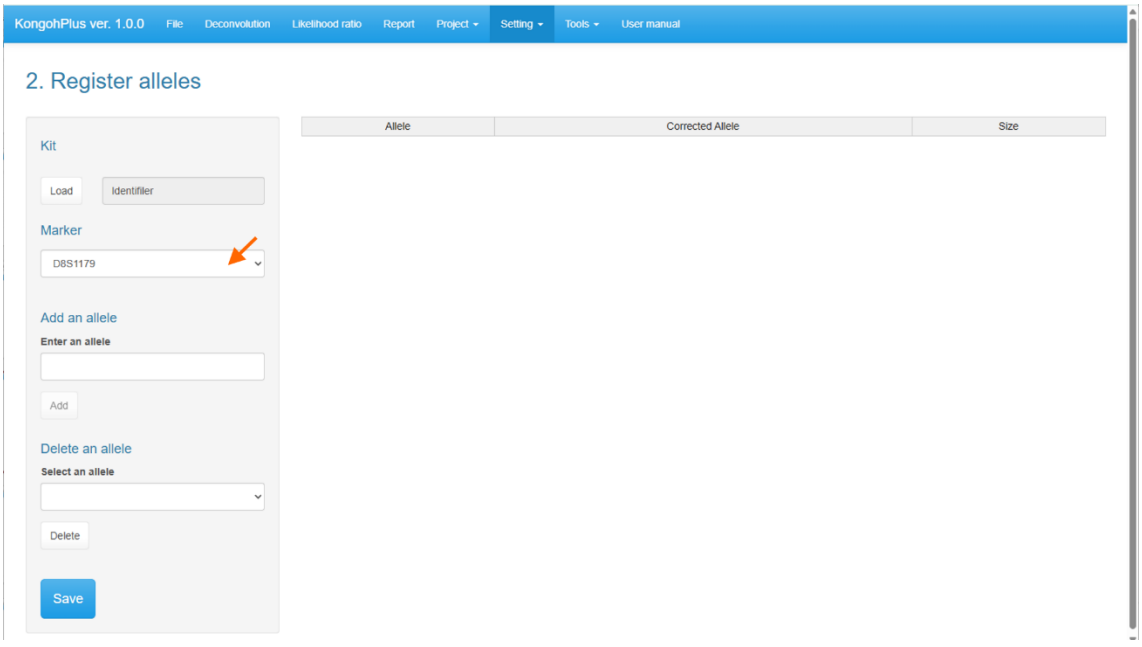
1. **“Setting” ▶ “2. Register alleles”** をクリックします。



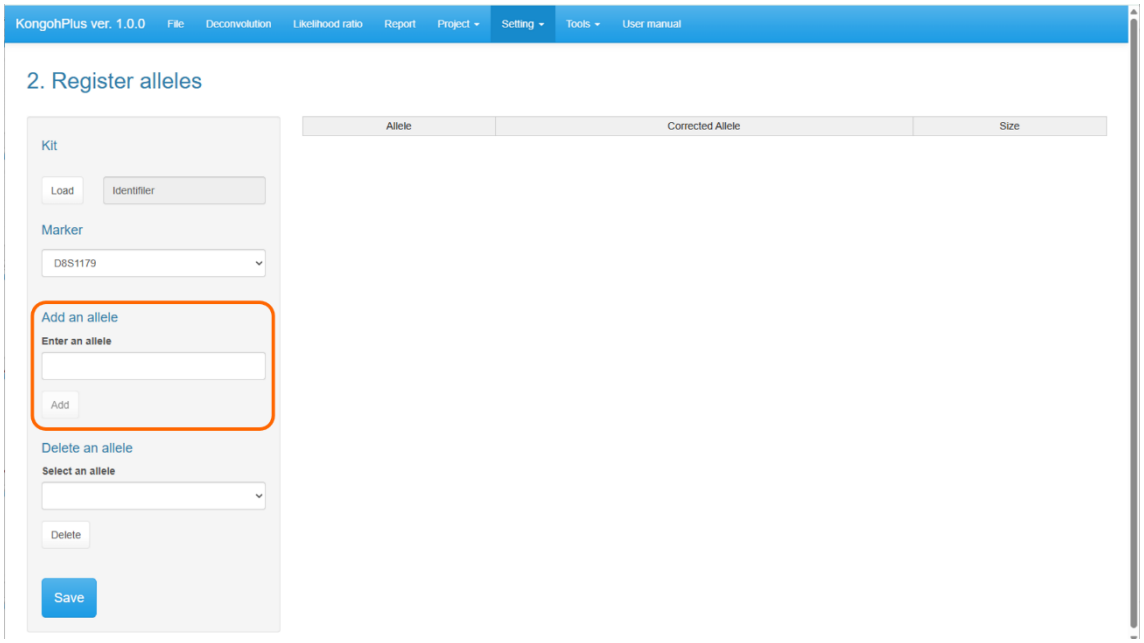
2. 登録したキットの情報を **“Load”** ボタンから読み込みます。



3. マーカーを選択します。



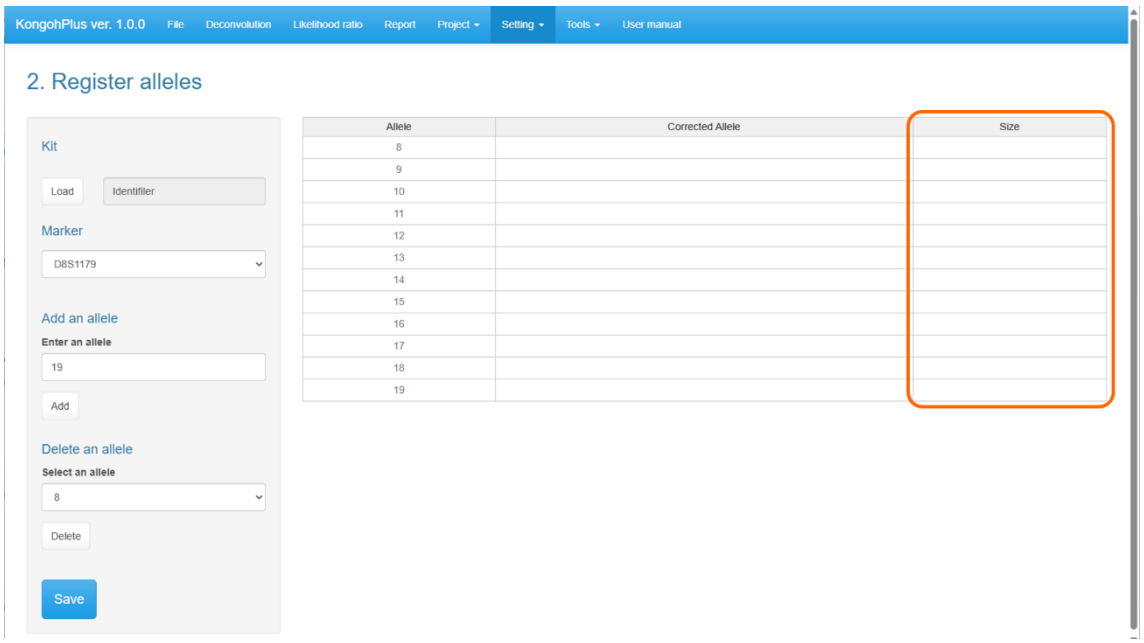
4. **“Add an allele”** でアレルの数字を入力し、**”Add”** ボタンをクリックします。



Note:

- ステップ 3 と 4 の操作を繰り返し、全てのマーカーについて、観察される可能性のあるアレルを登録してください。
- 間違って登録したアレルは、**”Delete an allele”** から削除することができます。

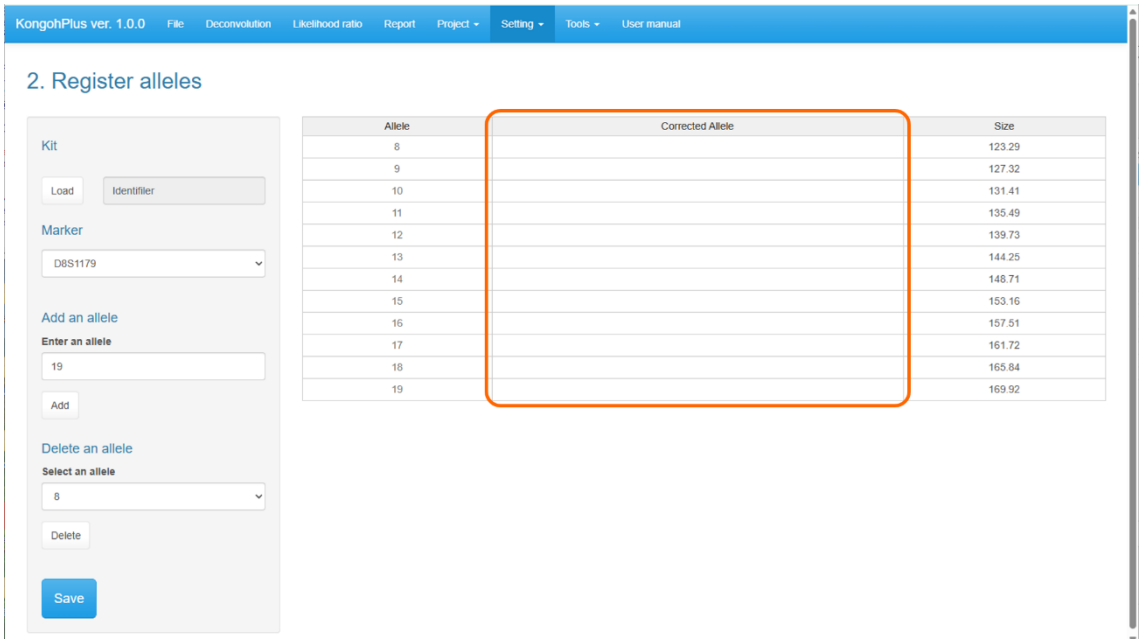
5. フラグメントサイズを入力します。



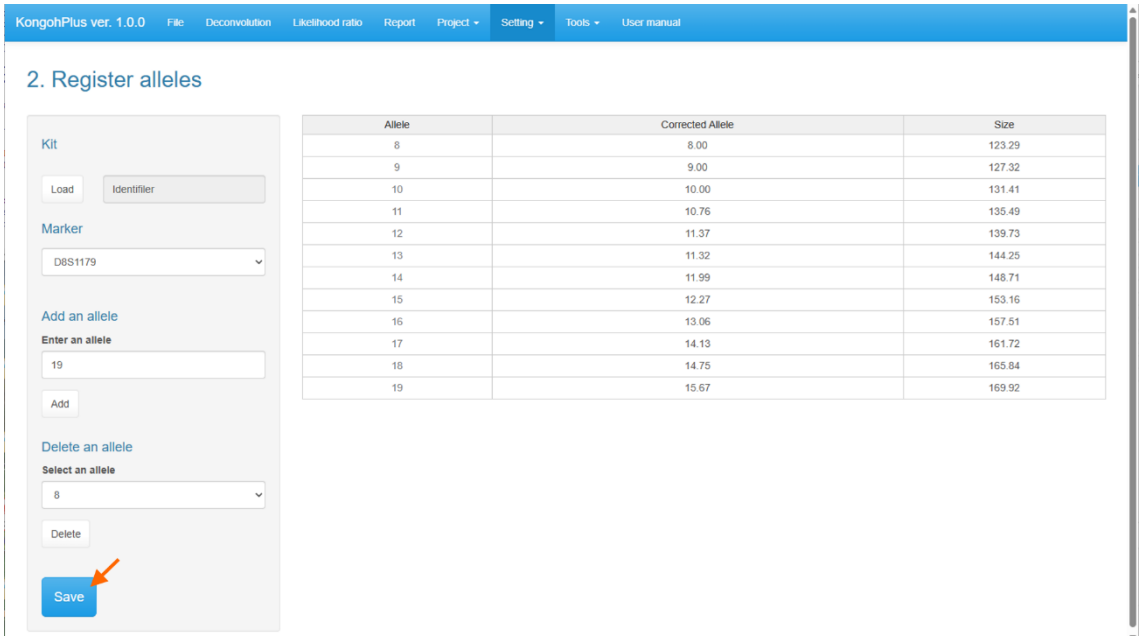
Note:

- 代表的なアレリックラダーのデータ等を基に、平均的なサイズを設定してください。

6. Stutter ratio の統計学的モデルとして、Linear (Corrected Allele) を採用するマーカーについて、Corrected Allele を入力します。Stutter ratio の統計学的モデルについては、第 10.7.1 項を参照してください。



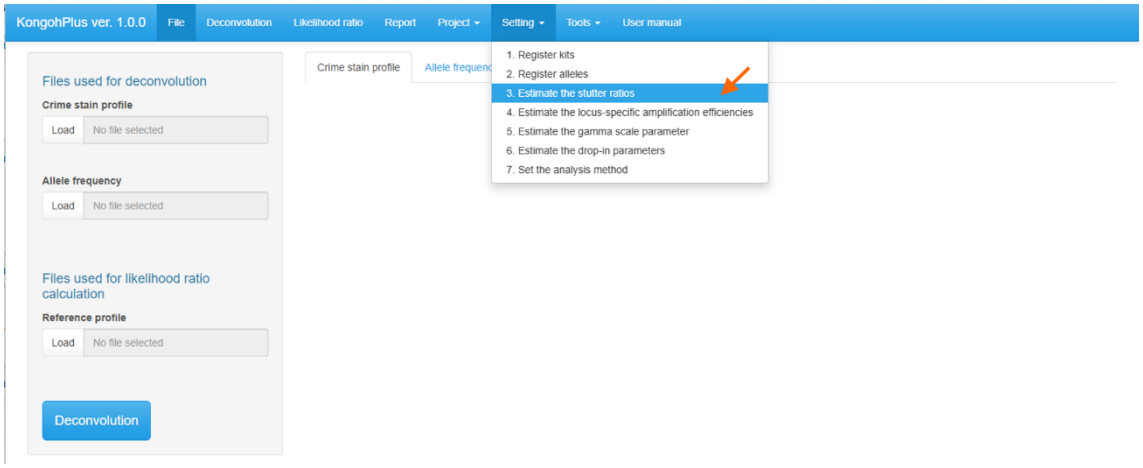
7. 全てのマーカーについて設定が完了したら、**"Save"** ボタンをクリックします。



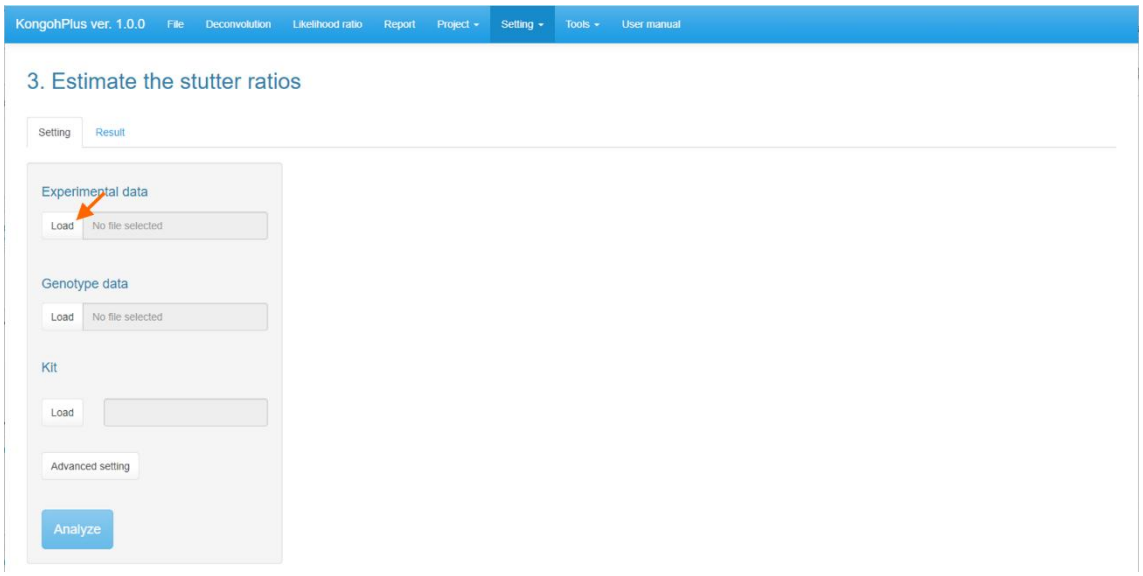
8.3. Stutter ratio の推定

本項では、実験的に取得したプロファイルを基に、アレル毎の stutter ratio を推定するための手順について説明します。

1. **“Setting” ▶ “3. Estimate the stutter ratios”** をクリックします。



2. 実験データセットを下図の **“Load”** ボタンから入力します。



実験データセットの条件

- 各プロファイルは、単一個人由来であること
- DNA の分解がないこと
- 様々な個人のプロファイルを含むデータセットであること（stutter ratio はアレル毎に推定されるため、様々なアレルが含まれていることが望ましい）

実験データセットのファイル形式

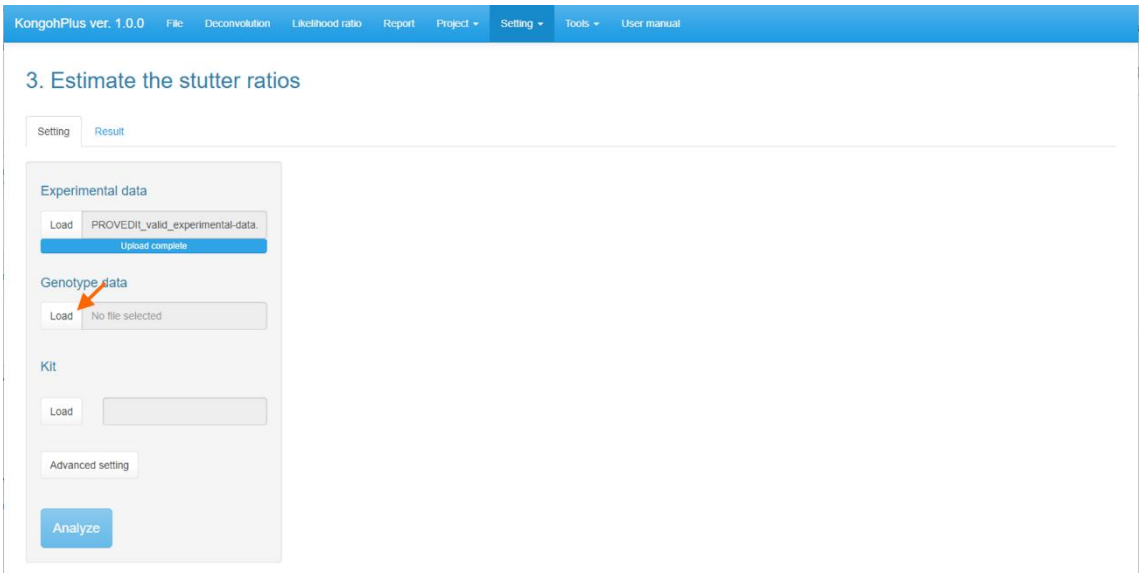
実験データセットは、以下の表に示すようなデータを **.csv 形式** でご準備ください。

SampleName	Marker	Allele1	Allele2	Allele3	Allele4	…	Height1	Height2	Height3	Height4	…
example1	D3S1358	13	14	17	18	…	103	2130	152	1701	…
example1	vWA	16	17	18	19	…	93	1394	104	1328	…
example1	D16S539	11	12	13		…	84	1610	1367		…
…	…	…	…	…	…	…	…	…	…	…	…

Note:

- 解析に使用されるデータは常染色体 STR のみですが、性染色体マーカーのデータが含まれていても問題ありません。
- 常染色体 STR の Allele と Height は全て数字である必要があります。Off-ladder (OL) や Outside Marker Range (OMR) のアレルについては、適切なアレルの数字を割り当てるか、プルアップやノイズと考えられる場合は削除してください。
- それぞれのプロファイルに異なる SampleName を設定し、同一の .csv ファイルに縦方向に連結してください。

3. 実験プロファイルの DNA 型データセットを下図の **“Load”** ボタンから入力します。



DNA 型データセットのファイル形式

DNA 型データセットは、以下の表に示すようなデータを **.csv 形式** でご準備ください。

SampleName	Marker	Allele1	Allele2
example1	D3S1358	15	16
example1	vWA	15	18
example1	D16S539	10	10
…	…	…	…

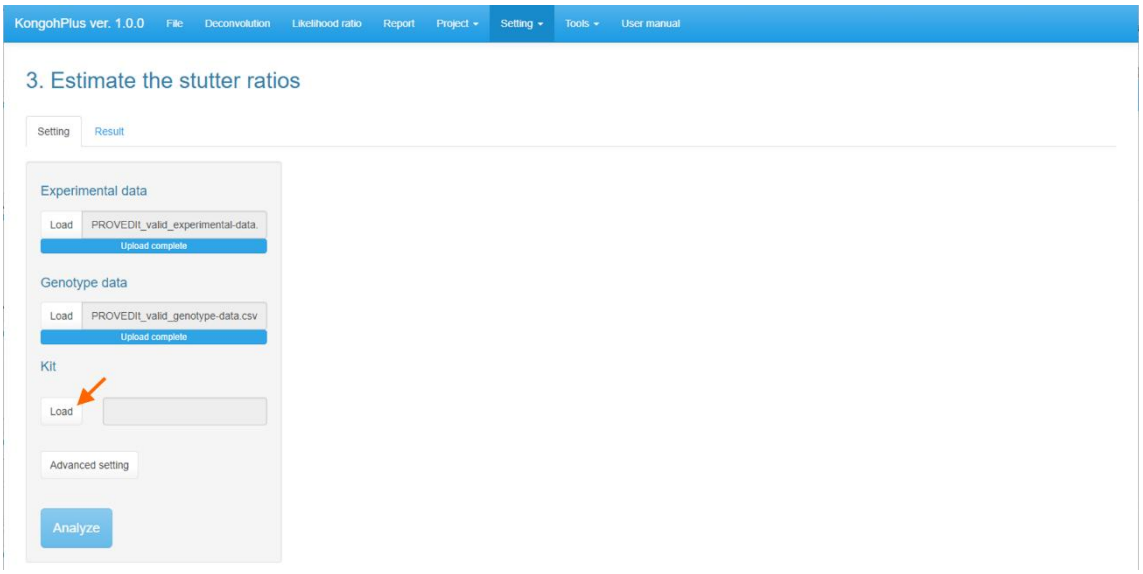
Note:

- SampleName は、実験データセットと対応させてください。
- 各プロファイルの DNA 型データは、同一の .csv ファイルに縦方向に連結してくだ

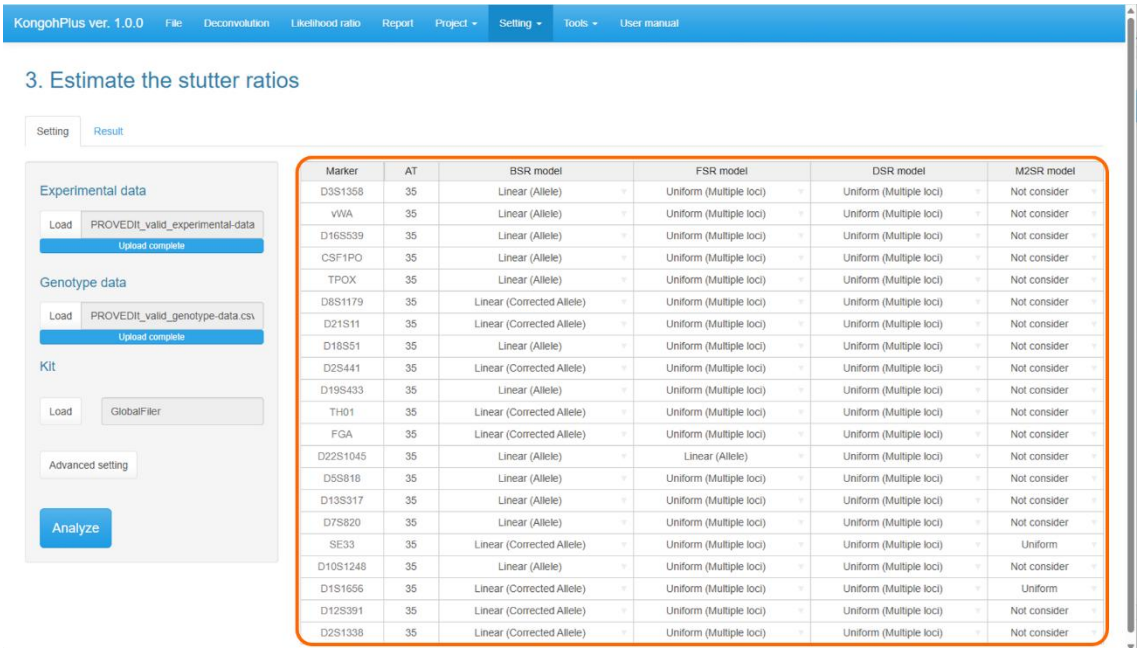
さい。

- 解析に使用されるデータは常染色体 STR のみですが、性染色体マーカーのデータが含まれていても問題ありません。
- 常染色体 STR の Allele は全て数字である必要があります。Off-ladder (OL) や Outside Marker Range (OMR) のアレルについては、適切なアレルの数字を割り当ててください。
- ホモ接合体のマーカーについては、同じ数字を 2 つ入力してください。

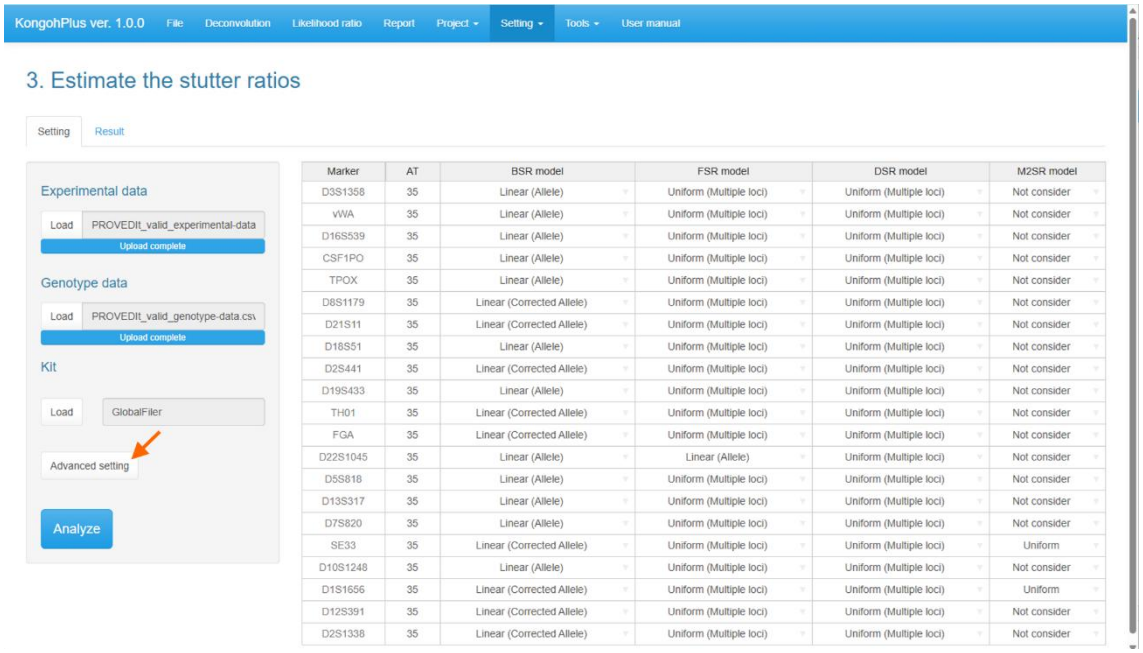
4. 下図の **“Load”** をクリックし、検査キットの情報を選択します。



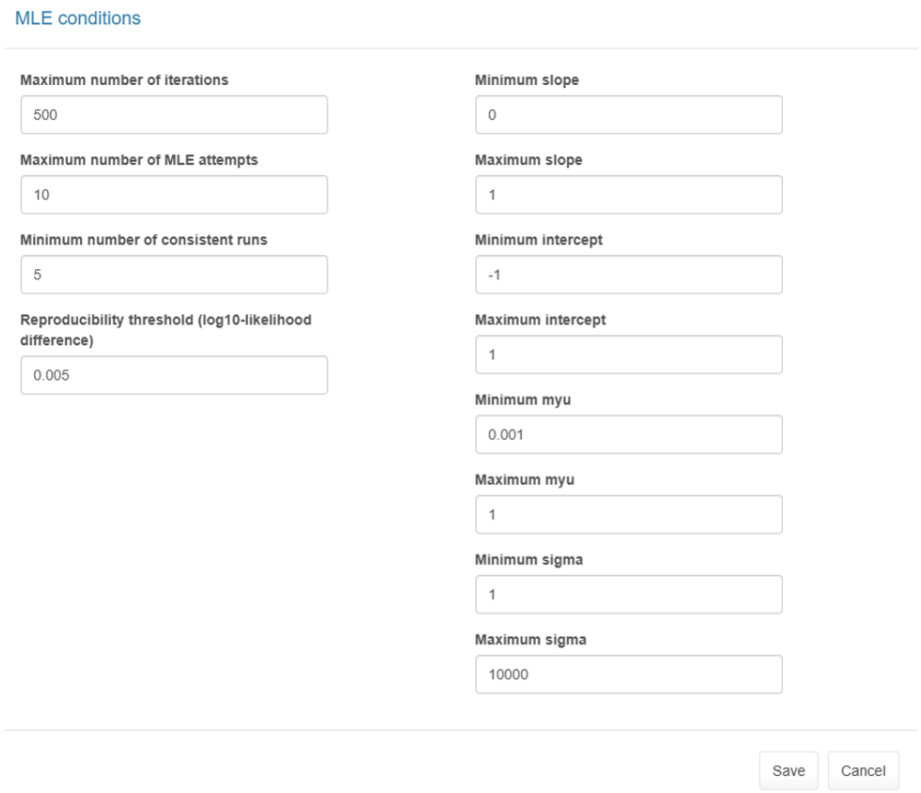
5. 各マーカーの analytical threshold（AT）と各種 stutter ratio の統計学的モデルを設定してください。各種 stutter ratio の統計学的モデルについては、第 10.7.1 項を参照してください。



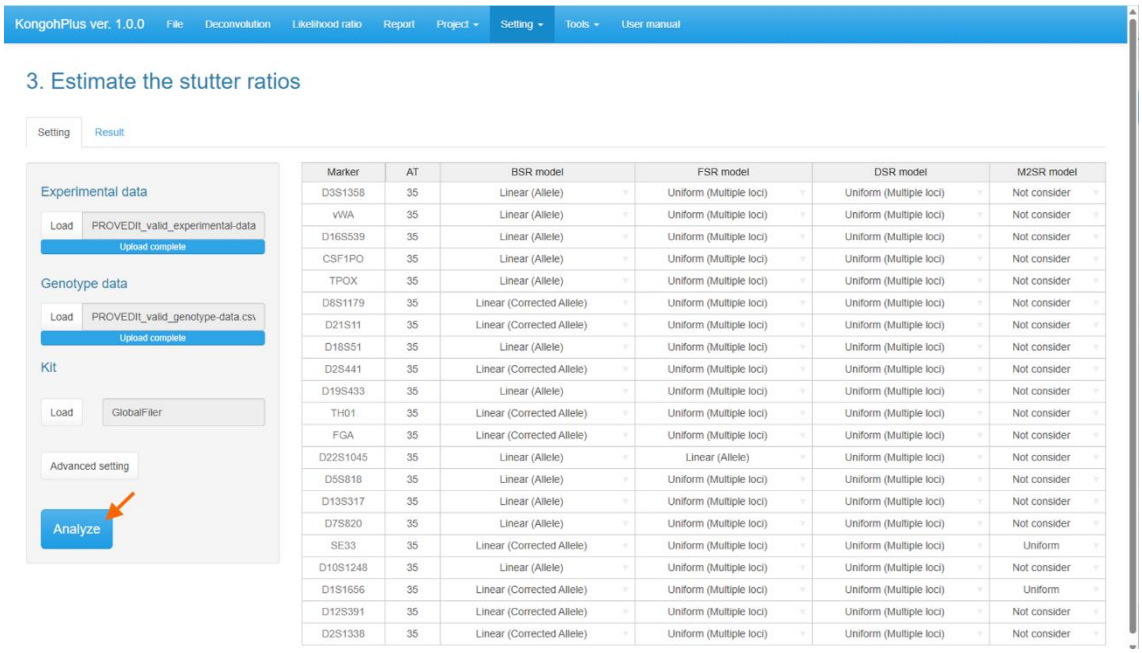
6. 必要に応じて、高度な設定を行います。**”Advanced setting”** をクリックします。



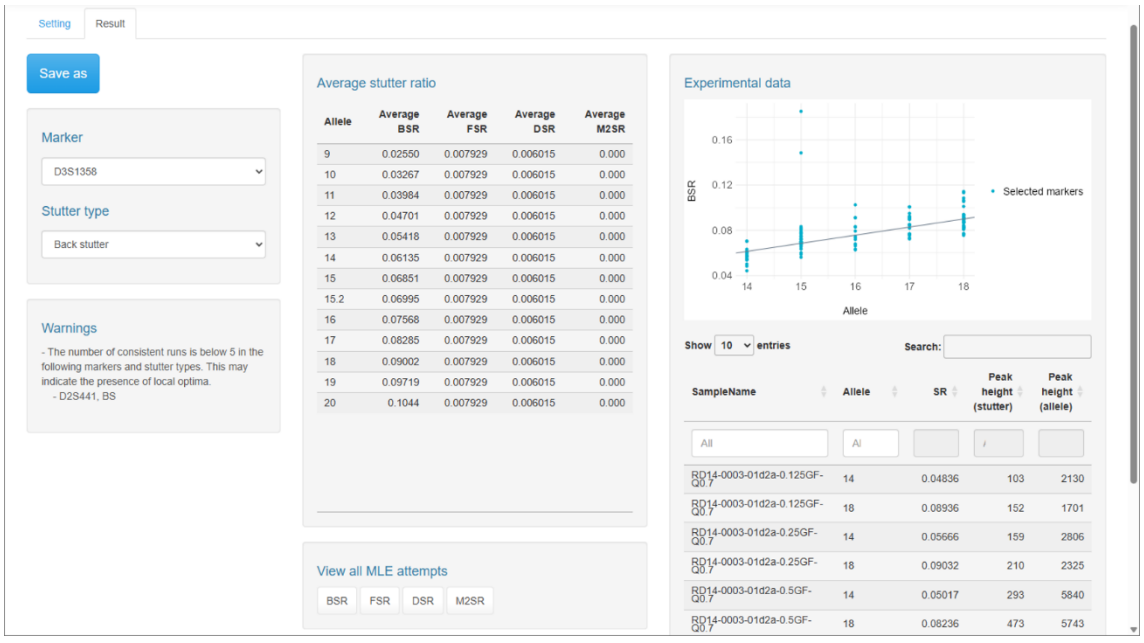
7. ここでは、stutter ratio の推定過程で実行される最尤推定の条件を設定します。各項目の値を確認し、**"Save"** をクリックします。最尤推定のアプローチは、Deconvolution と同様であり、詳細は第 10.4 項に示しています。また、推定パラメータについては、第 10.7.1 項に示しています。



8. **“Analyze”** をクリックします。



9. 解析終了後、結果を確認します。



Note:

- 画面左上から、結果を表示させるマーカーとスタターの種類を選択できます。

- 尤度の値の安定性が不十分な場合には、警告が表示されます。
- **“Average stutter ratio”** は、各種スタターに対する、アレル毎の平均的な stutter ratio の推定結果です。この値が Deconvolution 解析に使用されます。
- **“Experimental data”** には、stutter ratio とアレルの数字（もしくは補正値）との関係が図示されます。下表は実験データから得られた stutter ratio 等の値をまとめたもので、各行を選択すると、そのデータも併せて図示されます。
- **“View all MLE attempts”** にて、選択したマーカーにおける各種 stutter ratio の推定結果の安定性を確認することができます。KongohPlus では、各種 stutter ratio の推定を複数回実行し（既定では最大 10 回）、対数尤度 Log10 (likelihood) の値が所定の回数（既定では 5 回）安定した時点で解析を終了します。

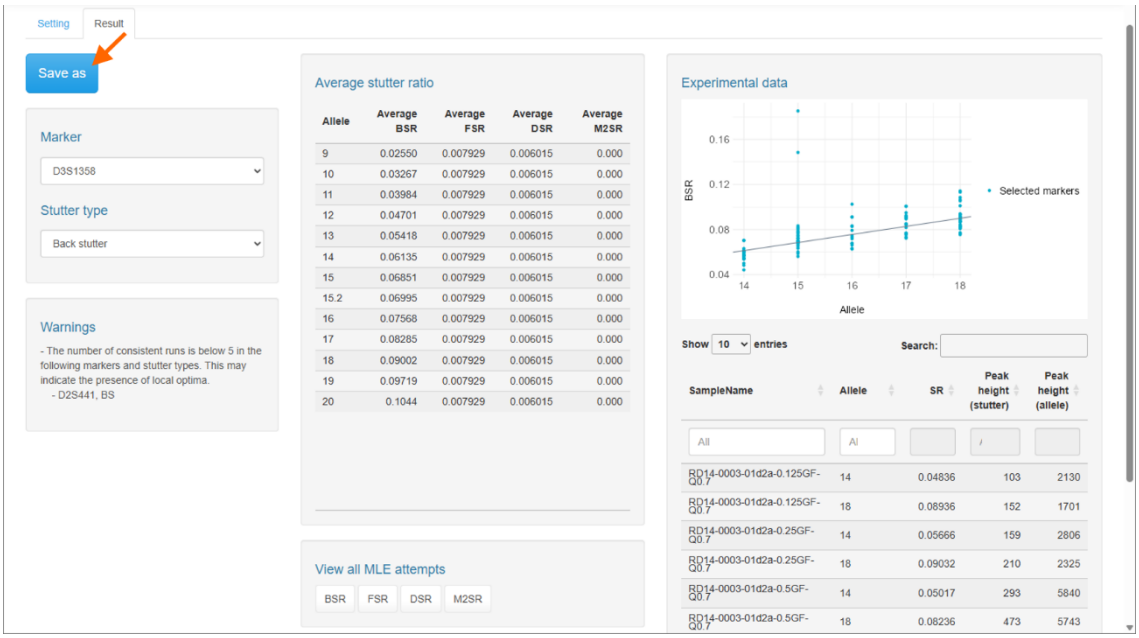
- 下図は、5 回連続で安定した結果が得られた例です。安定した結果の列は青色で示されます。対数尤度 Log10 (likelihood) の値が最も大きい結果の列は水色で示され、この結果が stutter ratio の推定結果として採用されます。

All MLE attempts (BSR)

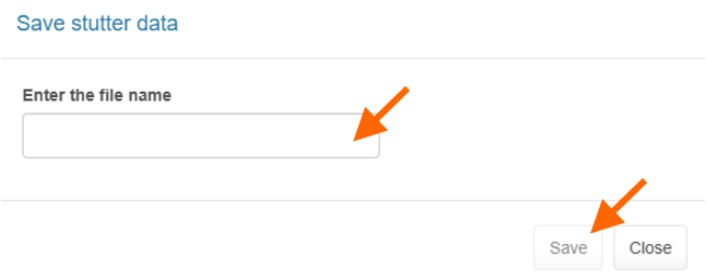
■ : Selected maximum likelihood ■ : Close to the maximum likelihood

Parameter	MLE 1	MLE 2	MLE 3	MLE 4	MLE 5
Log10 (likelihood)	186.670	186.670	186.670	186.670	186.670
Slope	0.00716880	0.00716880	0.00716880	0.00716880	0.00716880
Intercept	-0.0390171	-0.0390171	-0.0390171	-0.0390171	-0.0390171
Sigma	42.1072	42.1072	42.1072	42.1072	42.1072

10. **”Save as”** をクリックします。



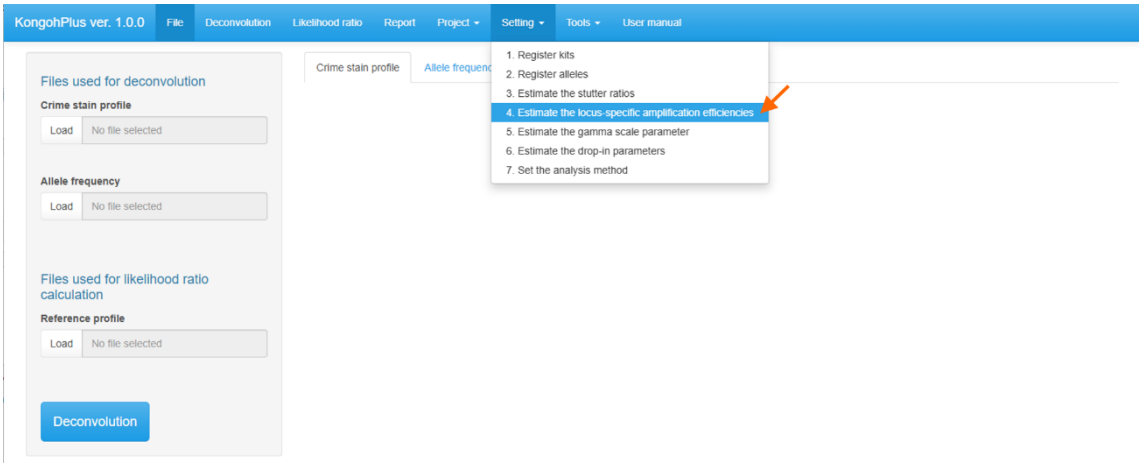
11. 任意のファイル名を入力し、**”Save”** をクリックします。



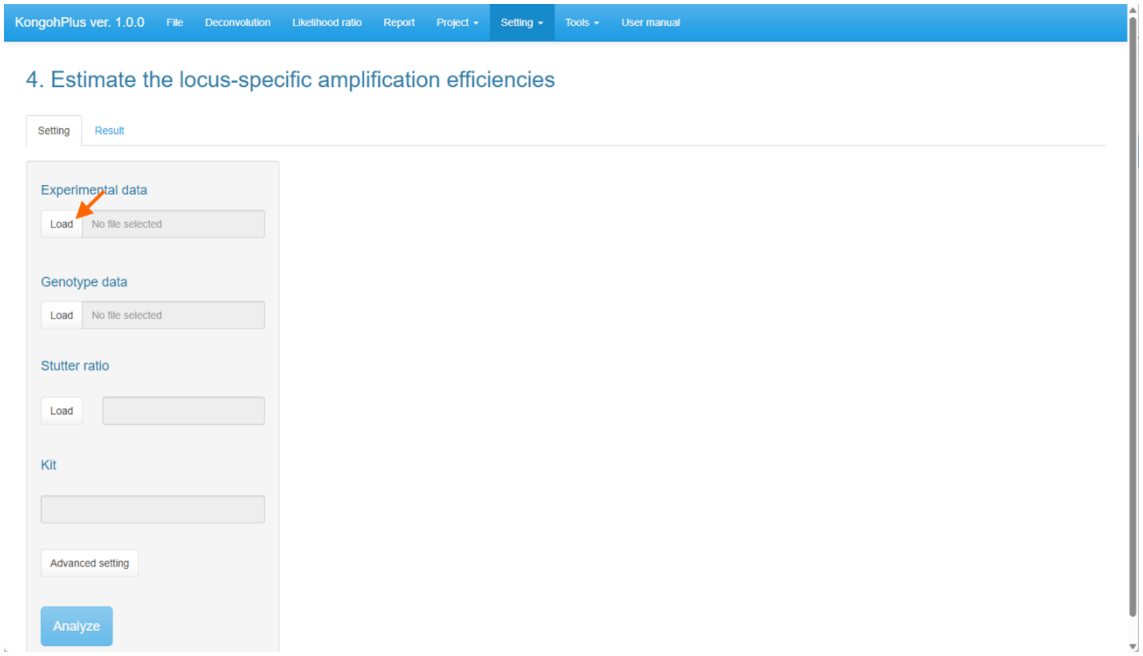
8.4. ローカス固有の PCR 増幅効率の推定

本項では、実験的に取得したプロファイルを基に、ローカス固有の PCR 増幅効率を推定するための手順について説明します。

1. **“Setting” ▶ “4. Estimate the locus specific amplification efficiencies”** をクリックします。



2. 実験データセットを下図の **“Load”** ボタンから入力します。



実験データセットの条件

- 各プロファイルは、単一個人由来であること
- DNA の分解がないこと

実験データセットのファイル形式

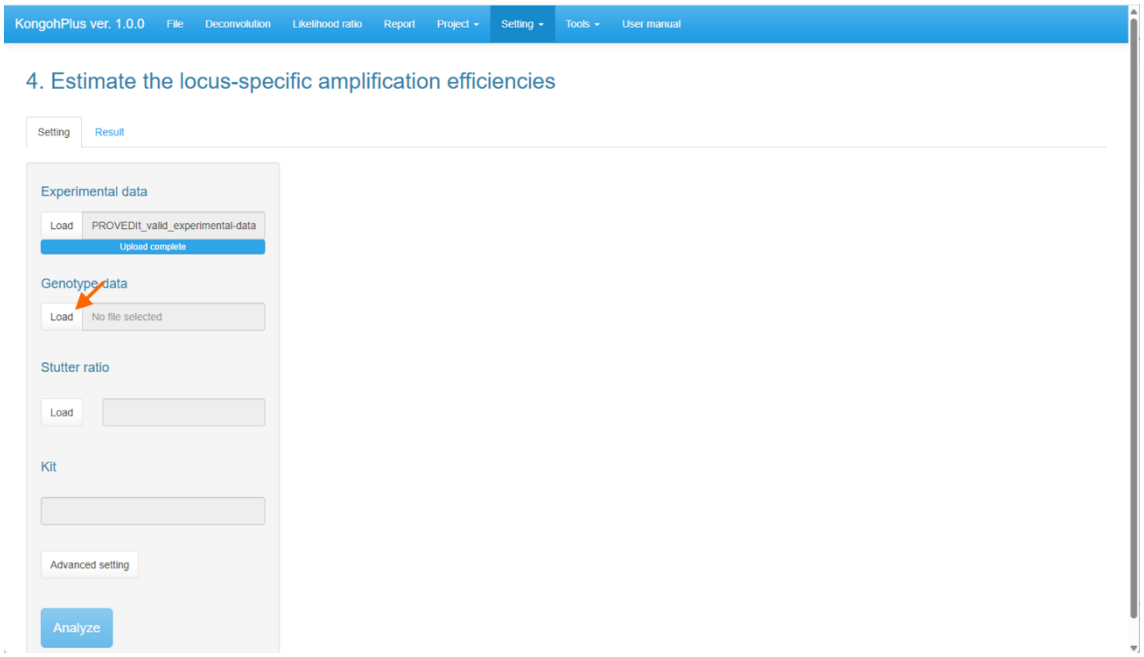
実験データセットは、以下の表に示すようなデータを **.csv 形式** でご準備ください。

SampleName	Marker	Allele1	Allele2	Allele3	Allele4	…	Height1	Height2	Height3	Height4	…
example1	D3S1358	13	14	17	18	…	103	2130	152	1701	…
example1	vWA	16	17	18	19	…	93	1394	104	1328	…
example1	D16S539	11	12	13		…	84	1610	1367		…
…	…	…	…	…	…	…	…	…	…	…	…

Note:

- 解析に使用されるデータは常染色体 STR のみですが、性染色体マーカーのデータが含まれていても問題ありません。
- 常染色体 STR の Allele と Height は全て数字である必要があります。Off-ladder (OL) や Outside Marker Range (OMR) のアレルについては、適切なアレルの数字を割り当てるか、プルアップやノイズと考えられる場合は削除してください。
- それぞれのプロファイルに異なる SampleName を設定し、同一の .csv ファイルに縦方向に連結してください。

3. 実験プロファイルの DNA 型データセットを下図の **“Load”** ボタンから入力します。



DNA 型データセットのファイル形式

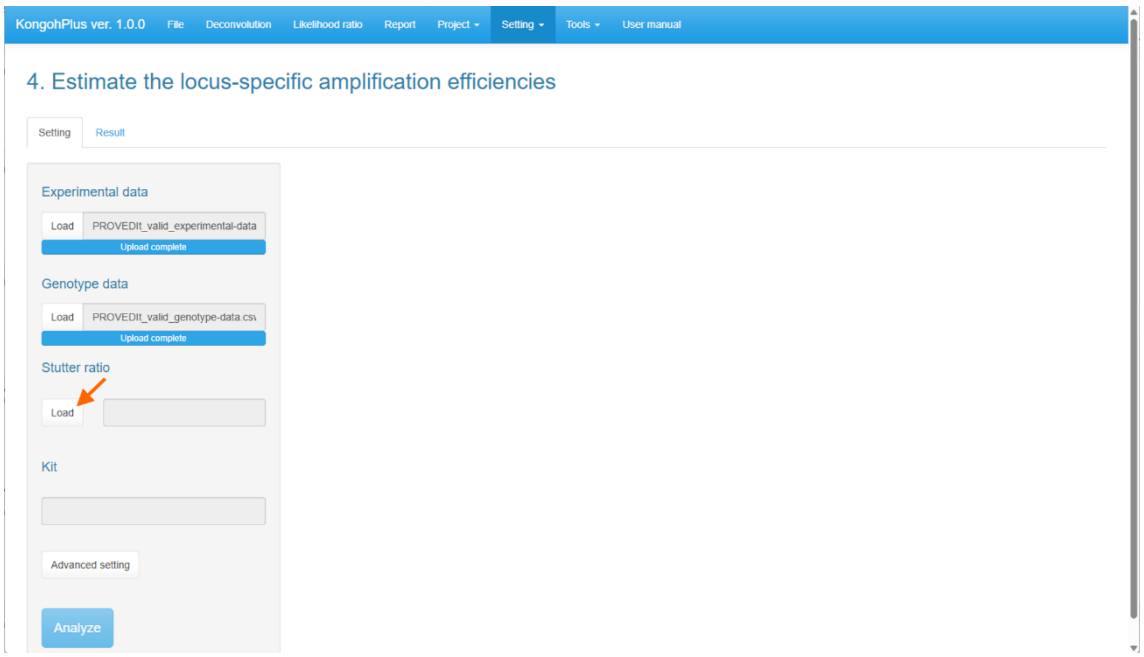
DNA 型データセットは、以下の表に示すようなデータを **.csv 形式** でご準備ください。

SampleName	Marker	Allele1	Allele2
example1	D3S1358	15	16
example1	vWA	15	18
example1	D16S539	10	10
…	…	…	…

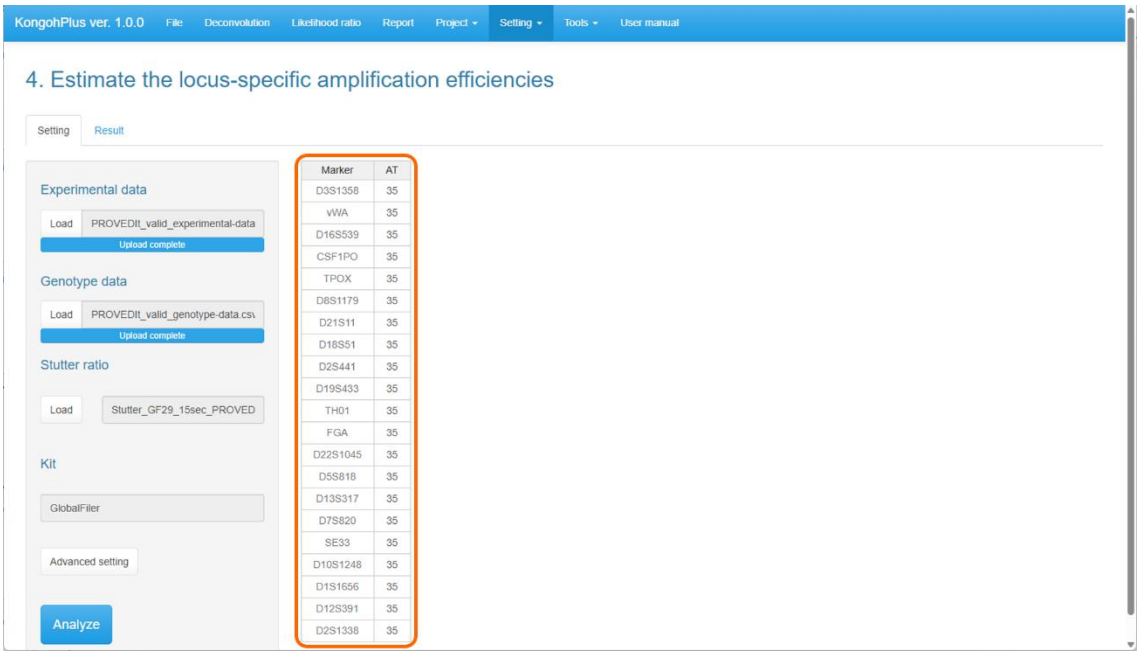
Note:

- SampleName は、実験データセットと対応させてください。
- 各プロファイルの DNA 型データは、同一の .csv ファイルに縦方向に連結してください。
- 解析に使用されるデータは常染色体 STR のみですが、性染色体マーカーのデータが含まれていても問題ありません。
- 常染色体 STR の Allele は全て数字である必要があります。Off-ladder (OL) や Outside Marker Range (OMR) のアレルについては、適切なアレルの数字を割り当ててください。
- ホモ接合体のマーカーについては、同じ数字を 2 つ入力してください。

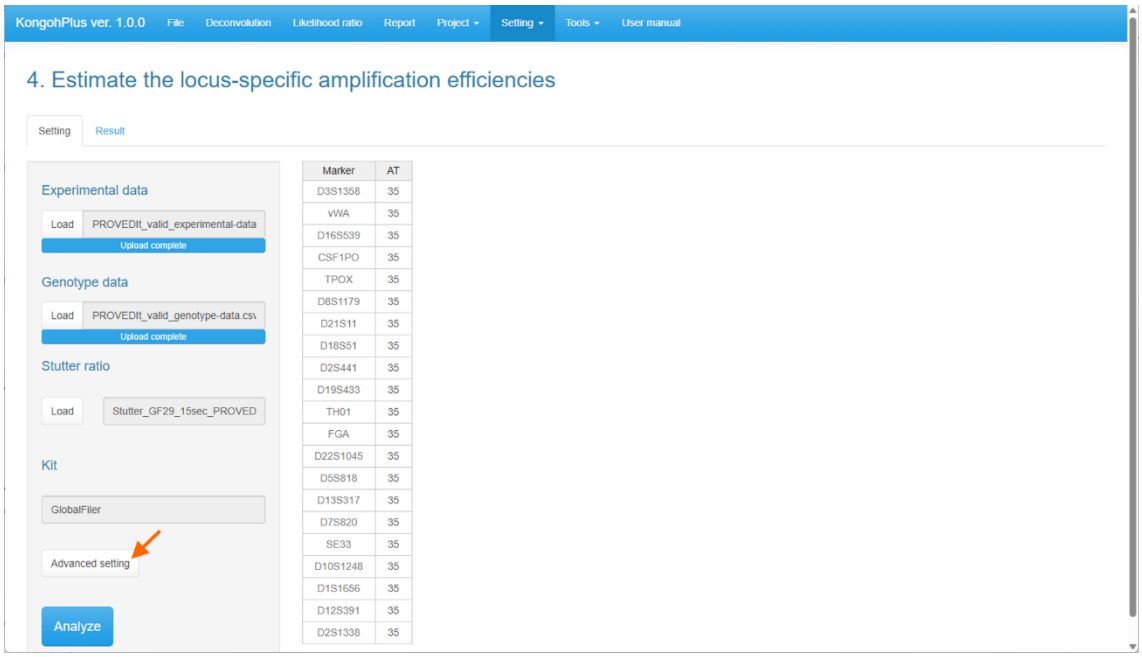
4. 下図の **“Load”** をクリックし、第 8.3 項の手順で推定した stutter ratio のデータを選択します。



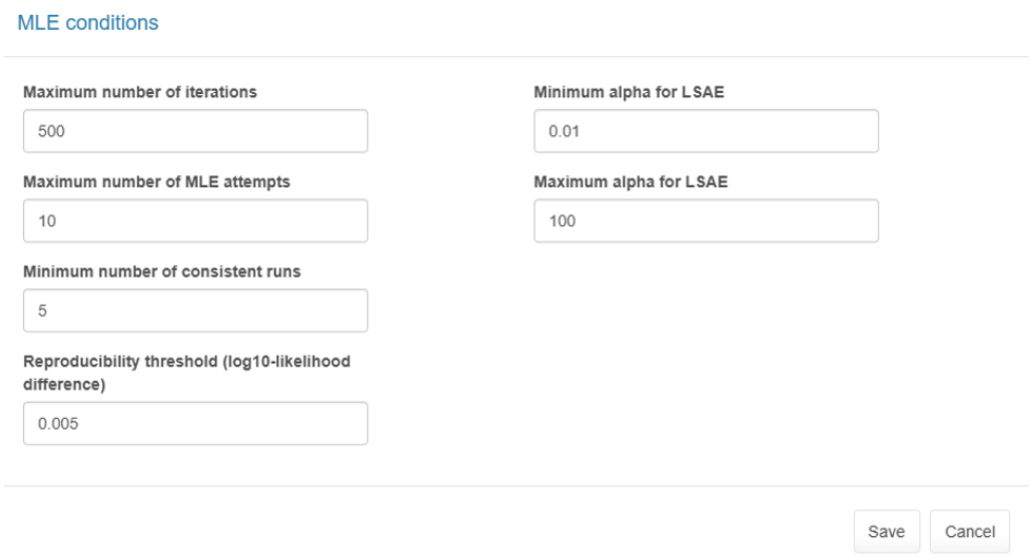
5. 各マーカーの analytical threshold（AT）を設定してください。



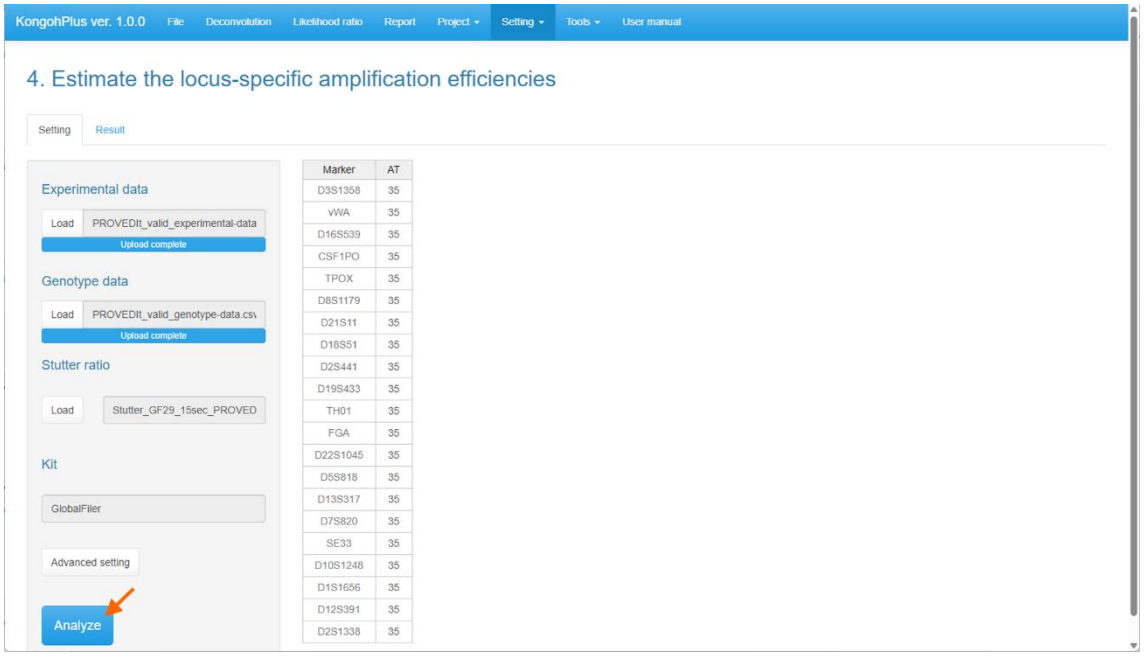
6. 必要に応じて、高度な設定を行います。**”Advanced setting”** をクリックします。



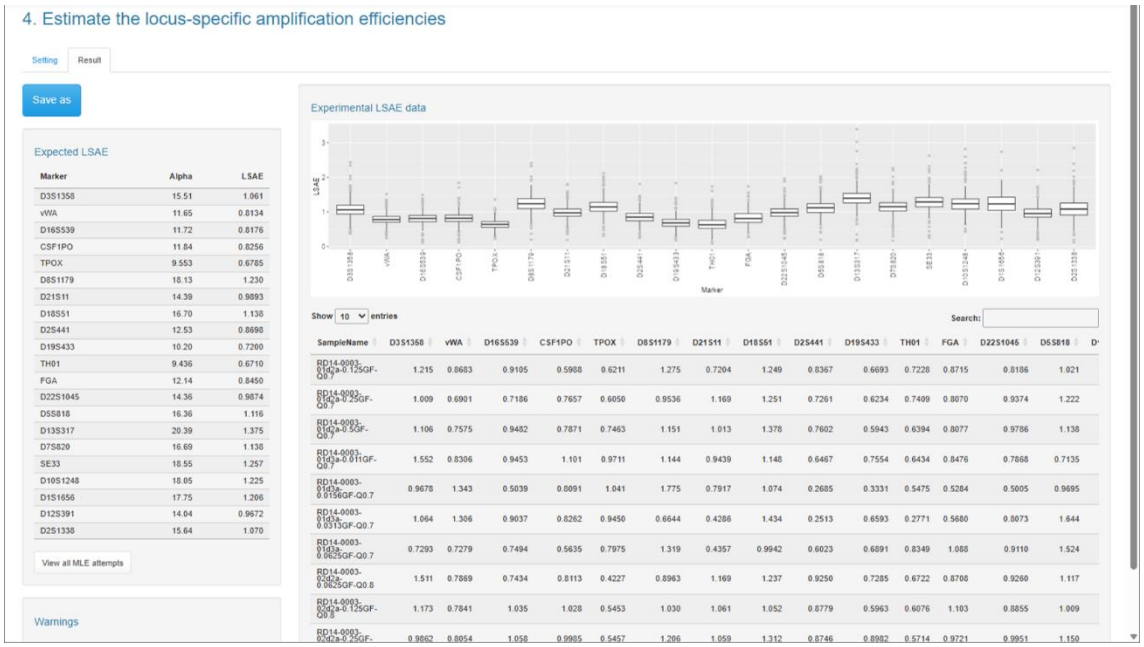
7. ここでは、ローカス固有の PCR 増幅効率の推定過程で実行される最尤推定の条件を設定します。各項目の値を確認し、**"Save"** をクリックします。最尤推定のアプローチは、Deconvolution と同様であり、詳細は第 10.4 項に示しています。また、推定パラメータについては、第 10.7.2 項に示しています。



8. **"Analyze"** をクリックします。



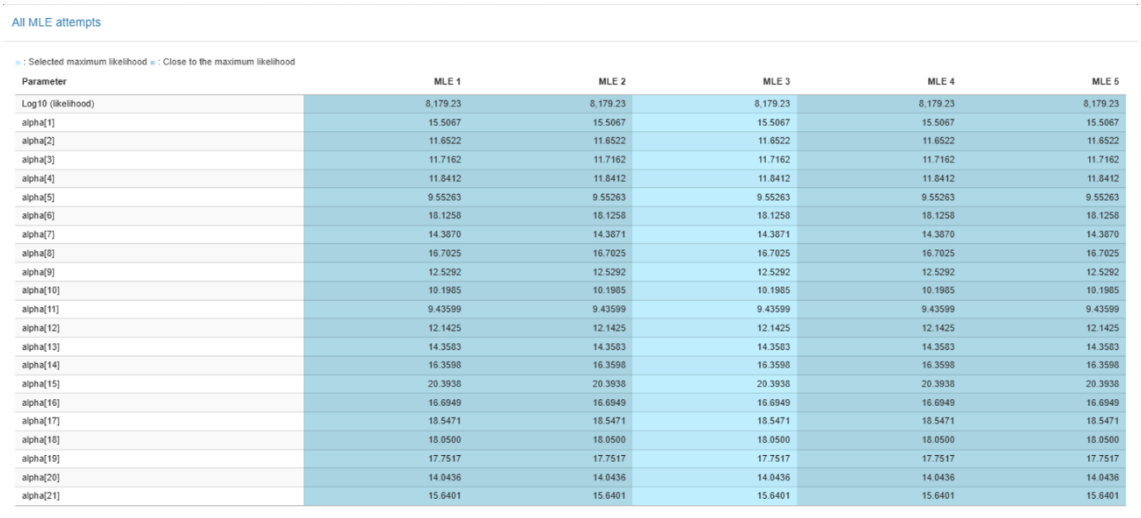
9. 解析終了後、結果を確認します。



Note:

- 尤度の値の安定性が不十分な場合には、警告が表示されます。
- **“Expected LSAE”** には、**Alpha** と **LSAE**（locus-specific amplification efficiency の略）の値がローカス毎に示されます。**LSAE** の値が Deconvolution 解析に使用されます。**Alpha** は、ローカス固有の PCR 増幅効率を正規化した値がディリクレ分布に従うという前提の下で推定されたパラメータです（詳細は、第 10.7.2 項を参照）。
- **“Experimental data”** には、実験データから得られた増幅効率がローカス毎に図示されます。下表は個々の実験データの値をまとめたもので、各行を選択すると、そのデータも併せて図示されます。
- **“View all MLE attempts”** にて、推定結果の安定性を確認することができます。KongohPlus では、全ローカスの PCR 増幅効率の推定を複数回実行し（既定では最大 10 回）、対数尤度 Log10 (likelihood) の値が所定の回数（既定では 5 回）安定した時点で解析を終了します。

- 下図は、5 回連続で安定した結果が得られた例です。安定した結果の列は青色で示されます。対数尤度 Log10 (likelihood) の値が最も大きい結果の列は水色で示され、この結果がローカス固有の PCR 増幅効率の推定結果として採用されます。

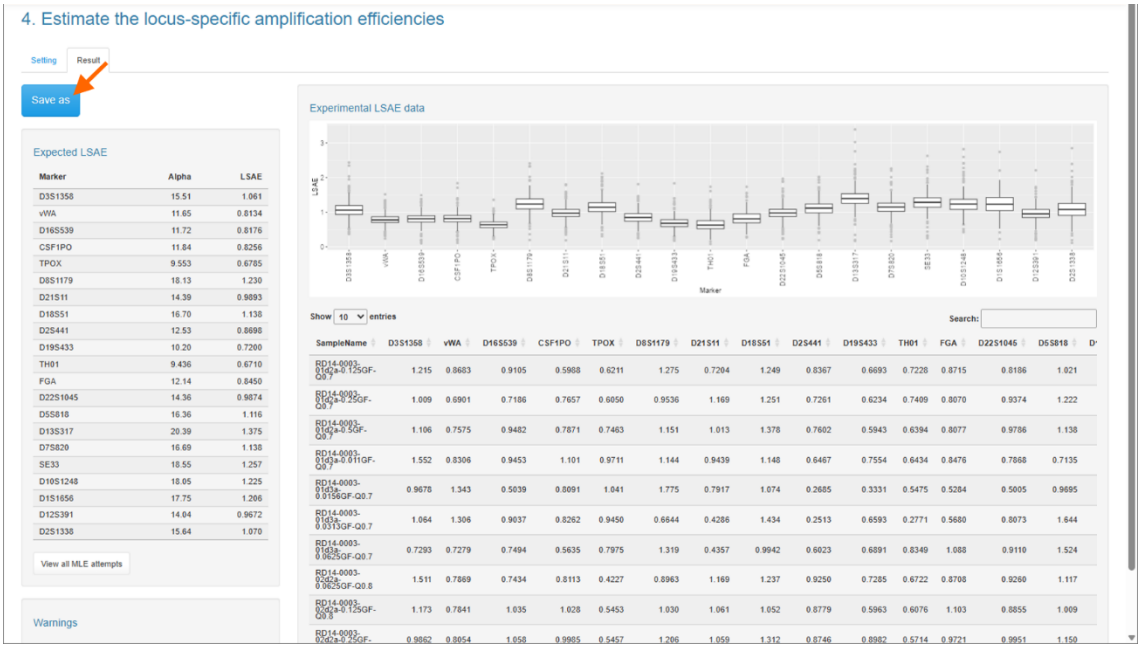


All MLE attempts

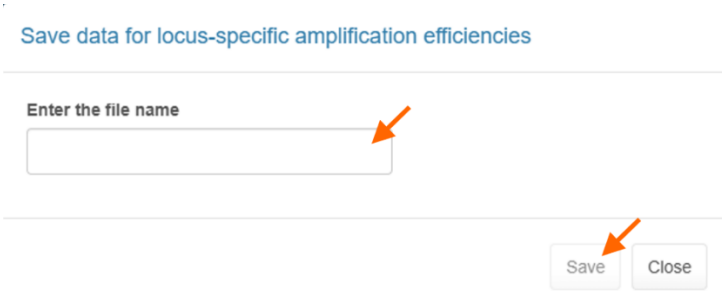
■ : Selected maximum likelihood ■ : Close to the maximum likelihood

Parameter	MLE 1	MLE 2	MLE 3	MLE 4	MLE 5
Log10 (likelihood)	8,179.23	8,179.23	8,179.23	8,179.23	8,179.23
alpha[1]	15.5067	15.5067	15.5067	15.5067	15.5067
alpha[2]	11.6522	11.6522	11.6522	11.6522	11.6522
alpha[3]	11.7162	11.7162	11.7162	11.7162	11.7162
alpha[4]	11.8412	11.8412	11.8412	11.8412	11.8412
alpha[5]	9.55263	9.55263	9.55263	9.55263	9.55263
alpha[6]	18.1258	18.1258	18.1258	18.1258	18.1258
alpha[7]	14.3870	14.3871	14.3871	14.3870	14.3870
alpha[8]	16.7025	16.7025	16.7025	16.7025	16.7025
alpha[9]	12.5292	12.5292	12.5292	12.5292	12.5292
alpha[10]	10.1985	10.1985	10.1985	10.1985	10.1985
alpha[11]	9.43599	9.43599	9.43599	9.43599	9.43599
alpha[12]	12.1425	12.1425	12.1425	12.1425	12.1425
alpha[13]	14.3583	14.3583	14.3583	14.3583	14.3583
alpha[14]	16.3598	16.3598	16.3598	16.3598	16.3598
alpha[15]	20.3938	20.3938	20.3938	20.3938	20.3938
alpha[16]	16.6949	16.6949	16.6949	16.6949	16.6949
alpha[17]	18.5471	18.5471	18.5471	18.5471	18.5471
alpha[18]	18.0500	18.0500	18.0500	18.0500	18.0500
alpha[19]	17.7517	17.7517	17.7517	17.7517	17.7517
alpha[20]	14.0436	14.0436	14.0436	14.0436	14.0436
alpha[21]	15.6401	15.6401	15.6401	15.6401	15.6401

10. **”Save as”** をクリックします。



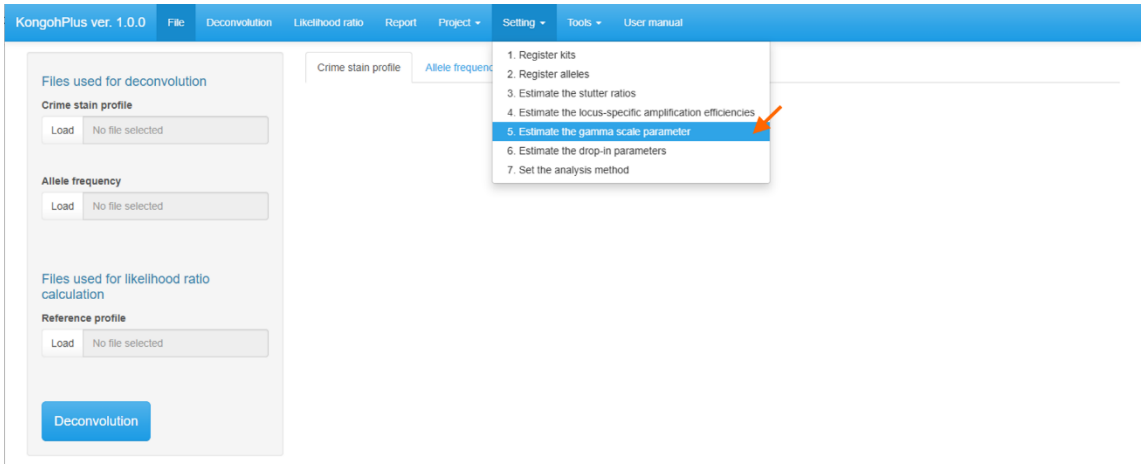
11. 任意のファイル名を入力し、**”Save”** をクリックします。



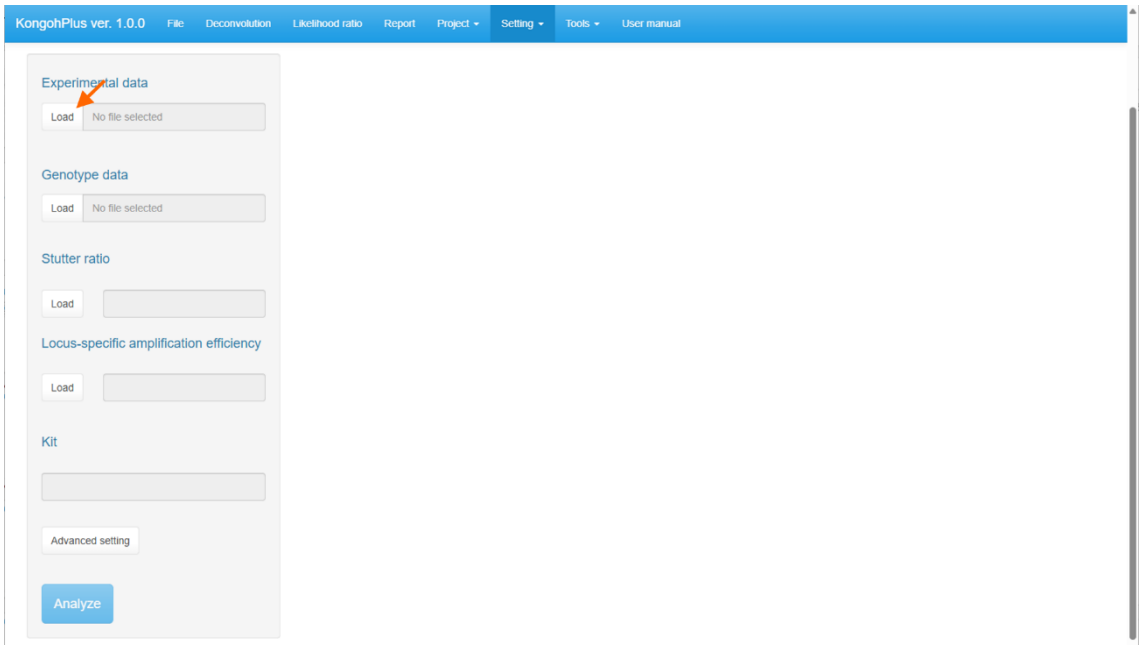
8.5. ガンマ分布の scale parameter の推定

本項では、実験的に取得したプロファイルを基に、ガンマ分布の scale parameter を推定するための手順について説明します。

1. **“Setting” ▶ “5. Estimate the gamma scale parameter”** をクリックします。



2. 実験データセットを下図の **“Load”** ボタンから入力します。



実験データセットの条件

- 各プロファイルは、単一個人由来であること
- DNA の分解がないこと
- 様々な PCR テンプレート量のプロファイルが含まれていること

実験データセットのファイル形式

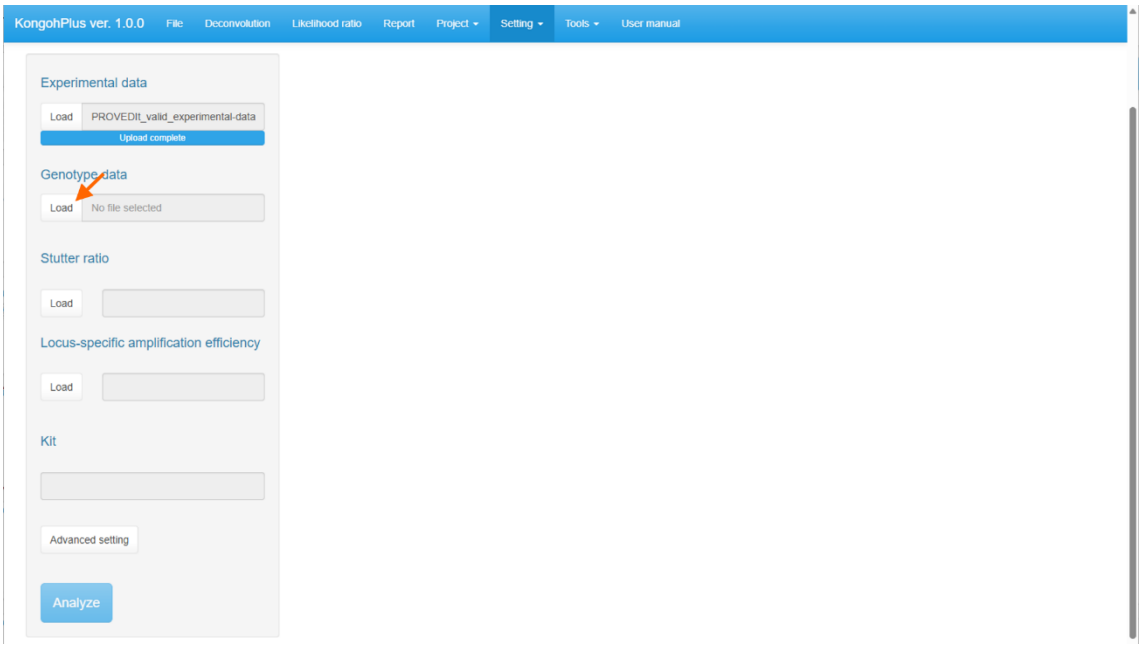
実験データセットは、以下の表に示すようなデータを **.csv 形式** でご準備ください。

SampleName	Marker	Allele1	Allele2	Allele3	Allele4	…	Height1	Height2	Height3	Height4	…
example1	D3S1358	13	14	17	18	…	103	2130	152	1701	…
example1	vWA	16	17	18	19	…	93	1394	104	1328	…
example1	D16S539	11	12	13		…	84	1610	1367		…
…	…	…	…	…	…	…	…	…	…	…	…

Note:

- 解析に使用されるデータは常染色体 STR のみですが、性染色体マーカーのデータが含まれていても問題ありません。
- 常染色体 STR の Allele と Height は全て数字である必要があります。Off-ladder (OL) や Outside Marker Range (OMR) のアレルについては、適切なアレルの数字を割り当てるか、プルアップやノイズと考えられる場合は削除してください。
- それぞれのプロファイルに異なる SampleName を設定し、同一の .csv ファイルに縦方向に連結してください。

3. 実験プロファイルの DNA 型データセットを下図の **“Load”** ボタンから入力します。



DNA 型データセットのファイル形式

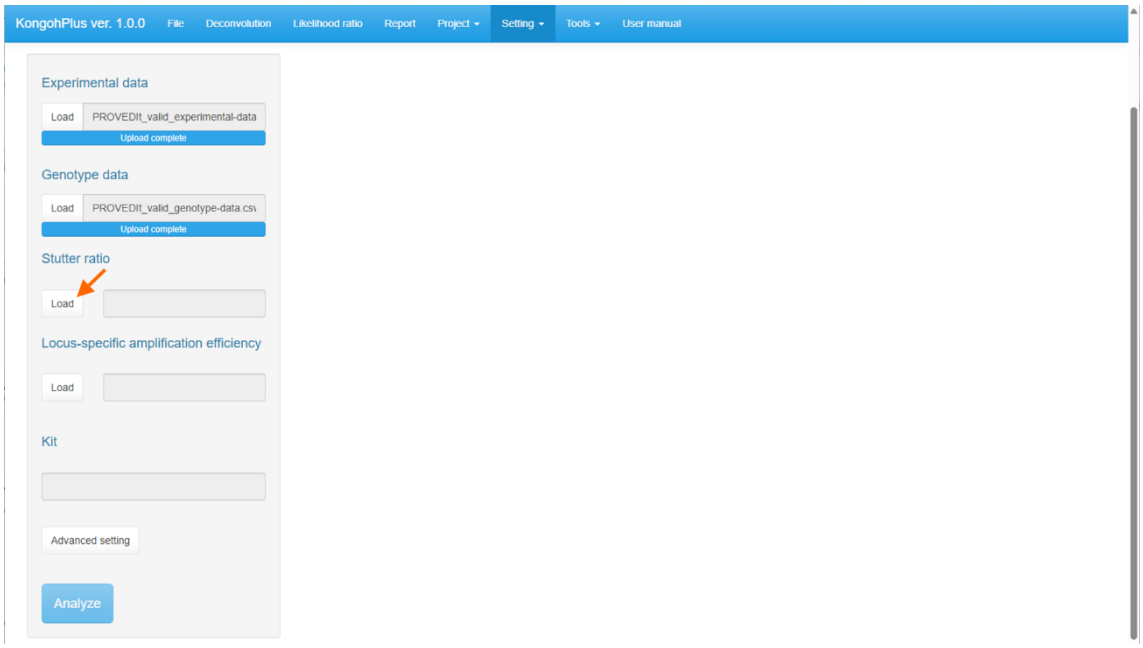
DNA 型データセットは、以下の表に示すようなデータを **.csv 形式** でご準備ください。

SampleName	Marker	Allele1	Allele2
example1	D3S1358	15	16
example1	vWA	15	18
example1	D16S539	10	10
…	…	…	…

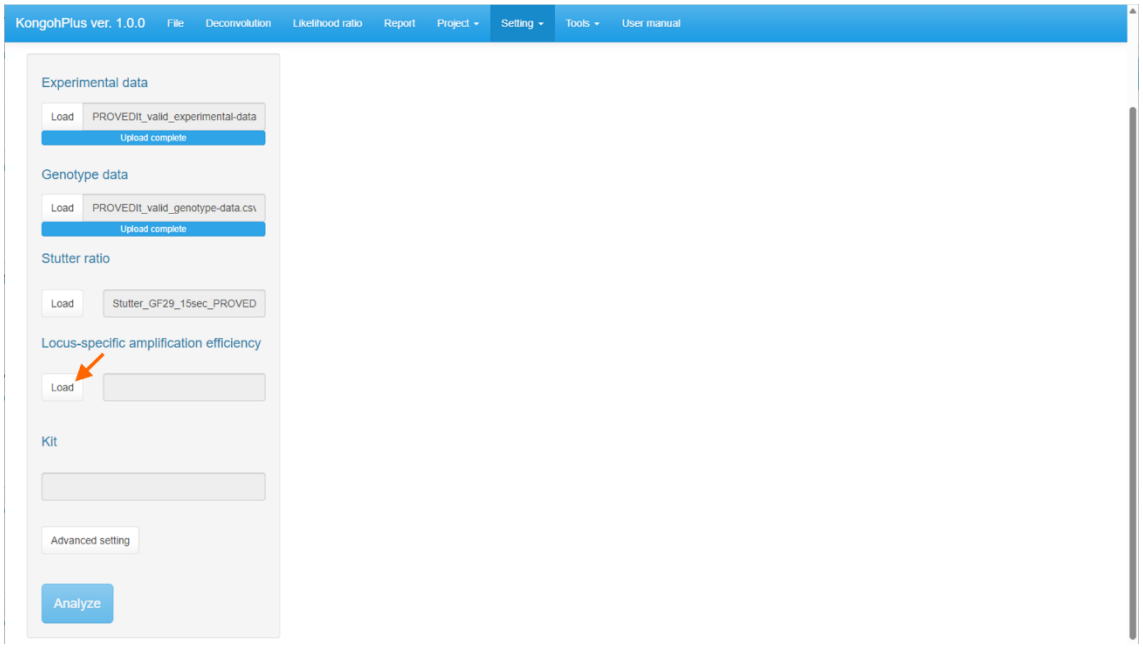
Note:

- SampleName は、実験データセットと対応させてください。
- 各プロファイルの DNA 型データは、同一の .csv ファイルに縦方向に連結してください。
- 解析に使用されるデータは常染色体 STR のみですが、性染色体マーカーのデータが含まれていても問題ありません。
- 常染色体 STR の Allele は全て数字である必要があります。Off-ladder (OL) や Outside Marker Range (OMR) のアレルについては、適切なアレルの数字を割り当ててください。
- ホモ接合体のマーカーについては、同じ数字を 2 つ入力してください。

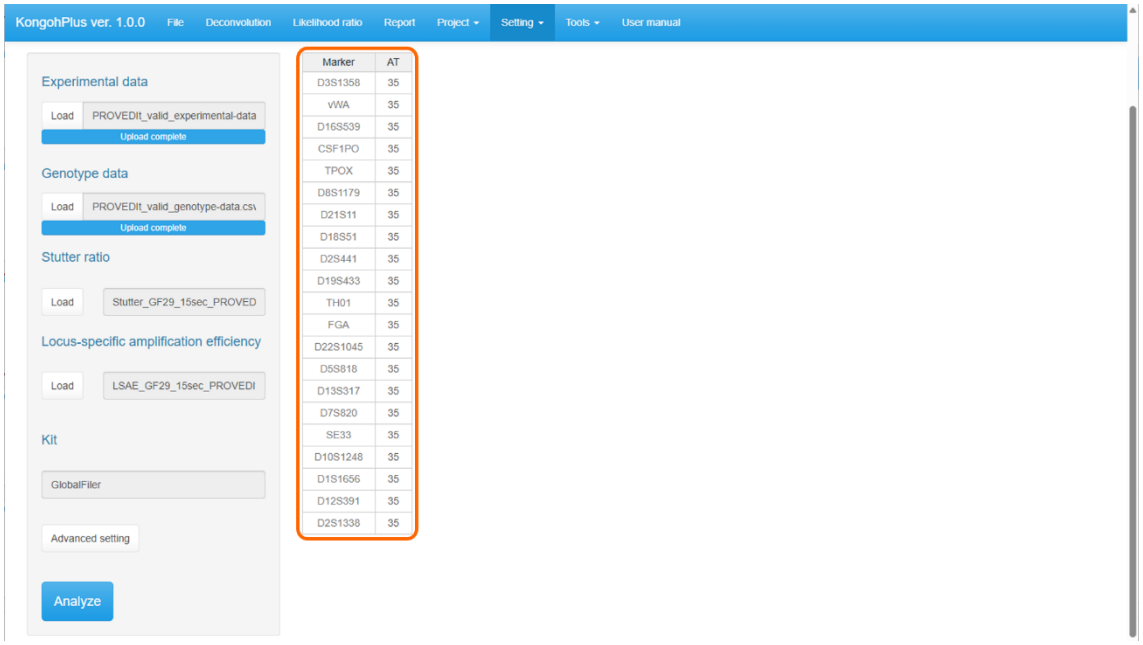
4. 下図の **“Load”** をクリックし、第 8.3 項の手順で推定した stutter ratio のデータを選択します。



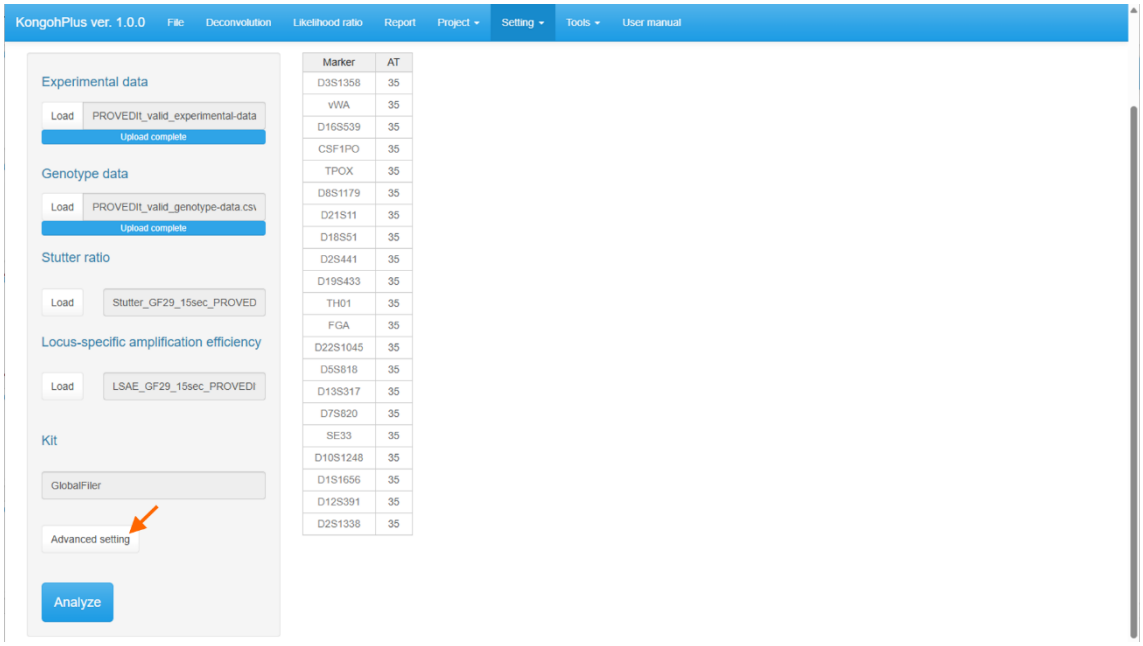
5. 下図の **“Load”** をクリックし、第 8.4 項の手順で推定したローカス固有の PCR 増幅効率のデータを選択します。



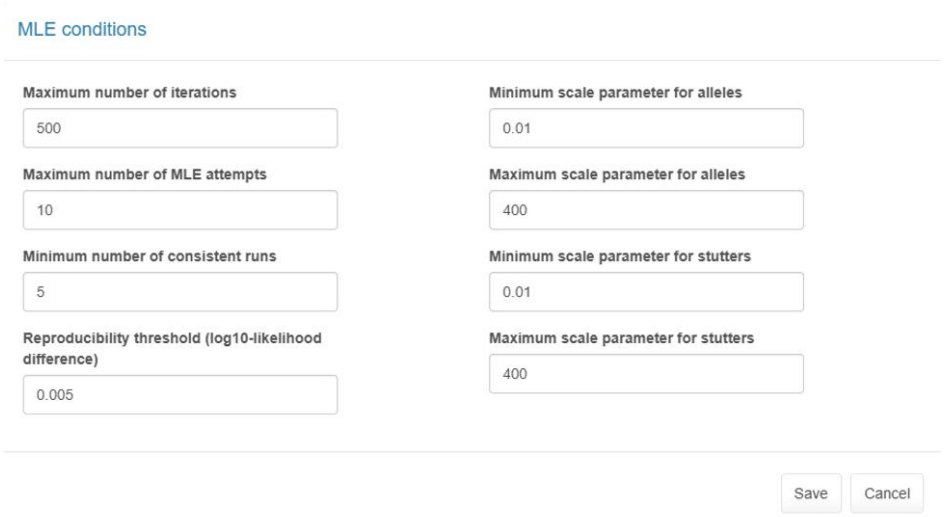
6. 各マーカーの analytical threshold（AT）を設定してください。



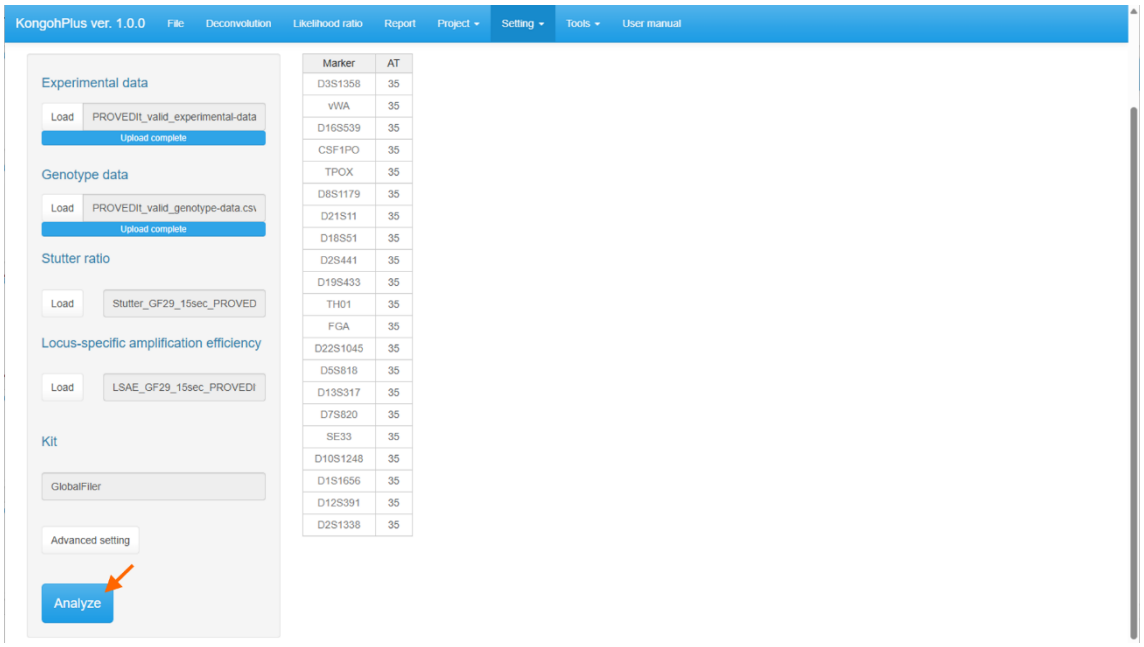
7. 必要に応じて、高度な設定を行います。**”Advanced setting”** をクリックします。



8. ここでは、ガンマ分布の scale parameter の推定過程で実行される最尤推定の条件を設定します。各項目の値を確認し、**”Save”** をクリックします。最尤推定のアプローチは、Deconvolution と同様であり、詳細は第 10.4 項に示しています。また、推定パラメータについては、第 10.7.3 項に示しています。



9. **“Analyze”** をクリックします。

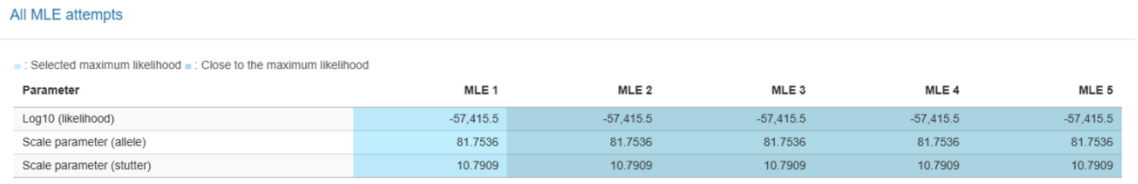


10. 解析終了後、結果を確認します。



Note:

- 尤度の値の安定性が不十分な場合には、警告が表示されます。
- **“Estimated parameters”** には、アレル成分とスタター成分それぞれのガンマ分布における scale parameter の推定値が示されています。
- **“Experimental peak height data”** には、ピーク高の観察値と期待値を比較したプロット図が描かれています。左がアレル成分のみ、中央がスタター成分のみ、右がアレル成分とスタター成分が混在しているデータです。下表は個々の実験データの値をまとめたもので、各行を選択すると、そのデータも併せて図示されます。
- **“View all MLE attempts”** にて、推定結果の安定性を確認することができます。KongohPlus では、ガンマ分布の scale parameter の推定を複数回実行し（既定では最大 10 回）、対数尤度 Log10 (likelihood) の値が所定の回数（既定では 5 回）安定した時点で解析を終了します。
- 下図は、5 回連続で安定した結果が得られた例です。安定した結果の列は青色で示されます。対数尤度 Log10 (likelihood) の値が最も大きい結果の列は水色で示され、この結果がガンマ分布の scale parameter の推定結果として採用されます。



11. **”Save as”** をクリックします。



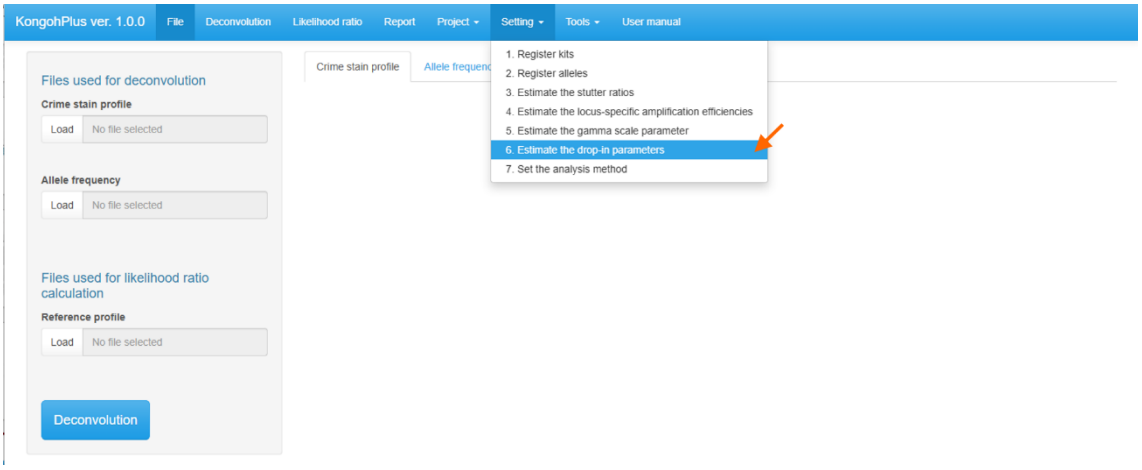
12. 任意のファイル名を入力し、**”Save”** をクリックします。



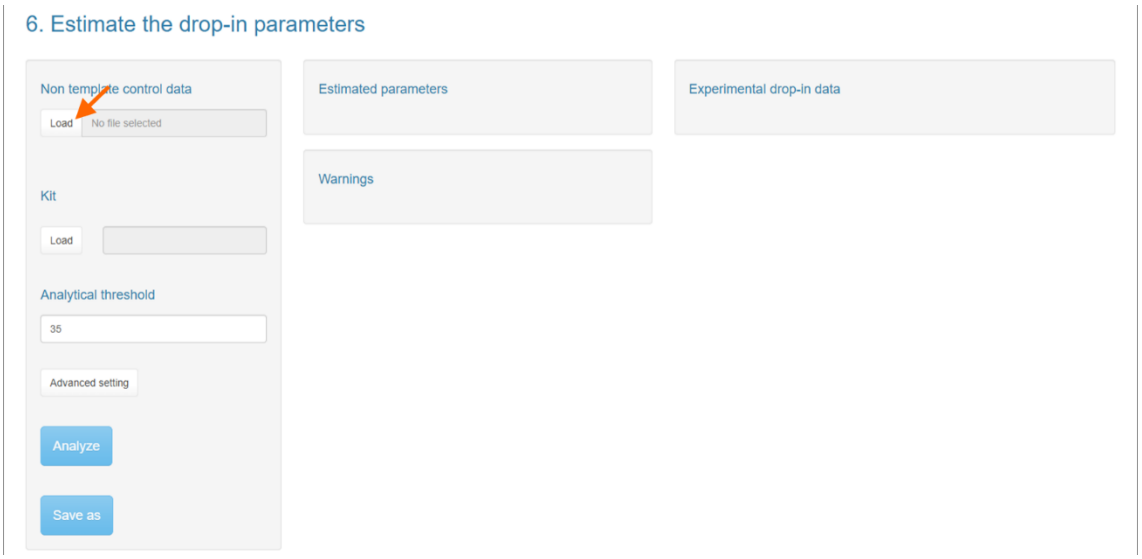
8.6. Drop-in パラメータの推定

本項では、実験的に取得した non-template control のプロファイルを基に、drop-in の統計学的モデルに関するパラメータを推定するための手順について説明します。

1. **“Setting” ▶ “6. Estimate the drop-in parameters”** をクリックします。



2. Non-template control データセットを下図の **“Load”** ボタンから入力します。



Non-template control データセットのファイル形式

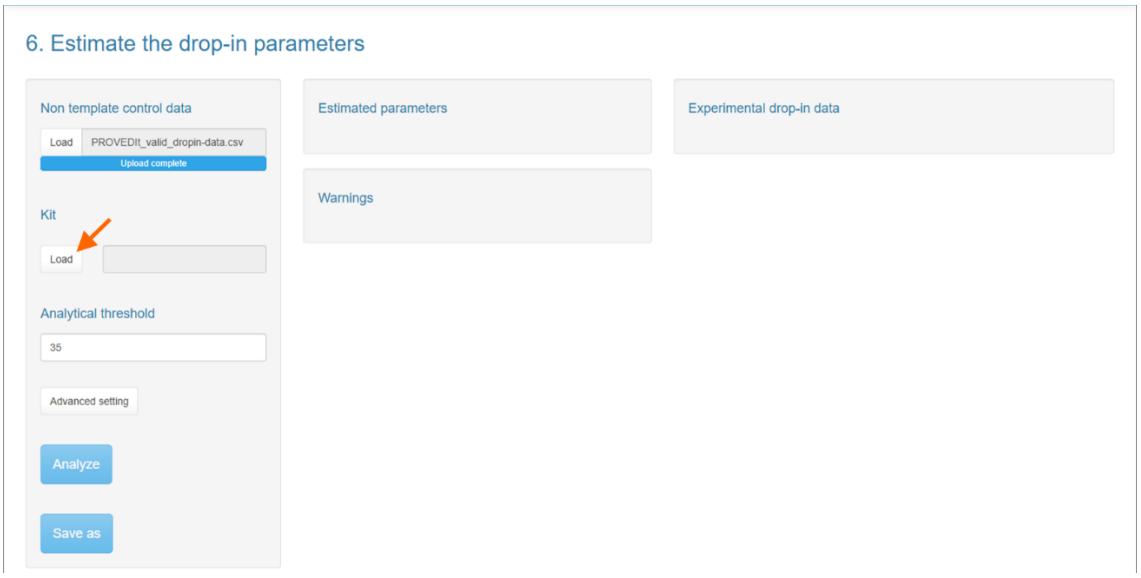
Non-template control データセットは、以下の表に示すようなデータを **.csv 形式**でご準備ください。

SampleName	Marker	Allele1	Allele2	Allele3	Allele4	…	Height1	Height2	Height3	Height4	…
example1	D3S1358					…					…
example1	vWA	16				…	63				…
example1	D16S539					…					…
…	…	…	…	…	…	…	…	…	…	…	…

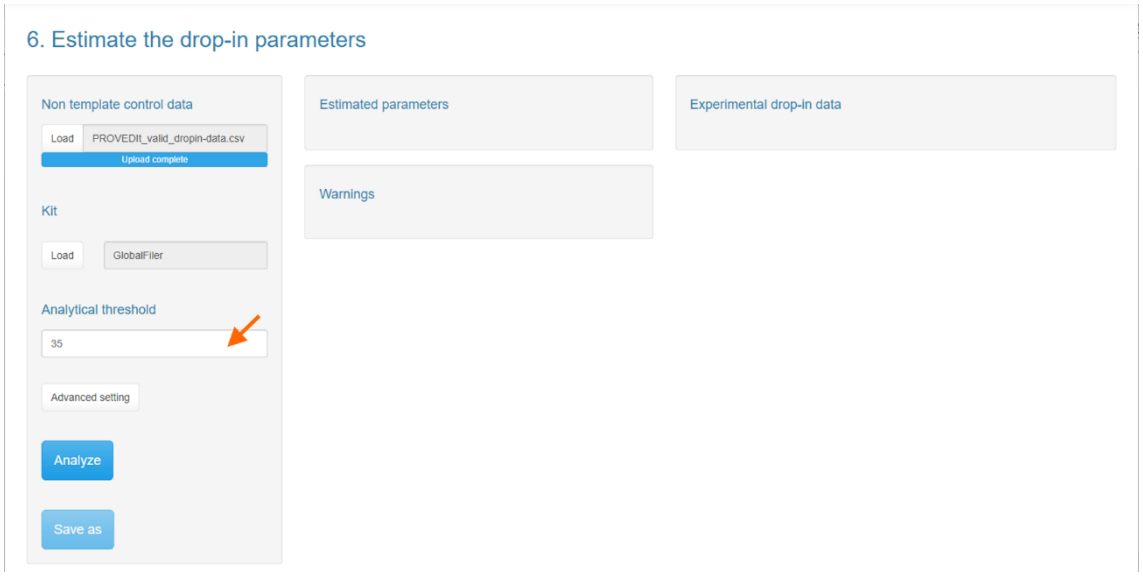
Note:

- drop-in が検出されたプロファイルだけでなく、検査した全ての non-template control のプロファイルをデータセットに含めてください。
- 解析に使用されるデータは常染色体 STR のみですが、性染色体マーカーのデータが含まれていても問題ありません。
- それぞれのプロファイルに異なる SampleName を設定し、同一の .csv ファイルに縦方向に連結してください。

3. 下図の **“Load”** をクリックし、検査キットの情報を選択します。



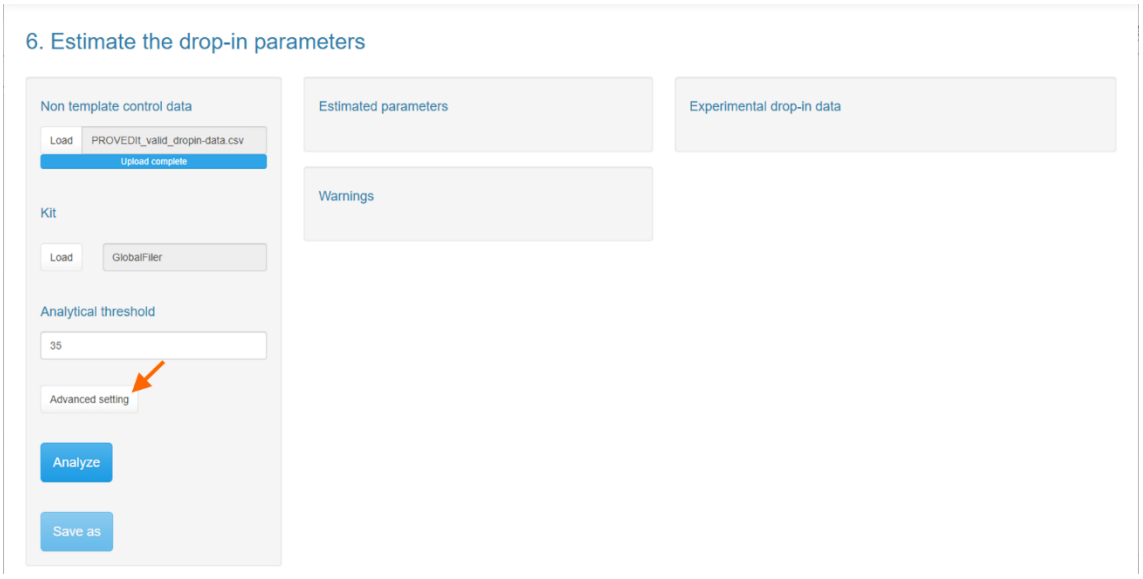
4. Analytical threshold（AT）を設定してください。



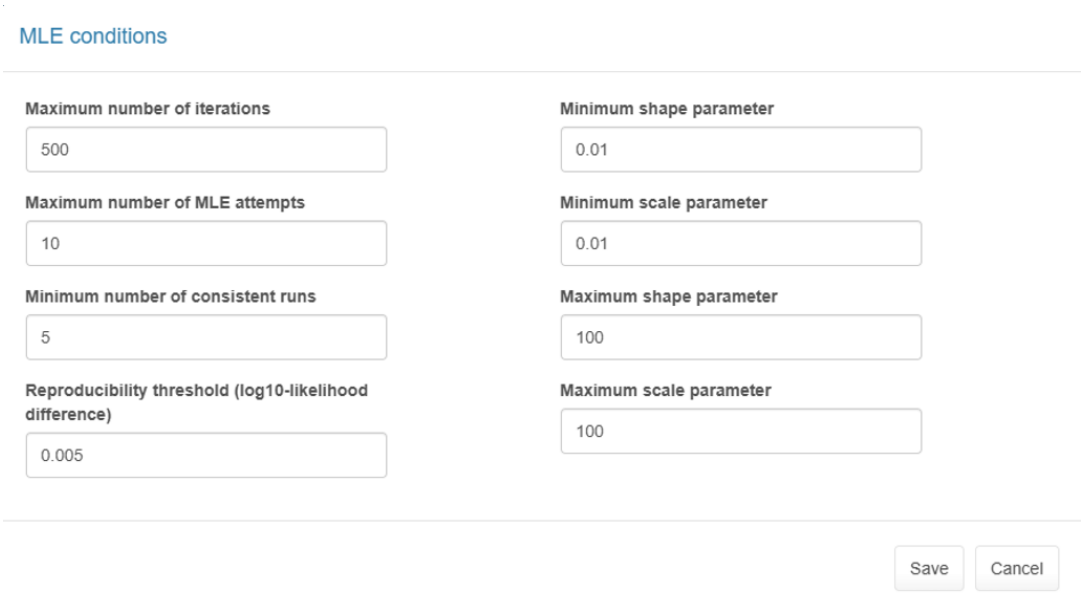
Note:

- 全マーカーで共通の AT です。
- より多くの drop-in データを得るため、可能な限り小さい値にしてください。

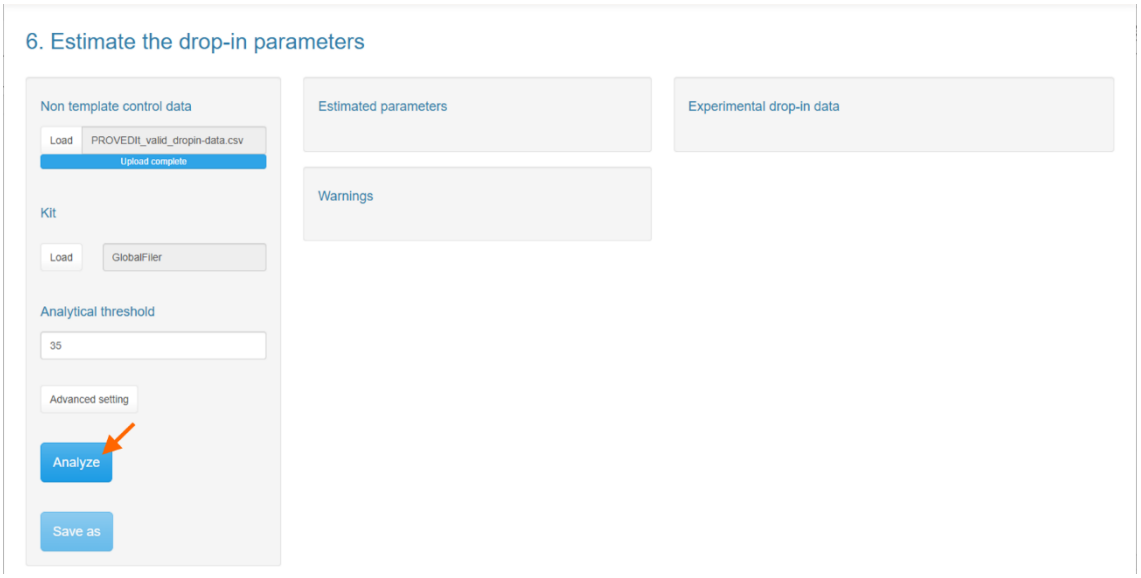
5. 必要に応じて、高度な設定を行います。**”Advanced setting”** をクリックします。



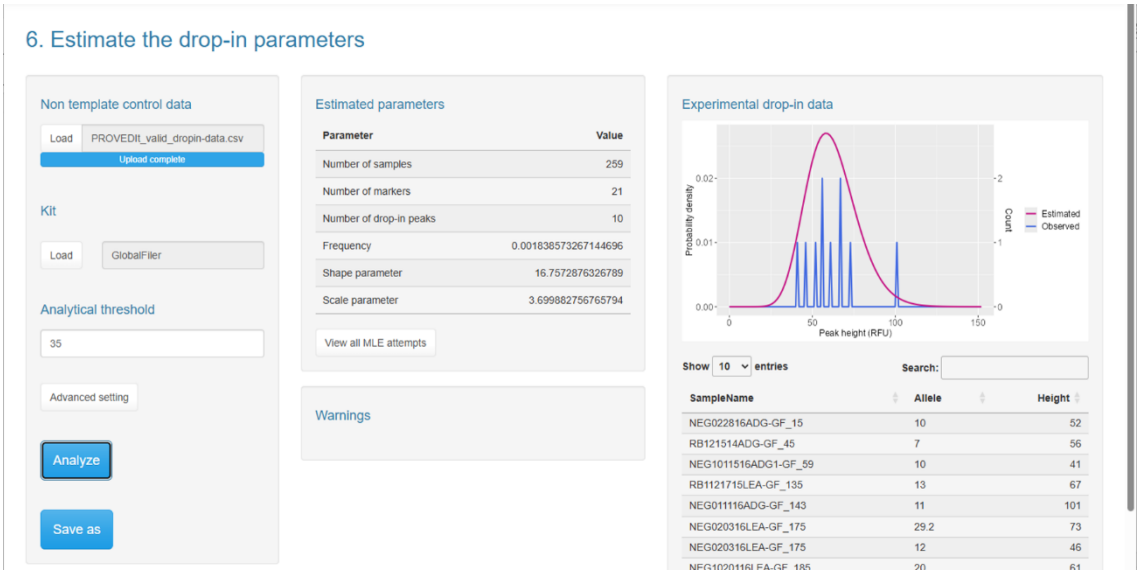
6. ここでは、drop-in に関するパラメータの推定過程で実行される最尤推定の条件を設定します。各項目の値を確認し、**”Save”** をクリックします。最尤推定のアプローチは、Deconvolution と同様であり、詳細は第 10.4 項に示しています。また、推定パラメータについては、第 10.7.4 項に示しています。



7. **“Analyze”** をクリックします。

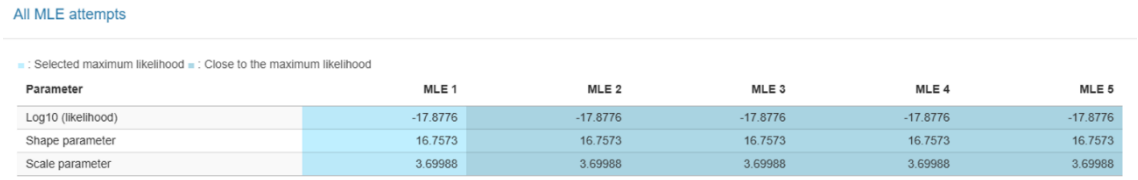


8. 解析終了後、結果を確認します。

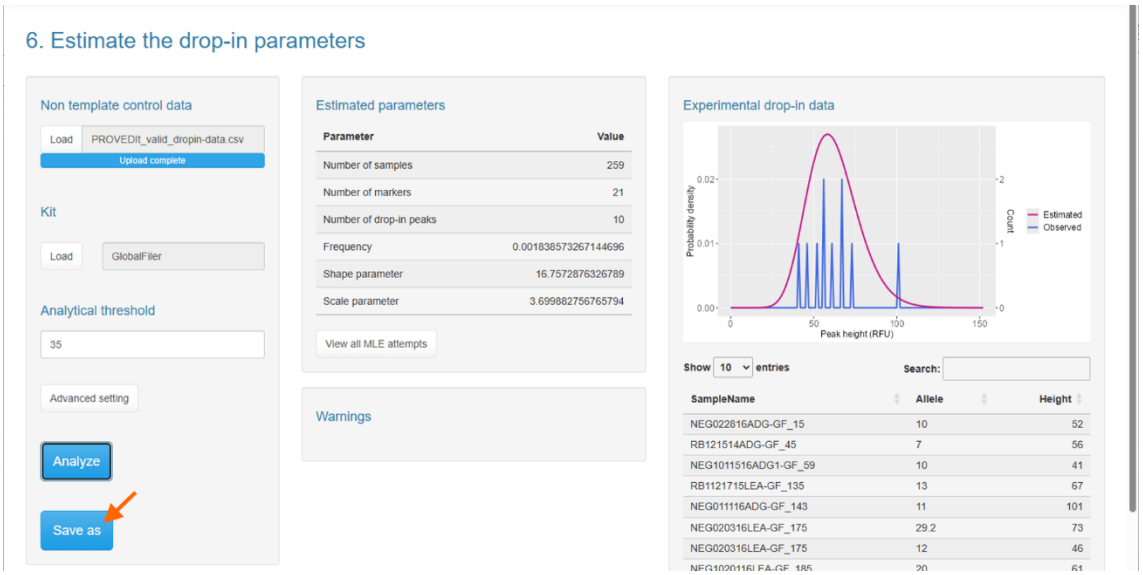


Note:

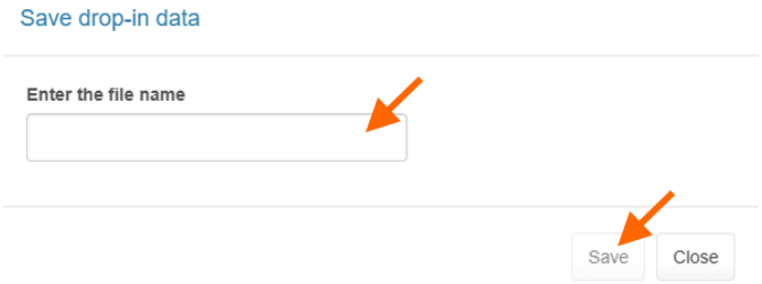
- 尤度の値の安定性が不十分な場合には、警告が表示されます。
- **“Estimated parameters”** には、drop-in の観察数や頻度、drop-in のピーク高のガンマ分布における shape parameter および scale parameter の推定値が示されています。
- **“Experimental drop-in data”** には、観察された drop-in のピーク高をガンマ分布で近似した結果が図示されます。下表は non-template control データで観察された drop-in の位置と高さをまとめたものです。
- **“View all MLE attempts”** にて、推定結果の安定性を確認することができます。KongohPlus では、drop-in のピーク高に関するガンマ分布パラメータの推定を複数回実行し（既定では最大 10 回）、対数尤度 Log10 (likelihood) の値が所定の回数（既定では 5 回）安定した時点で解析を終了します。
- 下図は、5 回連続で安定した結果が得られた例です。安定した結果の列は青色で示されます。対数尤度 Log10 (likelihood) の値が最も大きい結果の列は水色で示され、この結果がドロップインに関するパラメータの推定結果として採用されます。



9. **”Save as”** をクリックします。



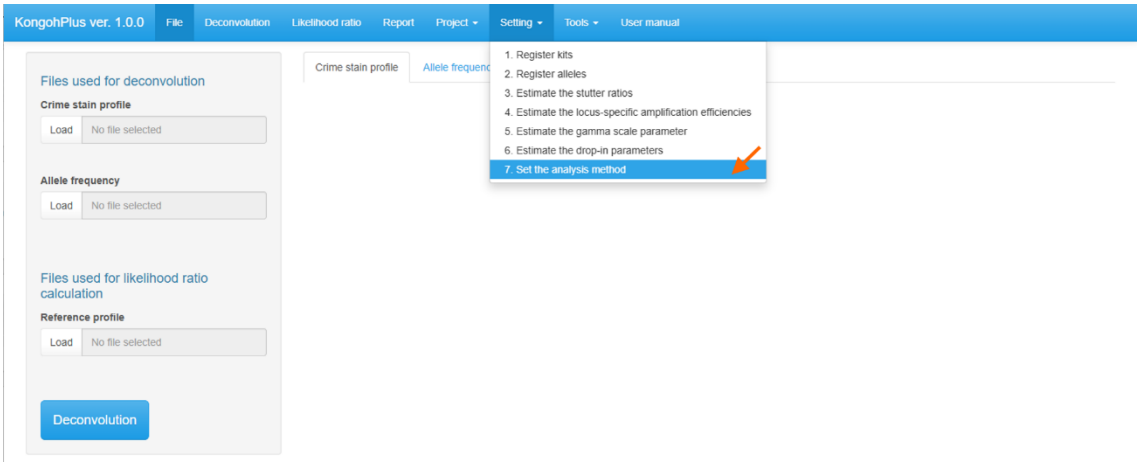
10. 任意のファイル名を入力し、**”Save”** をクリックします。



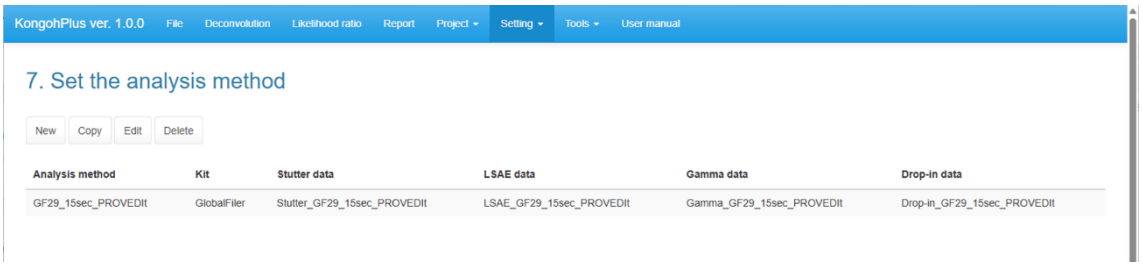
8.7. Analysis method の設定

本項では、analysis method の設定方法について説明します。

1. **“Setting” ▶ “7. Set the analysis method”** をクリックします。



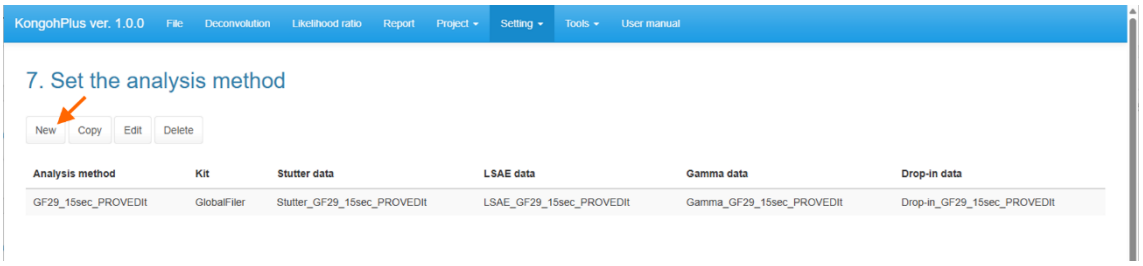
2. すると、以下のような画面が表示されます。



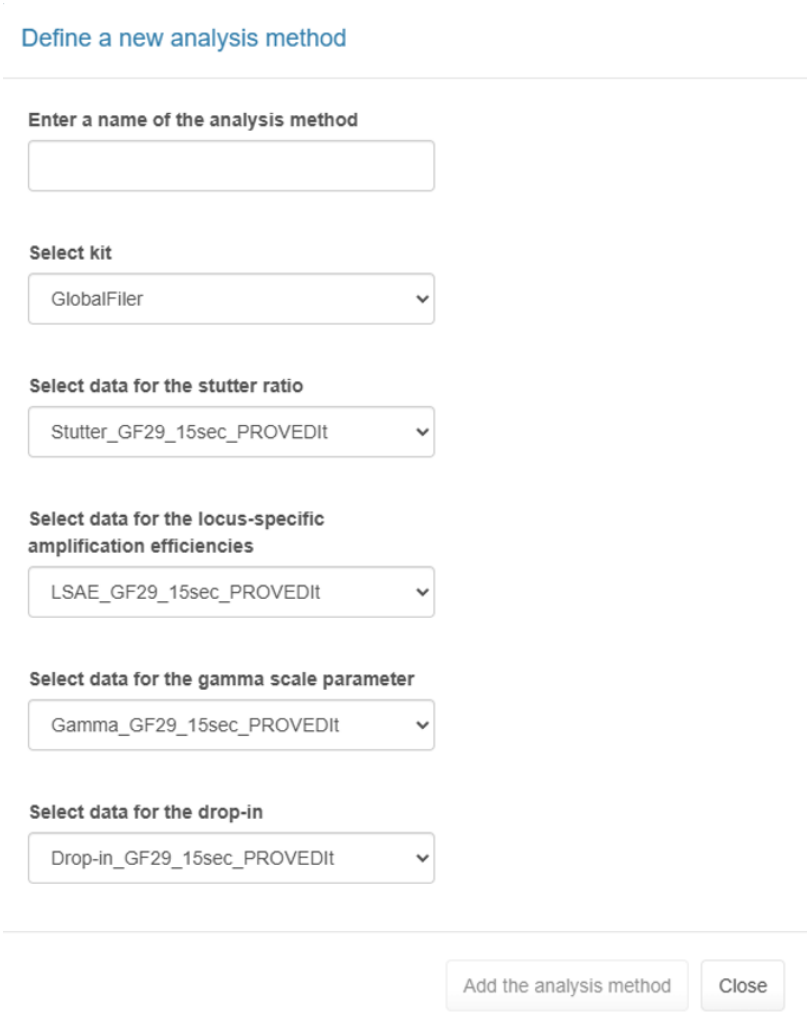
Note:

- **New:** 新しい analysis method を設定します。
- **Copy:** 選択した analysis method のコピーが作成されます。
- **Edit:** 選択した analysis method を編集できます。
- **Delete:** 選択した analysis method を削除できます。

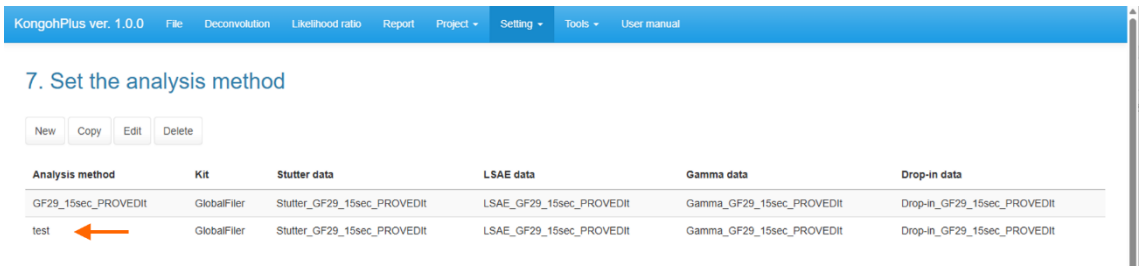
3. 以降、新しい analysis method の設定方法を説明します。**”New”** ボタンをクリックします。



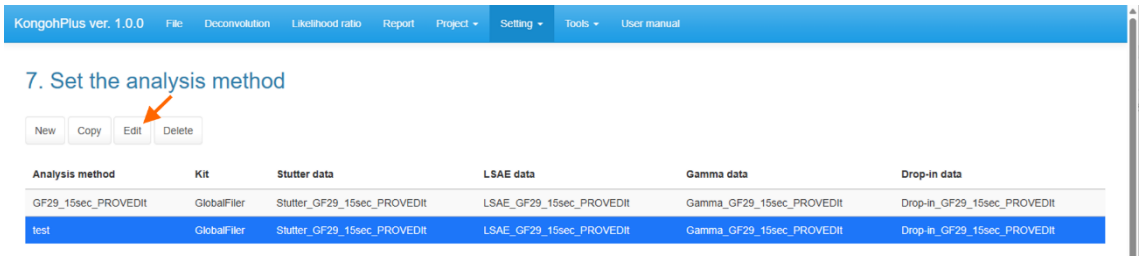
4. 以下の画面の項目を設定し、**”Add the analysis method”** をクリックします。なお、3 つ目以降の項目については、第 8.3 項から第 8.6 項で設定した各種パラメータの推定結果を選択します。



5. すると、新しい analysis method が一覧表に示されます。

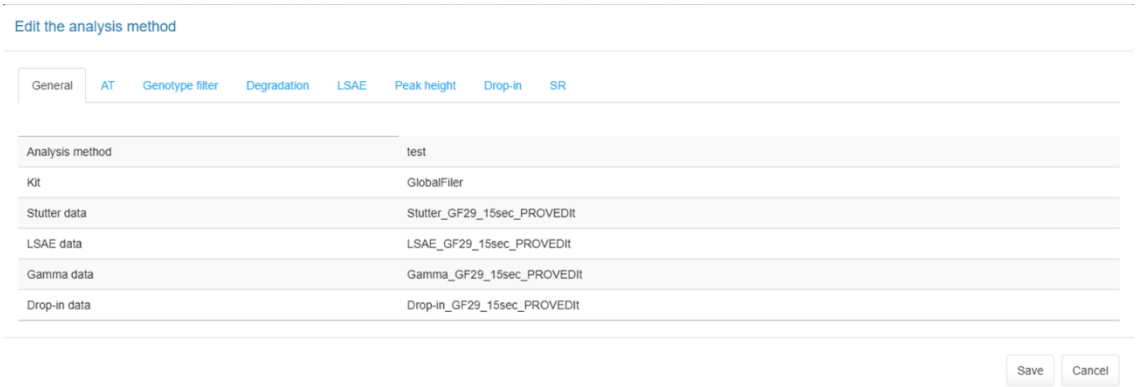


6. 新しい analysis method を選択した状態で、**"Edit"** ボタンをクリックします。



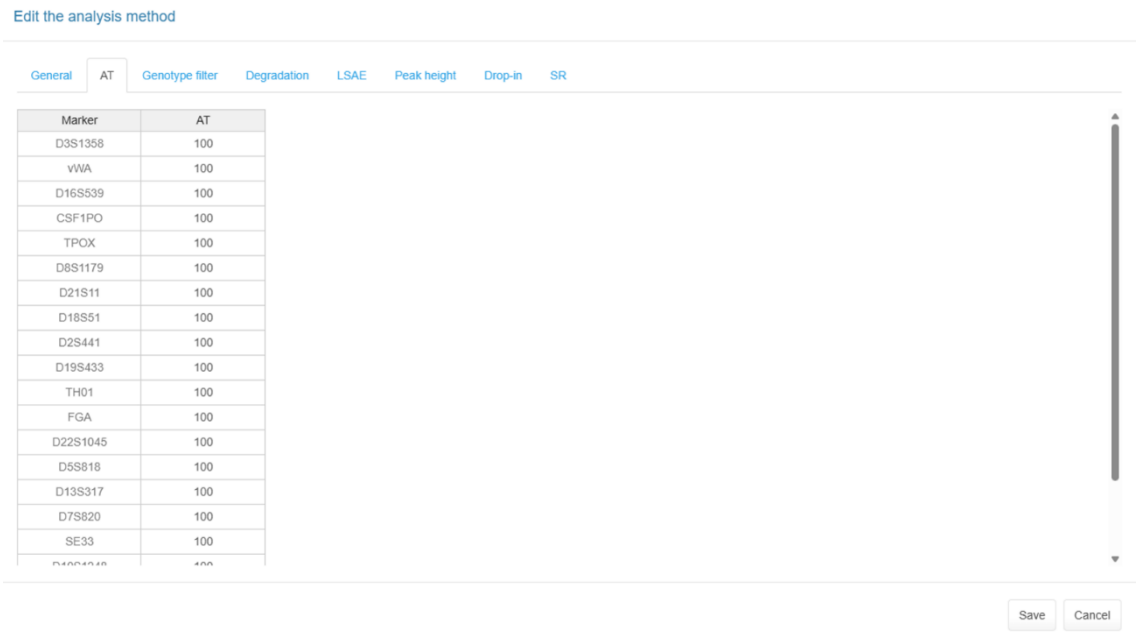
7. すると、設定用のポップアップ画面が開きます。以下、各タブの内容について説明します。

General



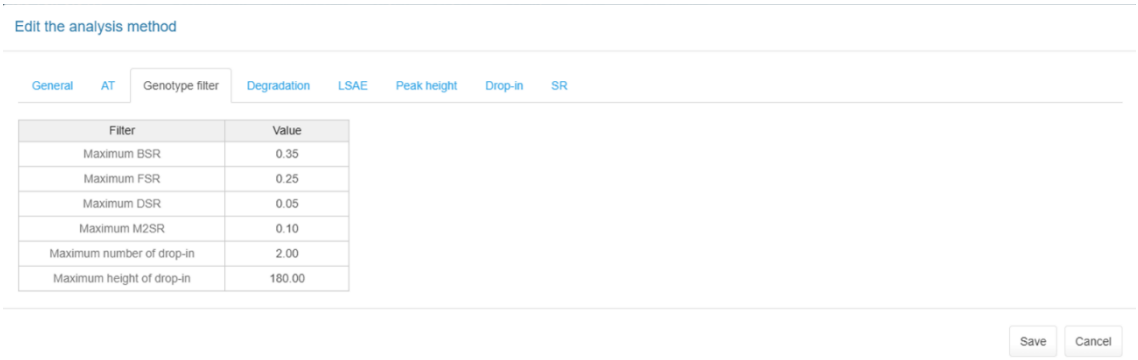
analysis method の名前やキットの情報、および実験データによるパラメータ推定結果のデータ名を確認できます。

AT



マーカー毎の AT 値を設定します。

Genotype filter

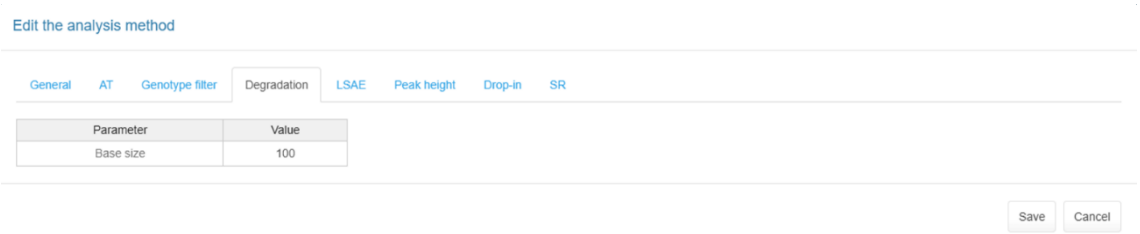


非現実的な DNA 型を解析から除外するための基準を設定します。

- **Maximum SR:** stutter ratio (SR) が指定の値を超える場合、その DNA 型を解析から除外します。back stutter ratio (BSR), forward stutter ratio (FSR), double-back stutter ratio (DSR), minus 2-nt stutter ratio (M2SR) に対して設定できます。
- **Maximum number of drop-in:** ローカスあたりの drop-in 数の最大許容数を指定します。

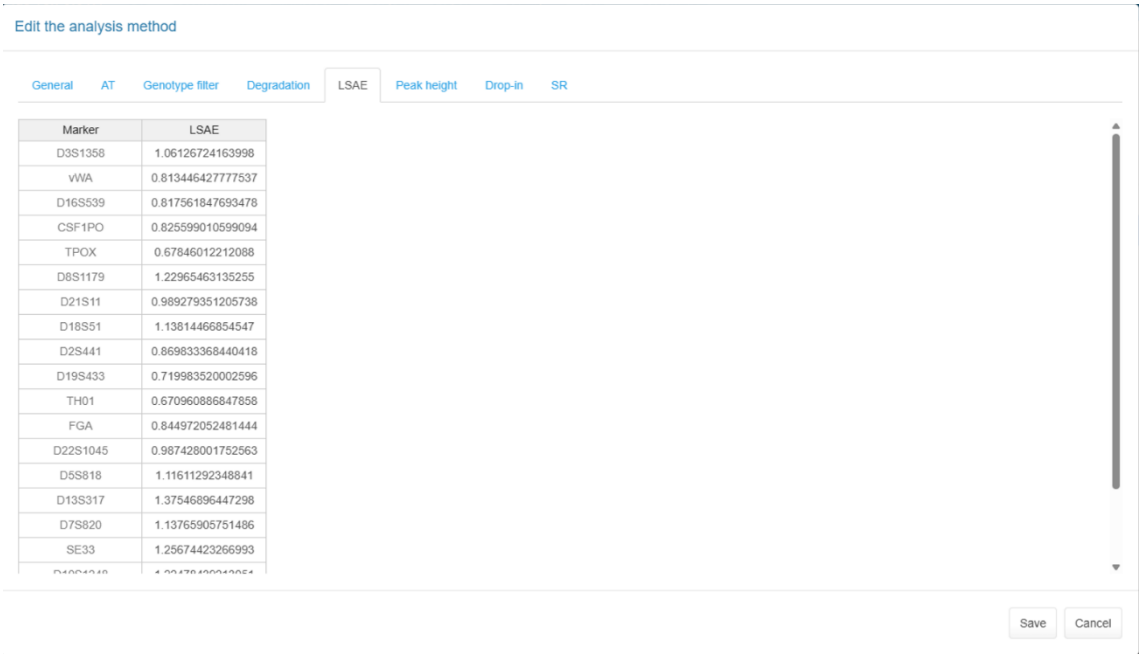
- **Maximum height of drop-in:** drop-in のピーク高の最大値を指定します。指定の値を超えるピークについては、drop-in の可能性を考慮しません。

Degradation



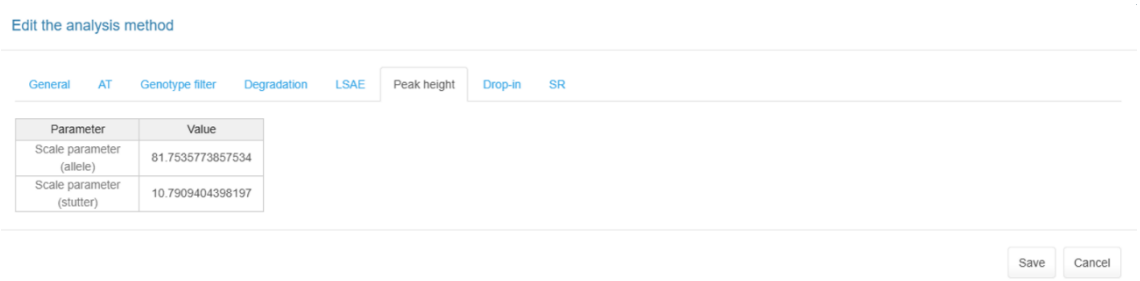
フラグメントサイズの基準値（$\hat{f}$）を設定します。詳細は、第 10.3.1 項を参照してください。

LSAE



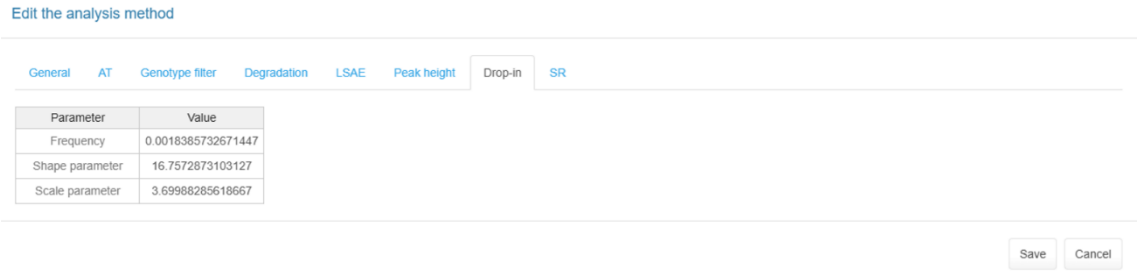
ローカス固有の PCR 増幅効率を設定します。既定では、第 8.4 項の手順に従って推定した値が設定されていますが、ユーザーが値を変更することもできます。

Peak height



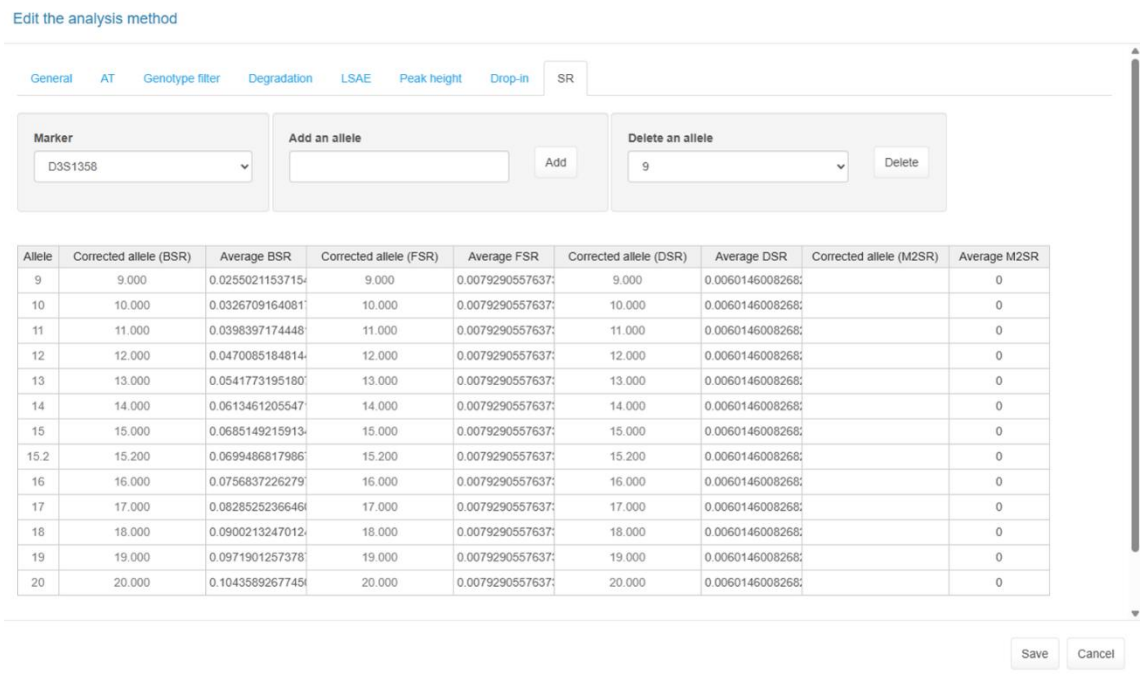
ガンマ分布の scale parameter を設定します。既定では、第 8.5 項の手順に従って推定した値が設定されていますが、ユーザーが値を変更することもできます。

Drop-in



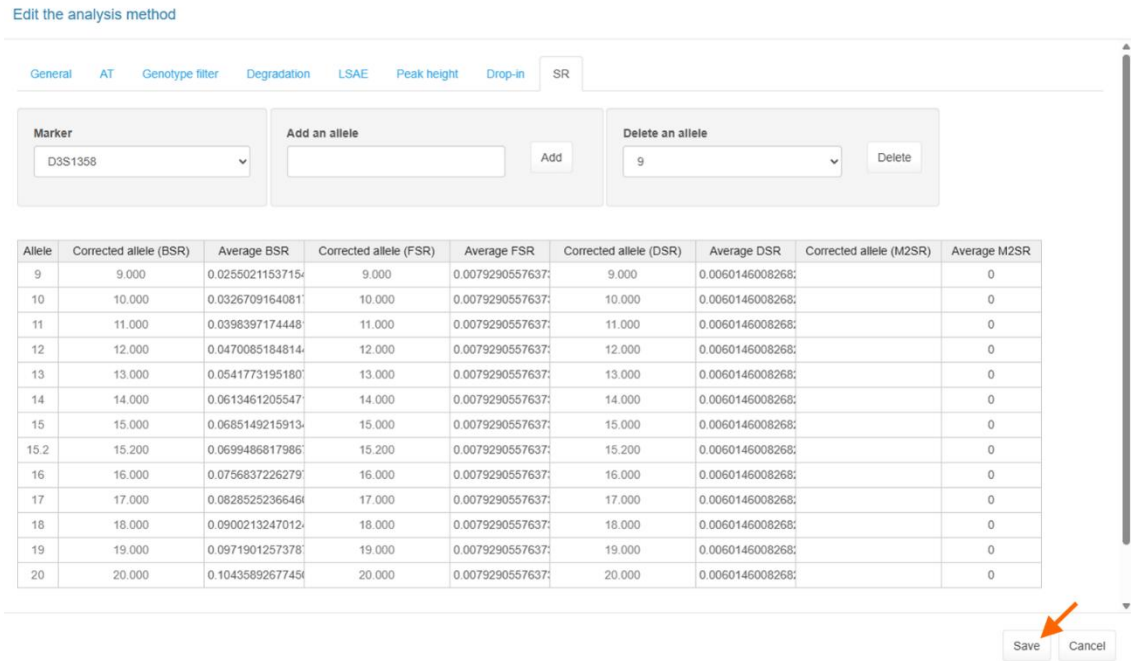
drop-in に関するパラメータを設定します。既定では、第 8.6 項の手順に従って推定した値が設定されていますが、ユーザーが値を変更することもできます。

SR



　各ローカスにおける、アレル毎の stutter ratio を設定します。既定では、第 8.3 項の手順に従って推定した値が設定されていますが、ユーザーが値を変更することもできます。新たなアレルを追加することも可能です。

8.　全ての項目の設定が完了したら、**”Save”** ボタンをクリックします。

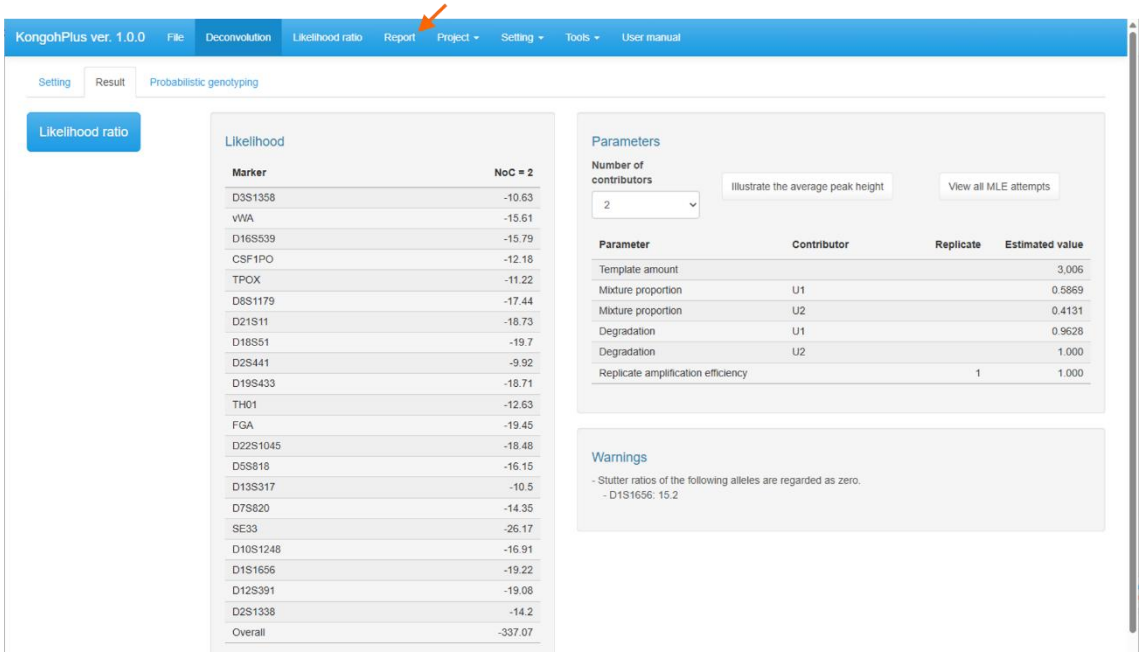


9. その他の機能

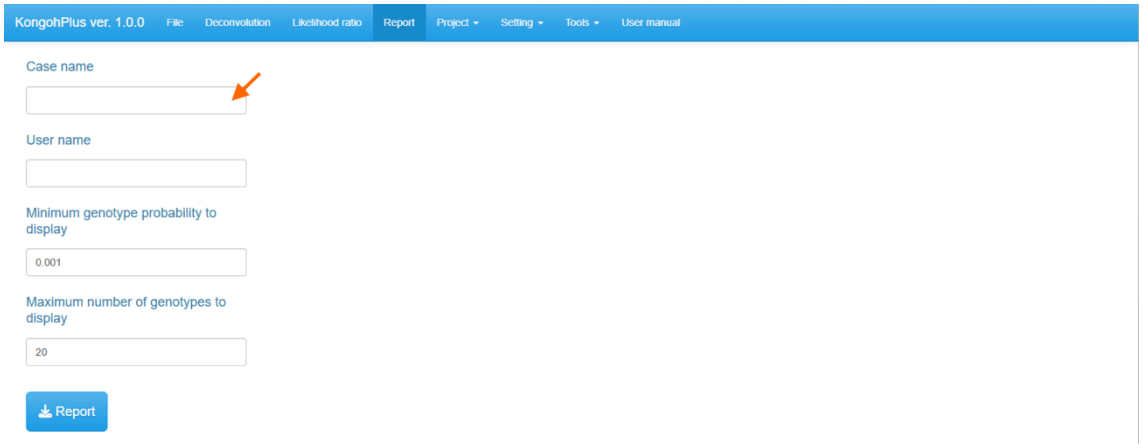
9.1. レポート出力

本項では、解析結果をレポートとして出力する手順を説明します。

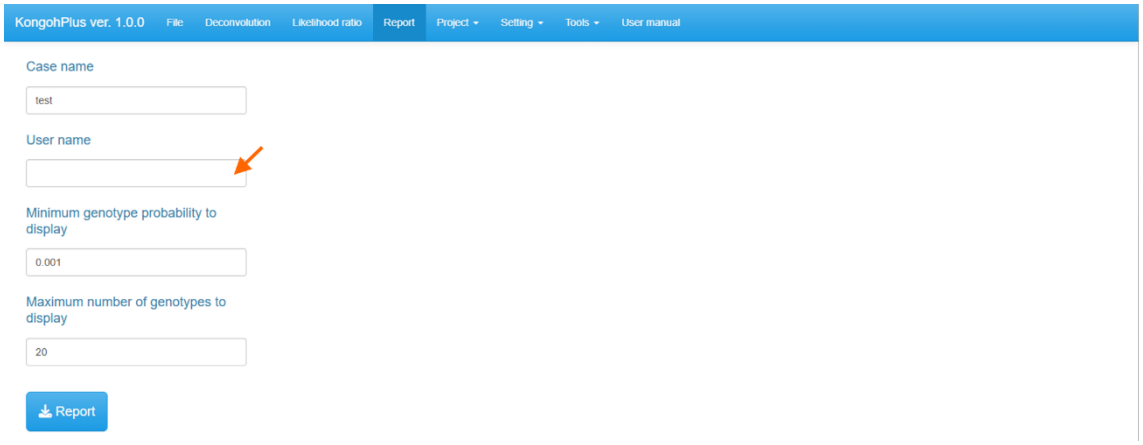
1. **“Report”** タブをクリックします。



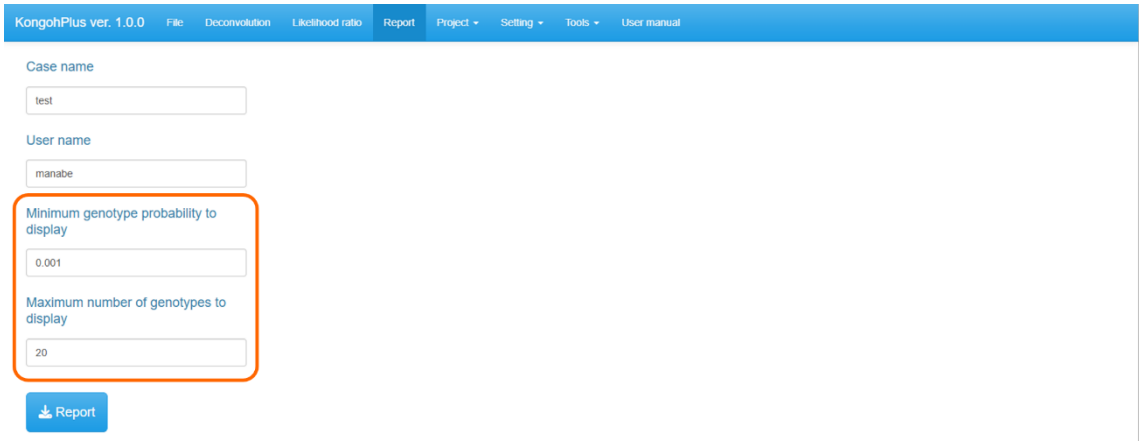
2. **“Case name”** を入力します。



3. **“User name”** を入力します。



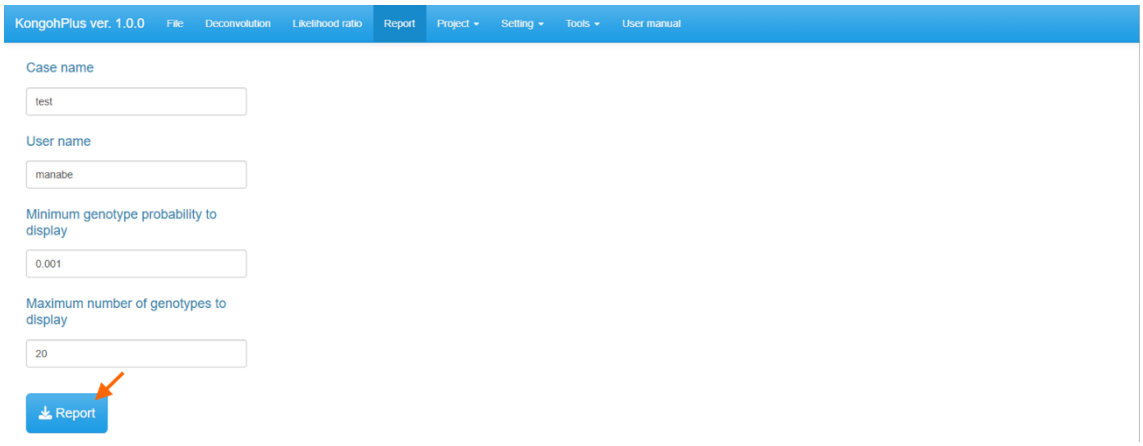
4. レポート出力する DNA 型の候補に関する設定を行います。



Note:

- **Minimum genotype probability to display:** レポートに出力する DNA 型の確率の下限値を設定します。この値以上の確率を持つ DNA 型のみがレポートに出力されます。
- **Maximum number of genotypes to display:** レポートに出力する DNA 型候補の最大数を設定します。

5. **“Report”** をクリックします。

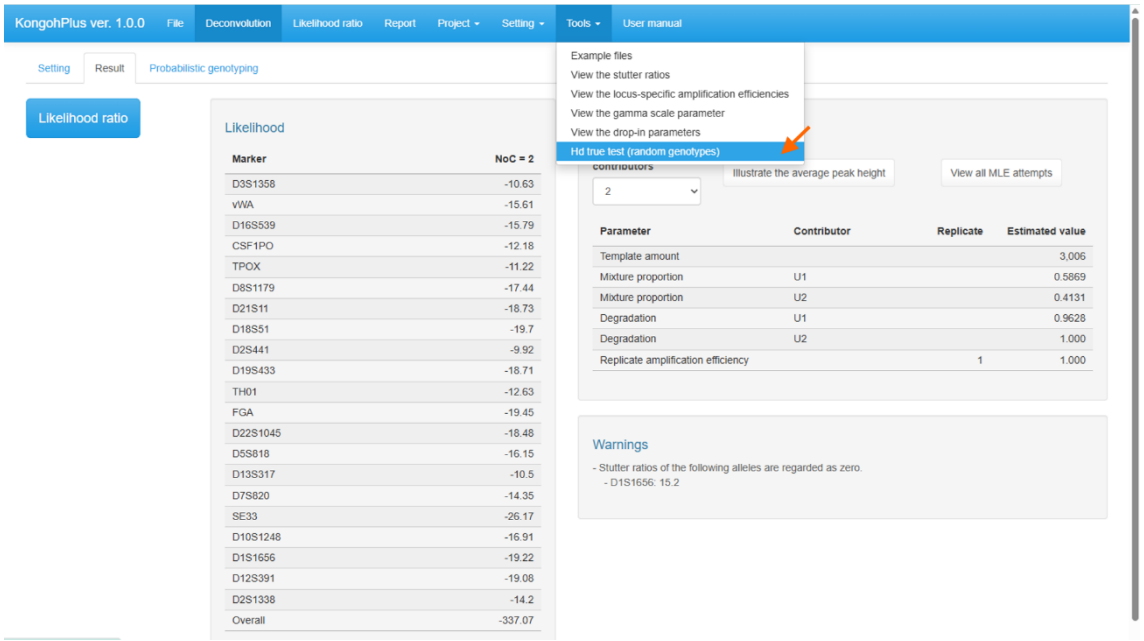


9.2. Hd true test

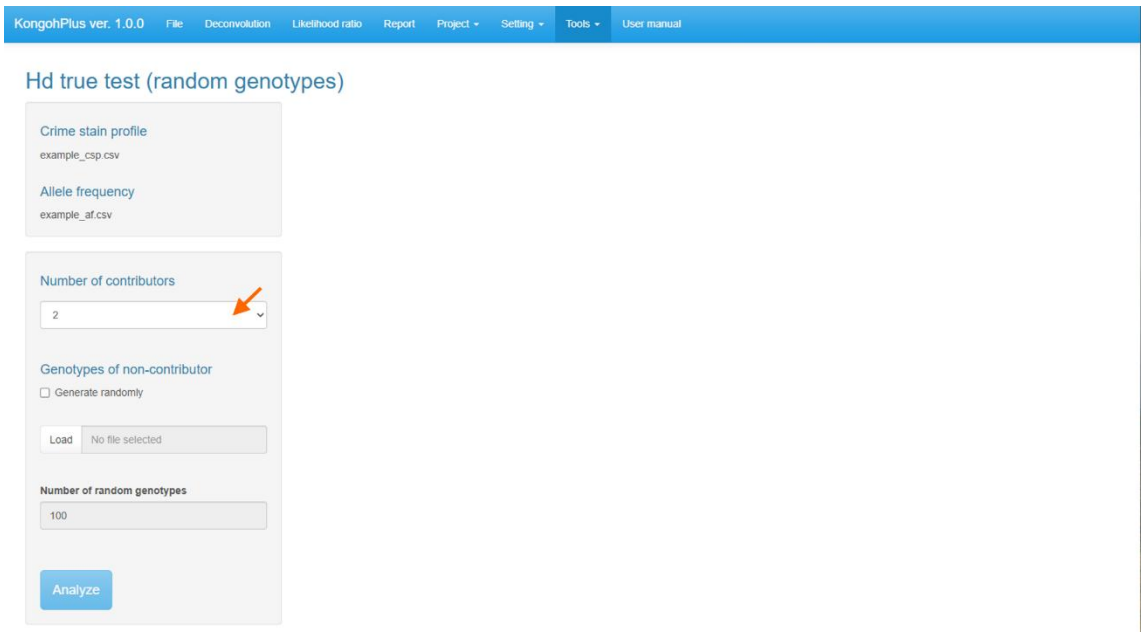
本項では、問題の遺留資料の DNA プロファイル（crime stain profile）に対して、実際には DNA を提供していない人物（非関与者）の DNA 型を用いて尤度比分布をシミュレーションする機能について説明します。これは、問題となる人物（person of interest: POI）が実際には関与者ではないという Hd 仮説が真である場合を想定したシミュレーションです。

1. 問題の遺留資料の DNA プロファイルについて、Deconvolution を実行します。詳細は第 3 項を参照してください。

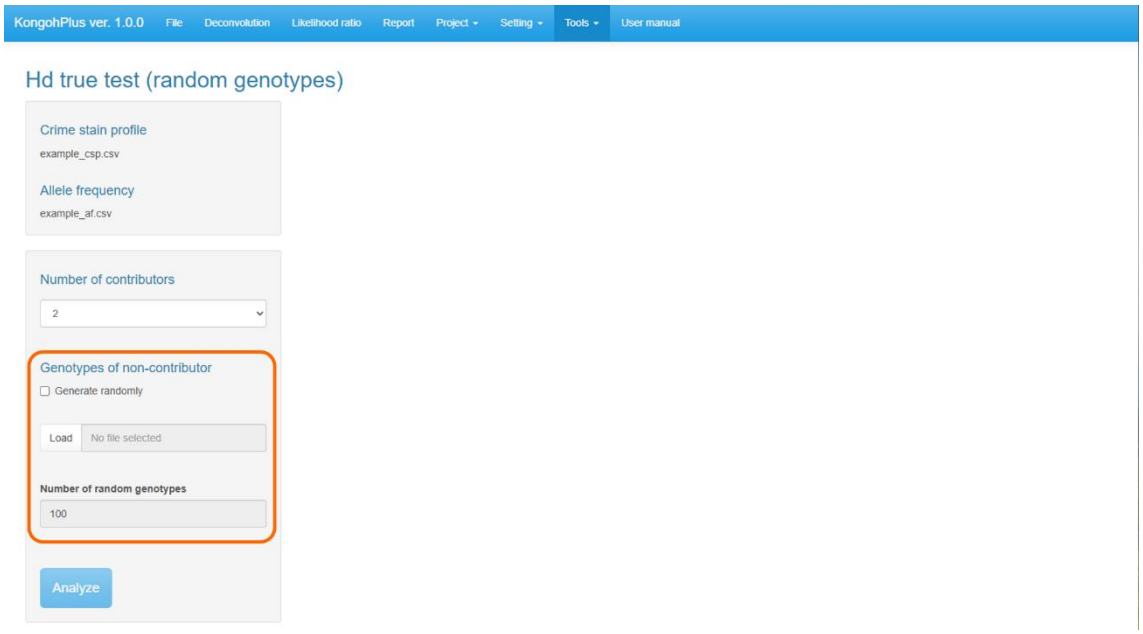
2. **“Tools” ▶ “Hd true test (random genotypes)”** をクリックします。



3. 関与人数を選択します。



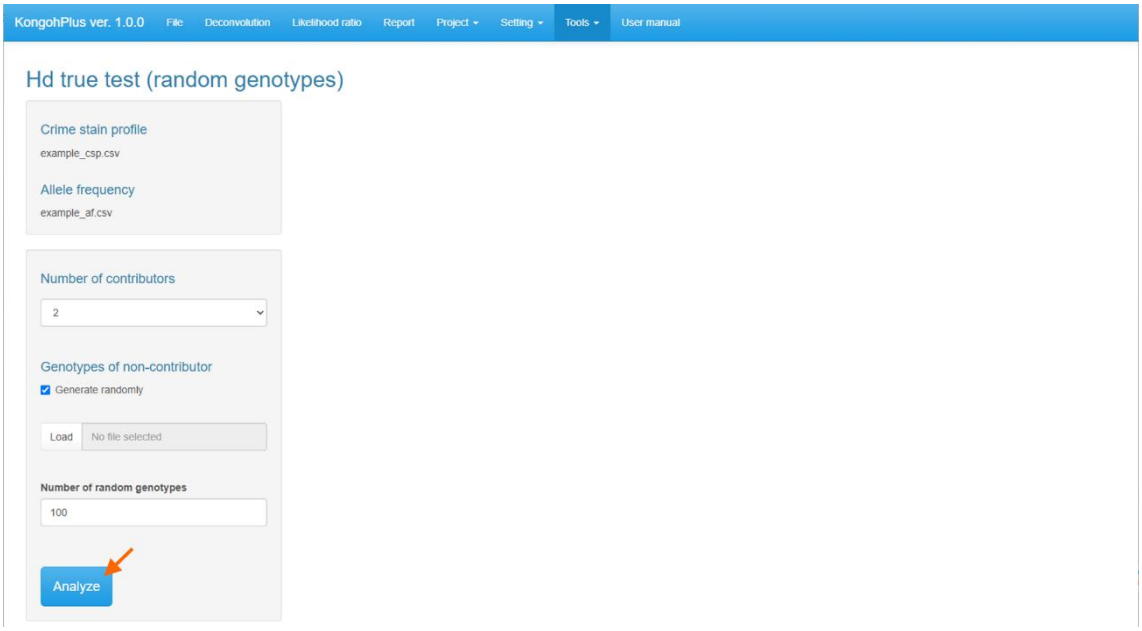
4. 非関与者の DNA 型に関する設定を行います。



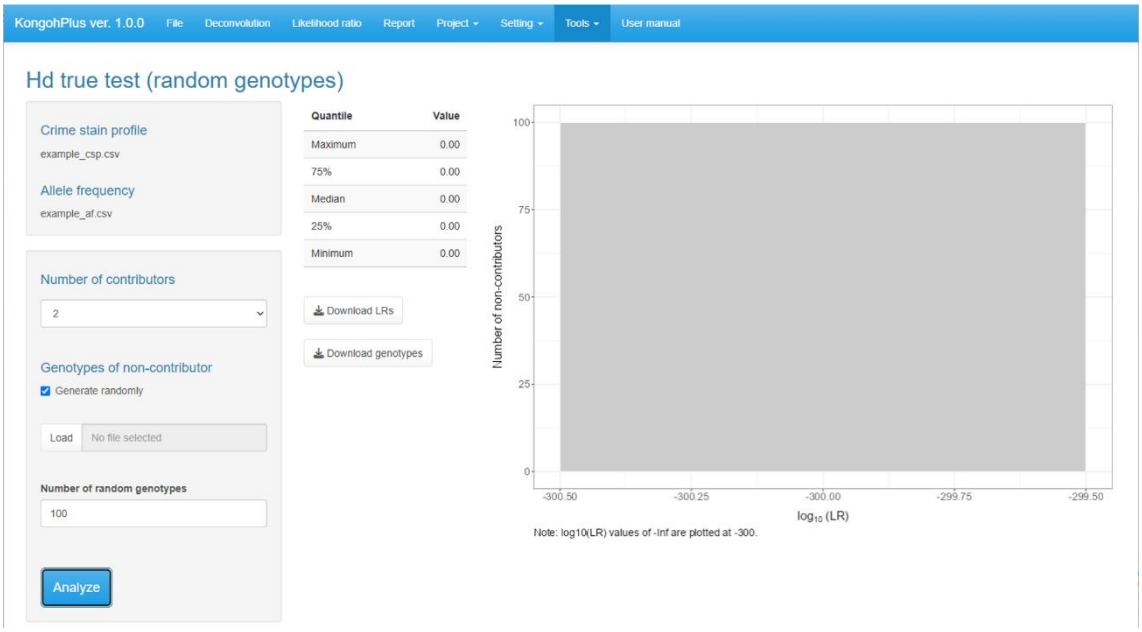
Note:

- **“Generate randomly”** にチェックを入れると、読み込まれているアレル頻度データに基づいて非関与者の DNA 型をランダムに生成できます。この機能を使用する場合は、**”Number of random genotypes”** に生成する DNA 型の数を指定してください。
- ユーザーが用意した非関与者の DNA 型を使用することもできます。この場合は **“Generate randomly”** のチェックを外し、**”Load”** ボタンをクリックして DNA 型ファイルを読み込みます。ファイル形式は、第 4.3 項で説明した対照資料の DNA プロファイル（reference profile）と同一です。

5. **“Analyze”** をクリックします。



6. 解析終了後、尤度比の要約統計量とヒストグラムが表示されます。尤度比の計算結果および解析に用いた DNA 型をダウンロードできます。



10. 計算原理

KongohPlus による解析は、Deconvolution と尤度比（Likelihood Ratio; LR）の計算の 2 段階で行われる（図 1）。

まず、Deconvolution では、観察された DNA プロファイルを最もよく説明するパラメータ（混合比や分解の程度など）を推定し、観察データに対する DNA 型の確率的な重み付けを行う。この解析を行うにあたり、法科学者はあらかじめ「何人分の DNA が混合しているか」を推定する必要がある。

次に、法科学者が設定した 2 つの仮説に基づき、Deconvolution の結果を用いて LR を計算する。LR は、観察された DNA プロファイルが 2 つの仮説のどちらをより支持するかを定量的に評価する指標である。

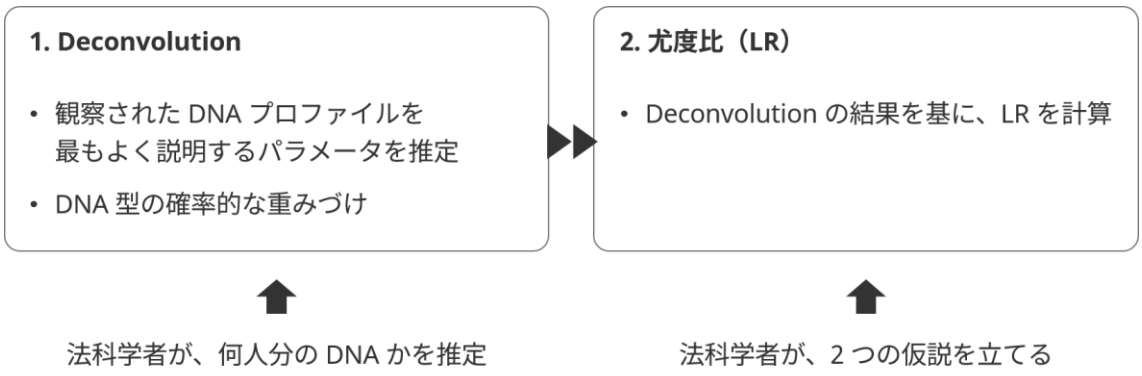


図 1　KongohPlus による解析の流れ

10.1. Deconvolution

Deconvolution の目的は、法科学者が考える仮説 H の下で、観察された crime stain profile（CSP）を最もよく説明するパラメータを推定することである。ここで、仮説 H は unknown contributor の人数に関する仮説を表す。

Taylor らが示した probabilistic genotyping software の枠組み [3] に従い、想定し

た関与人数およびモデルパラメータのもとで観察された crime stain profile（CSP）が得られる尤度を、次式で表す。

$$f(CSP \mid H, M) = \prod_{l} \sum_{i} f\left(CSP_l \mid G_{l,i}, M\right) \Pr\left(G_{l,i} \mid H\right) \quad (1)$$

CSP_l　：ローカス l における crime stain profile（検出された各ピークの高さ）

$G_{l,i}$　：ローカス l における i 番目の DNA 型の組合せ

M　：パラメータの集合

H　：仮説（関与者の構成に関する前提条件）

KongohPlus では、ピーク高を説明するために必要なパラメータの集合を M と表す。これらのパラメータには、プロファイル毎に異なる値をとるもの（case-specific parameter: DNA 量や混合比など）と、あらかじめ実験データから決定されるもの（laboratory-specific parameter: ローカス固有の PCR 増幅効率や back stutter ratio など）が含まれる（詳細は第 10.7 項を参照）。解析では、laboratory-specific parameter を固定した上で、case-specific parameter の値を変化させながら尤度を計算し、観察された crime stain profile を最もよく説明する case-specific parameter を求める。

計算の手順は、以下の通りである。

1. あり得る DNA 型の組合せ $G_{l,i}$（$i = 1, 2, \ldots, I$）を全て列挙する
2. 仮説（H）の下で、DNA 型の組合せ $G_{l,i}$ が得られる確率を計算する（$\Pr\left(G_{l,i} \mid H\right)$）
3. DNA 型の組合せ $G_{l,i}$ について、観察ピーク高をどの程度説明できるかを評価する（$f\left(CSP_l \mid G_{l,i}, M\right)$）
4. それらを重みづけで合計する（$\sum_i$ の部分）
5. ローカス毎の合計値を掛け合わせる（$\prod_l$ の部分）

これを case-specific parameter の値を変更しながら計算し、$f(CSP \mid H, M)$ が最大となる case-specific parameter を推定する。

10.2. DNA 型の確率計算

本項では、式 (1) における $\Pr(G_{l,i} \mid H)$ の計算に関する事項について説明する。

KongohPlus では、各ローカスにおいて考えられる全ての DNA 型の組合せを列挙し、それぞれの組合せが仮説 H（unknown contributor の人数）の下で得られる確率を計算する。この確率は、各 contributor の DNA 型の出現確率から求められる。必要に応じて、Balding–Nichols モデルによる集団構造の補正を適用する[4]。

10.2.1. DNA 型の組合せ

KongohPlus では原則として、各ローカスにおいて想定される全ての DNA 型の組合せを列挙して解析する。ただし、計算負荷を減らすため、非現実的な DNA 型を解析から除外するための基準を設けることが可能である。基準は以下の通りである。

- **Maximum BSR:** back stutter ratio (SR) が指定の値を超える場合、その DNA 型を解析から除外する。
- **Maximum FSR:** forward stutter ratio (FSR) が指定の値を超える場合、その DNA 型を解析から除外する。
- **Maximum DSR:** double-back stutter ratio (DSR) が指定の値を超える場合、その DNA 型を解析から除外する。
- **Maximum M2SR:** minus 2-nt stutter ratio (M2SR) が指定の値を超える場合、その DNA 型を解析から除外する。
- **Maximum number of drop-in:** ローカスあたりの drop-in 数の最大許容数。仮定した DNA 型の下で、drop-in の個数が指定の値を超える場合、その DNA 型を解析から除外する。
- **Maximum height of drop-in:** drop-in のピーク高の最大値。指定の値を超えるピークについては、drop-in の可能性を考慮しない。

10.2.2. アレル頻度

DNA 型の確率計算には、アレル頻度が必要となる。

KongohPlus では、アレル頻度はディリクレ分布に従う確率変数であると仮定する。事前分布には一様分布を用い、ディリクレ分布の期待値をアレル頻度として採用する。

アレル a の頻度 p_a は、以下の式により計算される [5]。

$$p_a = \frac{n_a + 1}{\sum_{a=1}^{k+1}(n_a + 1)} \tag{2}$$

n_a は、population database におけるアレル a の観察数を示す。k は、population database で観察されたアレルの種類数を示す。

分母で $k+1$ としているのは、未観測アレルに対応するカテゴリをあらかじめ 1 つ設けているためである。一般的には、ディリクレ分布の次元数は population database で観察されたアレルの種類数 k とするが、KongohPlus では、未観測アレルの有無によってディリクレ分布の次元数が変化し、それに伴って既知アレルの推定頻度が変化することを避けるため、未観測アレルに対応するカテゴリをあらかじめ 1 つ追加し、ディリクレ分布の次元数を $k+1$ としてアレル頻度を推定する。

未観測アレルは一般に稀であるため、多く解析では 1 種類の未観測アレルを考慮すれば十分であると考え、このような設計としている。一方、解析対象に 2 種類以上の未観測アレルが含まれる場合には、その数に応じてディリクレ分布の次元数が自動的に増やされる。この場合には、ディリクレ分布の次元数が増加するため、既知アレルを含めたすべてのアレル頻度が通常の解析時とはわずかに異なる。

10.2.3. Drop-out したアレルの扱い

ドロップアウトが起きている場合には、観察されていないアレルの確率を考慮する必要がある。

例えば、あるローカスでアレル 11 のみが観察されている場合を考える。このとき、真の DNA 型は 11, 11 型だけでなく、11, Q 型である可能性も考えられる。ここで Q は、11 以外の任意のアレルを表す。

この場合、Q のアレル頻度は、11 以外のすべてのアレル頻度の総和となるため、

$p_Q = 1 - p_{11}$

と表すことができる。

したがって、11, Q 型の確率は、ハーディー・ワインベルク平衡を前提とすると、

$2p_{11}(1 - p_{11})$

として計算される。

同様に、複数のアレルが観察されている場合には、観察されたアレル以外をまとめて Q とし、そのアレル頻度は観察されたアレル頻度の総和 1 から引くことで求められる。

10.3. ピーク高の統計学的モデル

本項では、式 (1) における $f\left(CSP_l \mid G_{l,i}, M\right)$ の計算方法について説明する。

$f\left(CSP_l \mid G_{l,i}, M\right)$ の計算のイメージは、ある条件下におけるピーク高の期待値を求めて、実際の観察値と比較するというものである。例えば、図 2 に示すように、あるローカスでアレル 9 と 10 のピーク高が比較的高く、アレル 11 と 12 のピーク高が比較的低く観察されている場合を考える。条件 1 として、major contributor を 9, 10 型、minor contributor を 11, 12 型と仮定したとき、9 と 10 の期待値は比較的高く、11 と 12 の期待値は比較的低くなる。これらの期待値は観察値とほぼ同等であることから、「9, 10 型 + 11, 12 型」という DNA 型の組合せに対しては高い重みをつける。一方、条件 2 として、major contributor を 9, 11 型、minor contributor を 10, 12 型と仮定したとき、9 と 11 の期待値は比較的高く、10 と 12 の期待値は比較的低くなる。これらの期待値は観察値から大きく乖離していることから、「9, 11 型 + 10, 12 型」という DNA 型の組合せに対しては低い重みをつける。

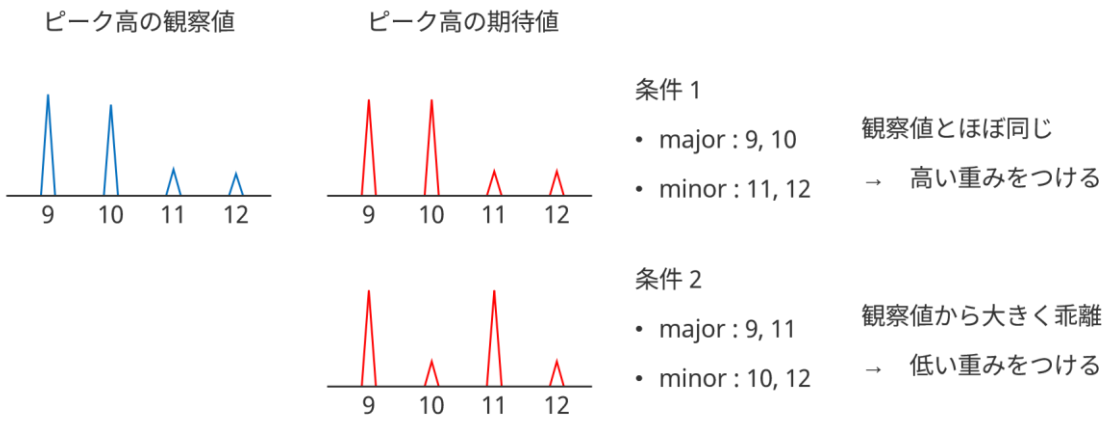


図 2　$f\left(CSP_l \mid G_{l,i}, M\right)$ の計算のイメージ

10.3.1. ピーク高の期待値

各ピーク成分（アレル成分およびスター成分）のピーク高の期待値は、それぞれのピーク成分に対応するパラメータから計算される。ヘテロ接合体 1 本あたりのアレル成分のピーク高の期待値（$E_{l,r,a,c}$）は、以下の式で表される。

$$E_{l,r,a,c} = \frac{TM_c D_c^{(f_a - \hat{f})/100} R_r \hat{A}_l}{1 + \hat{S}_{l,a}^{(\text{back})} + \hat{S}_{l,a}^{(\text{forward})} + \hat{S}_{l,a}^{(\text{double-back})} + \hat{S}_{l,a}^{(\text{minus 2-nt})}} \tag{3}$$

$E_{l,r,a,c}$ は、ローカス l、r 回目の PCR における contributor c のアレル a 成分のピーク高の期待値という意味である。また、式 (3) に現れるパラメータは、プロファイル毎に最適な値が変わる case-specific parameter と、鑑定機関毎に最適な値が変わる laboratory-specific parameter に分類される。

case-specific parameter

T : ヘテロ接合体 1 本あたりのピーク高

M_c : contributor c の混合比

D_c : contributor c の DNA 分解の程度

R_r : 1 回目の PCR を 1 としたときの r 回目の PCR のピーク高の相対量

laboratory-specific parameter

$\hat{A}_l$: ローカス l の PCR 増幅効率（全体平均を 1 としたときの相対量）

$\hat{S}_{l,a}^{(\mathrm{back})}$: ローカス l、アレル a の back stutter ratio

$\hat{S}_{l,a}^{(\mathrm{forward})}$: ローカス l、アレル a の forward stutter ratio

$\hat{S}_{l,a}^{(\mathrm{double-back})}$: ローカス l、アレル a の double-back stutter ratio

$\hat{S}_{l,a}^{(\mathrm{minus\ 2-nt})}$: ローカス l、アレル a の minus 2-nt stutter ratio

case-specific parameter については、KongohPlus がプロファイル固有の値を最尤推定により推定する。laboratory-specific parameter については、KongohPlus で特定のプロファイルを解析する前に、実験的に決めておくものである。

f_a はアレル a のフラグメントサイズ、$\hat{f}$ はフラグメントサイズの基準値（既定値は 100 base）を表す。これらは、DNA 分解によるピーク高の減衰を表現するための因子である。$D_c^{(f_a-\hat{f})/100}$ は、フラグメントサイズ f_a におけるピーク高が、基準フラグメントサイズ $\hat{f}$ におけるピーク高の $D_c^{(f_a-\hat{f})/100}$ 倍になることを意味する。また、指数表記部分を 100 で除しているが、これにより、フラグメントサイズが 100 base 増加する毎に、ピーク高は D_c 倍になると解釈できる [6]。

スタター成分についても同様の考え方に基づいて期待ピーク高を計算する。同一のピーク位置に複数のピーク成分が寄与する場合には、それぞれの成分の期待ピーク高を加算し、その和を当該ピーク位置における期待ピーク高とする。

10.3.2. 観察ピーク高の得られやすさ

図 2 では、式 (1) における $f(CSP_l \mid G_{l,i}, M)$ の計算のイメージとして、ピーク高の期待値を求め、実際の観察値と比較することを説明した。本項では、この比較を具体的にどのように行うかについて説明する。

仮に、あるアレル成分のピーク高の期待値が 1000 RFU と計算されたとしても、実際に観察されるピーク高が常に 1000 RFU となるわけではない。PCR 増幅には確率的なばらつきが存在するため、同じ DNA 試料を繰り返し測定した場合でも、観察されるピーク高は毎回わずかに異なる。

したがって、期待値と観察値が完全に一致するかどうかではなく、**その観察値が期待値の下でどの程度得られやすいか**を評価する必要がある。

図 3 は、この「観察値の得られやすさ」の概念を模式的に示したものである。観察ピーク高が 1020 RFU のように期待値付近のピーク高であった場合、「観察値の得られやすさ」は大きくなり、仮定した条件下では起こりやすい観察値であると評価される。一方、観察ピーク高が 300 RFU や 2500 RFU のように期待値から大きく離れている場合には、「観察値の得られやすさ」は小さくなり、仮定した条件下では起こりにくい観察値であると評価される。このように、KongohPlus では、観察ピーク高と期待ピーク高との差そのものではなく、**その差がどの程度起こり得るか**に基づいて各ピーク高を評価する。

「観察値の得られやすさ」は、$f(O_{l,r,a} \mid G_{l,i}, M)$ と表記する。つまり、ある DNA 型の組合せ（$G_{l,i}$）とパラメータ（M）の条件下において、ローカス l、r 回目の PCR におけるアレル a の位置にあるピークの観察値が $O_{l,r,a}$ となる度合いであり、図 3 の縦軸の値（確率密度）に相当する。

ただし、ローカス l における crime stain profile（CSP_l）は、1 つのピーク高だけで構成されるわけではない。実際には、同じローカス内に複数のアレル位置が存在し、さらに複数回 PCR を行う場合には、それぞれの PCR においてピーク高が観察される。

そのため、ローカス l における観察ピーク高全体の得られやすさは、各 PCR、各アレル位置における観察値の得られやすさを掛け合わせることで計算する。すなわち、式 (1) における $f(CSP_l \mid G_{l,i}, M)$ は、以下のように表される。

$$f\left(CSP_l \mid G_{l,i}, M\right) = \prod_r \prod_a f\left(O_{l,r,a} \mid G_{l,i}, M\right) \tag{4}$$

次項では、個々の $f\left(O_{l,r,a} \mid G_{l,i}, M\right)$ をどのように計算するかについて説明する。

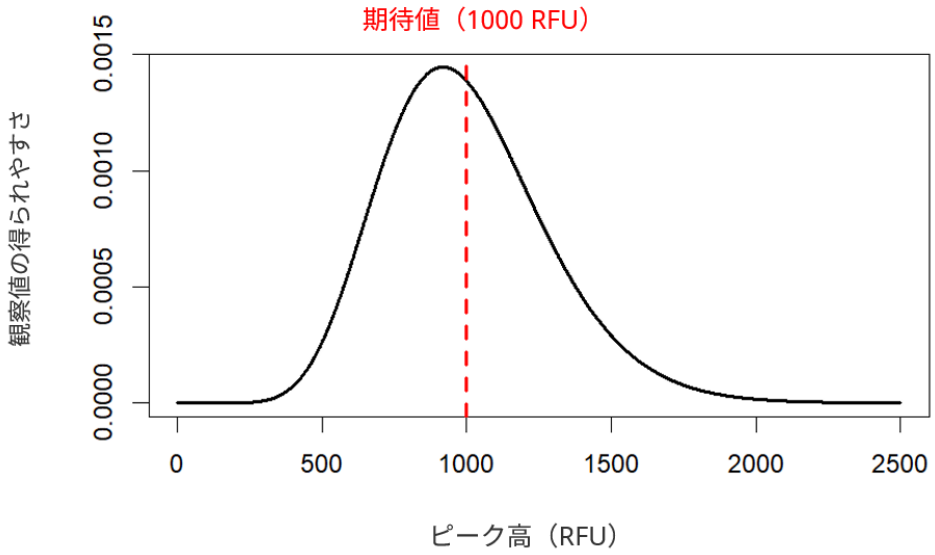


図 3　ピーク高とその得られやすさの模式図

10.3.3. ガンマ分布

KongohPlus では、図 3 に示す「観察値の得られやすさ」をガンマ分布によって表現する。このガンマ分布は、ある期待ピーク高に対して、観察ピーク高がどの程度ばらつくかを表した確率分布である。ガンマ分布における観察ピーク高の確率密度（分布の縦軸）を求めることで、その観察値の得られやすさを数値として評価する。

アレル a の位置にあるピークが contributor c のアレル成分のみに由来する場合、そのピーク高の観察値の得られやすさは、以下のガンマ分布に従う。

$$f\left(O_{l,r,a} \mid G_{l,i}, M\right) = \mathrm{Gamma}\left(\frac{E_{l,r,a,c}}{\hat{\eta}^{(\mathrm{allele})}}, \hat{\eta}^{(\mathrm{allele})}\right) \quad (5)$$

$E_{l,r,a,c}$ ： アレル成分の期待値

$\hat{\eta}^{(\mathrm{allele})}$ ： アレル成分の scale parameter

同様に、アレル $a-1$ の位置にあるピークが contributor c のアレル a から発生した back stutter 成分のみに由来する場合、そのピーク高の観察値の得られやすさは、以下のガンマ分布に従う。

$$f\left(O_{l,r,a-1} \mid G_{l,i}, M\right) = \mathrm{Gamma}\left(\frac{E_{l,r,a-1,c}}{\hat{\eta}^{(\mathrm{stutter})}}, \hat{\eta}^{(\mathrm{stutter})}\right) \quad (6)$$

$E_{l,r,a-1,c}$: back stutter 成分の期待値

$\hat{\eta}^{(\mathrm{stutter})}$: スタター成分の scale parameter（スタターの種類によらず共通）

ガンマ分布の scale parameter（$\hat{\eta}^{(\mathrm{allele})}$ および $\hat{\eta}^{(\mathrm{stutter})}$）については、あらかじめ実験的に決めておく laboratory-specific parameter である。

式 (5) や (6) は、ピークの構成要素が特定の contributor のアレル成分ないしはスタター成分のみの場合におけるガンマ分布であるが、実際には複数の contributor に由来する成分が混在する場合が考えられる。混在のパターンとして、以下の 3 つが挙げられる。

1. アレル成分の混在
   例 : contributor 1 のアレル 10 と contributor 2 のアレル 10
2. スタター成分の混在
   例 : contributor 1 のアレル 10 の forward stutter と contributor 2 のアレル 12 の back stutter
3. アレル成分とスタター成分の混在
   例 : contributor 1 のアレル 10 と contributor 2 のアレル 11 の back stutter

上記 3 パターンのうち、1.と 2.については、成分間の scale parameter が共通であるため、ガンマ分布の再生性より、複数成分の和の分布もガンマ分布となる。例えば、contributor 1（$c = 1$）のアレル a 成分と contributor 2（$c = 2$）のアレル a 成分の和のガンマ分布は、以下の式で表される。

$$f\left(O_{l,r,a} \mid G_{l,i}, M\right) = \mathrm{Gamma}\left(\frac{E_{l,r,a,1} + E_{l,r,a,2}}{\hat{\eta}^{(\mathrm{allele})}}, \hat{\eta}^{(\mathrm{allele})}\right) \tag{7}$$

一方で、アレル成分とスタター成分が混在する場合については、それぞれ異なる scale parameter を持つため、それらの和は厳密にはガンマ分布とならない。このような分布をそのまま扱うことは難しいため、KongohPlus では、各成分を足し合わせた結果として得られるピーク高の分布を、1 つのガンマ分布で近似することを考える。具体的には、各成分を足し合わせたときに得られるピーク高の平均と分散を計算し、それと同じ値を持つガンマ分布を求める。このような方法をモーメントマッチングという。

ここで、$\mathrm{Gamma}(k_1, \theta_1)$ に従うあるデータと、$\mathrm{Gamma}(k_2, \theta_2)$ に従う別のデータを足し合わせたデータが、近似的に $\mathrm{Gamma}(k_0, \theta_0)$ に従うとする。

このとき、近似後のガンマ分布の平均および分散が、足し合わせる前のデータの平均および分散と一致するように、k_0 および θ_0 を決定する。独立な確率変数の和の平均および分散は、それぞれ各成分の平均および分散の和で表されるため、

$E(X_0) = E(X_1) + E(X_2)$

$Var(X_0) = Var(X_1) + Var(X_2)$

となる。

一方、ガンマ分布 $\mathrm{Gamma}(k, \theta)$ の平均は $E(X) = k\theta$、分散は $Var(X) = k\theta^2$ で表される。したがって、以下の式が成立する。

$k_0\theta_0 = k_1\theta_1 + k_2\theta_2$

$k_0\theta_0^2 = k_1\theta_1^2 + k_2\theta_2^2$

これを基に、k_0 および θ_0 を求めると、以下のようになる。

$$k_0 = \frac{(k_1\theta_1 + k_2\theta_2)^2}{k_1\theta_1^2 + k_2\theta_2^2}$$

$$\theta_0 = \frac{k_1\theta_1^2 + k_2\theta_2^2}{k_1\theta_1 + k_2\theta_2}$$

よって、$\mathrm{Gamma}(k_1, \theta_1)$ に従うあるデータと、$\mathrm{Gamma}(k_2, \theta_2)$ に従う別のデータを足し合わせたデータは、以下のガンマ分布で表すことができる。

$$\mathrm{Gamma}(k_0, \theta_0) = \mathrm{Gamma}\left(\frac{(k_1\theta_1 + k_2\theta_2)^2}{k_1\theta_1^2 + k_2\theta_2^2}, \frac{k_1\theta_1^2 + k_2\theta_2^2}{k_1\theta_1 + k_2\theta_2}\right) \tag{8}$$

この考え方を KongohPlus のピーク高のモデルに当てはめる。例えば、contributor 1（$c = 1$）のアレル a 成分と contributor 2（$c = 2$）のアレル a' の back stutter 成分がアレル a の位置で重なっている場合（$a = a' - 1$）、それぞれの成分のガンマ分布は以下の通りとなる。

$$\mathrm{Gamma}(k_1, \theta_1) = \mathrm{Gamma}\left(\frac{E_{l,r,a,1}}{\hat{\eta}^{(\mathrm{allele})}}, \hat{\eta}^{(\mathrm{allele})}\right)$$

$$\mathrm{Gamma}(k_2, \theta_2) = \mathrm{Gamma}\left(\frac{E_{l,r,a'-1,2}}{\eta^{(\mathrm{stutter})}}, \eta^{(\mathrm{stutter})}\right)$$

このとき、以下の式が成立する。

$$k_1\theta_1 + k_2\theta_2 = E_{l,r,a,1} + E_{l,r,a'-1,2}$$

$$k_1\theta_1^2 + k_2\theta_2^2 = E_{l,r,a,1}\eta^{(allele)} + E_{l,r,a'-1,2}\,\eta^{(stutter)}$$

これらを式 (8) に代入すると、各成分の和の分布をガンマ分布で近似できる。

10.3.4. Drop-out の統計学的モデル

アレル a がドロップアウトしている場合、ピーク高の観察値 $O_{l,r,a}$ は得られていない。このため、$f\left(O_{l,r,a} \mid G_{l,i}, M\right)$ の値は、前述までのガンマ分布を使って得ることはできない。

そこで、アレル a がドロップアウトしている場合は、$O_{l,r,a}$ がローカス l における

ピークの検出閾値（AT_l）を下回っていると考える。$O_{l,r,a}$ が AT_l 未満となる確率は、アレル a がドロップアウトしている確率であり、以下の式で表される。

$$\Pr\left(O_{l,r,a} < AT_l \mid G_{l,i}M\right) = \int_0^{AT_l} \Pr\left(O_{l,r,a} = x \mid G_{l,i}, M\right)dx \tag{9}$$

なお、ドロップアウトしたアレルについては、第 10.2.3 項で示した通り、観察されたアレル以外をまとめて Q として扱う。また、アレル Q の期待ピーク高を式 (3) で計算する際に、フラグメントサイズ（f_a）は、当該ローカスにおいて登録されているアレルのフラグメントサイズの中央値とする。

10.3.5. Drop-in の統計学的モデル

アレル a がドロップインによるものである場合、第 10.3.1 項で述べた方法でピーク高の期待値を得ることはできない。よって、前述までのガンマ分布とは別に、ドロップイン用のガンマ分布をモデルとして立てる必要がある。

アレル a がドロップインし、かつ高さが $O_{l,r,a}$ となる度合いは、以下の式で表される。

$$f\left(O_{l,r,a}\right) = f\left(O_{l,r,a} \mid C\right)\Pr(C) = \mathrm{Gamma}\left(\hat{\xi}^{(\mathrm{dropin})}, \hat{\eta}^{(\mathrm{dropin})}\right) \times \frac{\hat{F}^{(\mathrm{dropin})}}{P^{(\mathrm{dropin} \geq AT_l)}} \tag{10}$$

$\Pr(C)$ ： ドロップインが発生する確率

$\hat{\xi}^{(\mathrm{dropin})}$ ： ドロップインのピーク高のガンマ分布における shape parameter

$\hat{\eta}^{(\mathrm{dropin})}$ ： ドロップインのピーク高のガンマ分布における scale parameter

$\hat{F}^{(\mathrm{dropin})}$ ： 実験データで観察されたドロップインの発生頻度

$P^{(\mathrm{dropin} \geq AT_l)}$ ： ドロップインのピーク高が、ローカス l の AT 以上となる確率

ここで、$\mathrm{Gamma}\left(\hat{\xi}^{(\mathrm{dropin})}, \hat{\eta}^{(\mathrm{dropin})}\right)$ は、ドロップインによるピーク高の分布を表す。また、$\Pr(C)$ については、実験データで観察されたドロップインの頻度 $\hat{F}^{(\mathrm{dropin})}$ そのものではなく、そのドロップインがピークの検出閾値 AT_l 以上となる確率を考慮して

いる。

$\hat{\xi}^{(\mathrm{dropin})}, \hat{\eta}^{(\mathrm{dropin})}$, $\hat{F}^{(\mathrm{dropin})}$ は laboratory-specific なパラメータとして事前に設定される。具体的な設定方法は、第 10.7.4 項で説明する。

10.4. 最尤推定

10.4.1. 最尤推定の概要

Deconvolution における最尤推定では、式（1）の $f(CSP \mid H)$ を最大化するような case-specific parameter を求める。KongohPlus では、この最尤推定のためのアルゴリズムとして、Covariance Matrix Adaptation Evolution Strategy（CMA-ES）法を用いている [7]。CMA-ES は、連続値のパラメータを対象とした確率的最適化手法であり、複数の候補解を同時に探索しながら、より尤度の高い領域へと探索分布を適応的に更新することで、最適解を探索する。

10.4.2. 多スタート法

式（1）の尤度関数は複雑であるため、局所最適解が複数存在する可能性がある。そのため、単一の初期値からの最尤推定では、大域的最適解に到達しない場合がある。

そこで KongohPlus では、初期値を変更しながら最尤推定を複数回実行する、多スタート法を採用している。各試行は独立に実行され、それぞれで最尤推定が行われる。

10.4.3. 安定性の評価

複数回の最適化の結果として得られる尤度のうち、最大尤度とほぼ同等の値が一定回数以上得られた場合、その結果は安定しているとみなす。

具体的には、最大尤度との差が所定の閾値以内である結果を「ほぼ同等」と定義し、その出現回数に基づいて再現性を評価する。

この条件が満たされない場合は、局所最適解に収束している可能性があることを示す警告が表示される。

10.4.4. 設定

最尤推定に関する設定は、以下のとおりである。

- **Maximum number of iterations**
  1 回の最適化における最大反復回数
- **Maximum number of MLE attempts**
  多スタートの試行回数
- **Minimum number of consistent runs**
  再現性があると判断するために必要な回数
- **Reproducibility threshold**
  最大尤度との差の許容範囲（log10 スケール）

これらの設定により、計算時間および結果の安定性のバランスを調整することができる。その他、各パラメータが取り得る値の上限と下限も設定可能である。

10.5. Probabilistic Genotyping

本項では、各ローカスにおける各 DNA 型の組合せに対する確率的な重みづけ（probabilistic genotyping）の方法について述べる。

deconvolution における最尤推定により case-specific parameter が得られた後、各 DNA 型の組合せに対して、$f(CSP_l \mid G_{l,i}, M)\Pr(G_{l,i} \mid H)$ の値を計算することができる。この値は、DNA 型の組合せ（$G_{l,i}$）が、観察されたピークとその高さをどの程度説明できるかを表す相対的な指標といえる。

ただし、ローカス l における $f(CSP_l \mid G_{l,i}, M)\Pr(G_{l,i} \mid H)$ の総和は 1 にならず、確率として解釈できない。そこで、以下のように正規化を行う。

$$\Pr(G_{l,i} \mid CSP_l, M, H) = \frac{f(CSP_l \mid G_{l,i}, M)\Pr(G_{l,i} \mid H)}{\sum_i f(CSP_l \mid G_{l,i}, M)\Pr(G_{l,i} \mid H)} \tag{11}$$

この $\Pr(G_{l,i} \mid CSP_l, M, H)$ が、各 DNA 型の組合せに対する確率的な重みづけに相当する。

具体例を表 1 に示す。$f(CSP_l \mid G_{l,i}, M)\Pr(G_{l,i} \mid H)$ の合計は、$f(CSP_l \mid G_{l,i}, M)$ のスケールが小さいため 1 にならないが、正規化することで、合計が 1 になるスケールに変換することができる。

表 1　各 DNA 型の組合せに対する確率的な重みづけの一例

1 人目の DNA 型	2 人目の DNA 型	$f(CSP_l \mid G_{l,i}, M)$	$\Pr(G_{l,i} \mid H)$	$\Pr(G_{l,i} \mid CSP_l, M, H)$
9, 10	11, 12	4.50×10^{-10}	$2p_9p_{10} \times 2p_{11}p_{12}$	0.9
9, 11	10, 12	2.00×10^{-11}	$2p_9p_{11} \times 2p_{10}p_{12}$	0.04
9, 12	10, 11	1.50×10^{-11}	$2p_9p_{12} \times 2p_{10}p_{11}$	0.03
10, 11	9, 12	1.00×10^{-11}	$2p_{10}p_{11} \times 2p_9p_{12}$	0.02
10, 12	9, 11	4.95×10^{-12}	$2p_{10}p_{12} \times 2p_9p_{11}$	0.0099
11, 12	9, 10	5.00×10^{-14}	$2p_{11}p_{12} \times 2p_9p_{10}$	0.0001

10.6. 尤度比

Deconvolution により case-specific parameter が推定されると、各仮説の尤度を計算できるようになる。本項では、これらを用いた尤度比の計算方法について説明する。

尤度比（LR）とは、観察されたプロファイルが 2 つの仮説 H_1 および H_2 の下で、それぞれどの程度得られやすいかを比較する指標である。Taylor らが示した尤度比の計算の枠組み [3] に基づき、KongohPlus では、Deconvolution で得られたパラメータ推定値を用いて、次式により尤度比（LR）を算出する。

$$\mathrm{LR} = \frac{f(CSP \mid H_1, M)}{f(CSP \mid H_2, M)} = \frac{\prod_l \sum_i f(CSP_l \mid G_{l,i}, M)\Pr(G_{l,i} \mid H_1)}{\prod_l \sum_i f(CSP_l \mid G_{l,i}, M)\Pr(G_{l,i} \mid H_2)} \tag{12}$$

分子および分母の尤度は、いずれも式（1）に示した尤度関数により計算される。ただし、KongohPlus では、Deconvolution により一度推定した case-specific parameter を分子・分母で共通に用いる。すなわち、同一の crime stain profile から推定されるピーク高モデルは、仮説によらず共通であると考える。一方、DNA 型の確率 $\Pr(G_{l,i} \mid H)$ は、各仮説に応じて計算されるため、分子と分母で異なる。

10.6.1. 例 1： 既知の contributor が存在しない場合

例えば、2 人分の DNA 混合資料について deconvolution を行い、表 1 のような結果が得られたとする。資料の DNA が被疑者（9, 10 型）に由来するかどうかを評価する場合、以下に示す 2 つの仮説を立てることができる。

H_1 ： 資料の DNA は、被疑者と誰か 1 人に由来する

H_2 ： 資料の DNA は、誰か 2 人に由来する

（「誰か」は被疑者とは血縁関係のない個人）

まず、H_1 について考える。

被疑者が 1 人目の contributor である場合と 2 人目の contributor である場合では、ピーク高の期待値が異なり、尤度も異なる。そのため、KongohPlus では両方の contributor position を仮定して尤度を計算し、尤度が高い方を採用する。

被疑者を 1 人目の contributor とした場合、被疑者（9, 10 型）に該当する組合せは表 1 の 1 行目のみとなる。$\Pr(G_{l,i} \mid H_1)$ については、被疑者（9, 10 型）は確定しており、誰か 1 人が 11, 12 型を持つ確率を考えればよいので、$2p_{11}p_{12}$ となる（ハーディー・ワインベルク平衡を前提）。よって、この場合の尤度は以下の通りとなる。

$$f(CSP_l \mid G_{l,i}, M)\Pr(G_{l,i} \mid H_1) = 4.50 \times 10^{-10} \times 2p_{11}p_{12} \tag{13}$$

被疑者を 2 人目の contributor とした場合、被疑者（9, 10 型）に該当する組合せは表 1 の 6 行目のみとなる。$\Pr(G_{l,i} \mid H_1)$ については、誰か 1 人が 11, 12 型を持つ確率を考えればよいので、$2p_{11}p_{12}$ となる。よって、この場合の尤度は以下の通りとなる。

$$f(CSP_l \mid G_{l,i}, M)\Pr(G_{l,i} \mid H_1) = 5.00 \times 10^{-14} \times 2p_{11}p_{12} \tag{14}$$

式（13）と式（14）を比較すると、式（13）の値の方が大きいため、H_1 仮説の尤度と

して採用するのは、式 (13) の値となる。

一方、H_2 では contributor の DNA 型は全て未知であるため、考えられる全ての DNA 型の組合せについて尤度を計算し、それらを合計する。

$$
\begin{aligned}
&f\left(CSP_l \mid G_{l,i}, M\right)\Pr\left(G_{l,i} \mid H_2\right) \\
&= 4.50 \times 10^{-10} \times 2p_9p_{10} \times 2p_{11}p_{12} \\
&+2.00 \times 10^{-11} \times 2p_9p_{11} \times 2p_{10}p_{12} \\
&+1.50 \times 10^{-11} \times 2p_9p_{12} \times 2p_{10}p_{11} \\
&+1.00 \times 10^{-11} \times 2p_{10}p_{11} \times 2p_9p_{12} \\
&+4.95 \times 10^{-12} \times 2p_{10}p_{12} \times 2p_9p_{11} \\
&+5.00 \times 10^{-14} \times 2p_{11}p_{12} \times 2p_9p_{10} \\
&= 2.00 \times 10^{-9} \times p_9p_{10}p_{11}p_{12}
\end{aligned}
\tag{15}
$$

最終的に計算される尤度比は、式 (13) と式 (15) の比となる。

$$
\mathrm{LR} = \frac{4.50 \times 10^{-10} \times 2p_{11}p_{12}}{2.00 \times 10^{-9} \times p_9p_{10}p_{11}p_{12}} = \frac{0.45}{p_9p_{10}} \tag{16}
$$

10.6.2. 例 2： 既知の contributor が存在する場合

続いて、資料の DNA の一部が被害者に由来することが前提である場合を考える。

例えば、資料が被害者の膣内容物である場合には、被害者は contributor の 1 人であると考えることが自然である。このような contributor は一般に、assumed contributor と呼ぶ。

この状況において、被害者を 11, 12 型、被疑者を 9, 10 型として、資料の DNA が被疑者に由来するかどうかを知りたい場合、以下に示す 2 つの仮説を立てることができる。

H_1 ： 資料の DNA は、被害者と被疑者に由来する

H_2 ： 資料の DNA は、被害者と誰か 1 人に由来する

（「誰か」は被害者・被疑者とは血縁関係のない個人）

このように、H_1 と H_2 で共通する contributor が存在する場合には、その contributor を何番目の contributor にするとプロファイルを最も説明しやすいかをまず考える。今回の例の場合、被害者（11, 12 型）を 1 人目の contributor とした場合と 2 人目の contributor とした場合それぞれの尤度を計算し、高い尤度を示した条件を採用する。

被害者を 1 人目の contributor とした場合の尤度は $5.00 \times 10^{-14} \times 2p_9p_{10}$、被害者を 2 人目の contributor とした場合の尤度は、$4.50 \times 10^{-10} \times 2p_9p_{10}$ となり、2 人目の contributor とした場合の方が尤度は大きくなる。よって、被害者を 2 人目の contributor として、H_1 仮説と H_2 仮説の尤度および尤度比を計算する。

この場合の尤度比は、下記の通りとなる。

$$\mathrm{LR} = \frac{4.50 \times 10^{-10}}{4.50 \times 10^{-10} \times 2p_9p_{10}} = \frac{1}{2p_9p_{10}} \tag{17}$$

10.7. laboratory-specific parameter の設定方法

本項では、実験データを基に事前に設定しておく laboratory-specific parameter について説明する。

各種 stutter ratio、ローカス固有の PCR 増幅効率、ガンマ分布の scale parameter を設定するには、実験データとして十分な数の単一個人由来プロファイルを用意する必要がある。各種 stutter ratio については、アレル毎に設定されることから、様々な個人からデータを取得することが望ましい。また、ガンマ分布の scale parameter については、様々な PCR テンプレート量のプロファイルが含まれていることが望ましい。

drop-in に関するパラメータを設定するには、DNA を全く含まない non-template control を多数用意する必要がある。

10.7.1. stutter ratio

本項では、アレルピークに対するスターターの発生割合（stutter ratio）を、アレルの反復構造に応じた補正を考慮して定義し、実験データから平均的な stutter ratio を設定する方法について述べる。

KongohPlus における解析で考慮できる stutter ratio は、back stutter ratio（$\hat{S}_{l,a}^{(\mathrm{back})}$）、forward stutter ratio（$\hat{S}_{l,a}^{(\mathrm{forward})}$）、double-back stutter ratio（$\hat{S}_{l,a}^{(\mathrm{double-back})}$）、minus 2-nt stutter ratio（$\hat{S}_{l,a}^{(\mathrm{minus\ 2-nt})}$）の 4 つである。以降は特に断りのない限り、各種 stutter ratio を総称して $S_{l,a}$ と表記する。stutter ratio はプロファイル毎にばらつきを示すが、ここでは各ローカスのアレル毎に「平均的な stutter ratio（$\hat{S}_{l,a}$）」を推定することを目的とする。

stutter ratio のばらつきに関する統計学的モデル

KongohPlus では、$S_{l,a}$ が以下に示す対数正規分布に従うと仮定する。

$$S_{l,a} \sim \mathrm{LN}\left(\mu_{l,a}, \frac{\hat{\sigma}_l^2}{h_{l,a}}\right) \tag{18}$$

$\mu_{l,a}$　：ローカス l、アレル a における stutter ratio の対数平均

$h_{l,a}$　：ローカス l、アレル a におけるアレル成分量とスターター成分量の合計値

σ_l^2　：ローカス l における $h_{l,a} = 1$ の場合の stutter ratio の分散（対数スケール）

対数スケールの stutter ratio の分散は $\hat{\sigma}_l^2 / h_{l,a}$ であり、$h_{l,a}$ が減少するほど stochastic effect によりばらつきが大きくなることを示している。$\hat{\sigma}_l^2$ については、実験データを基に推定するパラメータである。

アレルと stutter ratio の相関に関する統計学的モデル

stutter ratio は一般に、アレルの数字が大きくなるほど高くなる傾向にある。ただし、アレルの塩基庁が単純なリピート構造を示さない場合、stutter ratio は必ずしもアレル

の数字と相関せず、longest uninterrupted stretch（LUS）[8] 等によってアレルの数字を補正する必要がある。また、minus 2-nt stutter は、アレルの数字に依らず、stutter ratio の期待値はほぼ一定になる [9]。さらに、ローカスによっては、forward stutter、double-back stutter のデータが不十分なため、複数のローカスを合わせたモデルが必要となる。

以上の点を踏まえ、KongohPlus では、アレルと stutter ratio との関係について、以下の 5 つのモデルを実装している。

モデル	説明
Linear (Allele)	stutter ratio は、アレルの数字が大きいほど高い
Linear (Corrected Allele)	stutter ratio は、アレルの補正値が大きいほど高い
Uniform	stutter ratio はアレルに依らず一定
Uniform (Multiple loci)	stutter ratio はアレルに依らず一定 （複数ローカスのデータを統合）
Not consider	stutter ratio を考慮しない

Linear (Allele) モデルでは、アレルと stutter ratio の対数平均との関係を以下の式で表す。

$$\mu_{l,a} = \log_e\left(\hat{\beta}_{0,l} + \hat{\beta}_{1,l} \times a\right) \tag{19}$$

ここで、$\hat{\beta}_{0,l}$ は切片、$\hat{\beta}_{1,l}$ は傾きを表し、いずれも実験データを基に推定されるパラメータである。

ただし、$\hat{\beta}_{0,l} + \hat{\beta}_{1,l} \times a \leq 0$ となる場合には、対数が定義されない。このような場合には、本モデルでは $\mu_{l,a} = 0$ とする。これは、当該アレルにおいてスタターは発生しないとみなすことに対応する。

Uniform モデル、および Uniform (Multiple loci) モデルについては、stutter ratio は

アレルに依らず一定であることが前提なので、傾きや切片は設けず、式 (18) における $\mu_{l,a}$ を実験データを基に直接推定する。

Linear (Corrected Allele) モデルでは、ユーザーが各アレルの補正値を設定する必要がある。KongohPlus では、GlobalFiler キットに搭載されているローカスについて、既定のアレル補正値を設定している。D8S1179、D21S11、D2S441、TH01、FGA、D1S1656、D12S391、D2S1338 については LUS model [8]、SE33 については Multi-sequence model [10] に基づいて補正値を決定している。以下では、KongohPlus で既定のアレル補正値を設定するために採用している LUS model および Multi-sequence model について説明する。

LUS model

LUS とは、longest uninterrupted stretch の略で、STR の塩基配列において、リピート構造の繰り返し回数の最大値を指す [8]。多くの STR では、アレルの数字は繰り返し回数と一致するが、一部の STR では必ずしも一致せず、複数のリピート構造から成る複雑な塩基配列の場合もある。こういった STR では、アレルの数字よりも、LUS の方が stutter ratio のデータが示す傾向を説明しやすい。

LUS でアレルの数字を補正する場合、stutter ratio の対数平均は、以下の式で表される。

$$\mu_{l,a} = \log_e\left(\hat{\beta}_{0,l} + \hat{\beta}_{1,l} \times wLUS_{l,a}\right) \tag{20}$$

$wLUS_{l,a}$ は、ローカス l、アレル a における LUS の重みづけ平均を示し、以下の式で表される。

$$wLUS_{l,a} = \frac{\sum_{i=1}^{N} n_i LUS_i}{\sum_{i=1}^{N} n_i} \tag{21}$$

n_i は、ある遺伝的集団において、同一のアレルにおける i 番目の塩基配列の観察数を示し、LUS_i は、i 番目の塩基配列における LUS の値を示す。

例えば、NIST 1036 人の population database [11] において、D3S1358 のアレル 15 については以下のデータが得られている。

塩基配列	観察数（n_i）	LUS_i
TCTA [TCTG]2 [TCTA]12	429	12
TCTA TCTG [TCTA]13	173	13
TCTA [TCTG]3 [TCTA]11	27	11
TCTA [TCTG]2 [TCTA]8 TCTG [TCTA]3	1	8
TCTA [TCTG]3 [TCTA]5 TCTG [TCTA]5	1	5

このとき、D3S1358 のアレル 15 に対する $wLUS_{l,a}$ は、以下の通り計算される。

$$wLUS_{l,a} = \frac{429 \cdot 12 + 173 \cdot 13 + 27 \cdot 11 + 1 \cdot 8 + 1 \cdot 5}{429 + 173 + 27 + 1 + 1} \approx 12.2 \tag{22}$$

Multi-sequence model

SE33 のように、アレルの塩基配列内にリピート構造が複数存在する複雑な STR では、LUS でも stutter ratio のデータを説明しにくい。そこで、各リピート構造のうち、繰り返し回数が一定の基準を上回ったものについて、その繰り返し回数を合計した数字をアレルの補正値とする方法として、Multi-sequence model が編み出されている[10]。

Multi-sequence model にしたがってアレルの数字を補正する場合、stutter ratio の対数平均は、以下の式で表される。

$$\mu_{l,a} = \log_e\left(\hat{\beta}_{0,l} + \hat{\beta}_{1,l} \times wCA_{l,a}\right) \tag{23}$$

$wCA_{l,a}$ は、ローカス l、アレル a におけるアレルの補正値の重みづけ平均を示し、以下の式で表される。

$$wCA_{l,a} = \frac{\sum_{i=1}^{N} n_i CA_i}{\sum_{i=1}^{N} n_i} \tag{24}$$

n_i は、ある遺伝的集団において、同一のアレルにおける i 番目の塩基配列の観察数を示し、CA_i は、i 番目の塩基配列におけるアレルの補正値を示す。

CA_i は、以下の式で計算される。

$$CA_i = \sum_j \max(US_{i,j} - x_l, 0) \tag{25}$$

$US_{i,j}$ は、i 番目の塩基配列における j 番目のリピート構造の繰り返し回数を示し、x_l は stutter ratio に影響する最小の繰り返し回数を示す。

例えば、NIST 1036 人の population database [12] において、SE33 のアレル 22 については以下のデータが得られている。なお、ここでは $x_l = 7$ として補正値（CA_i）を計算している。

塩基配列	観察数（n_i）	CA_i ($x_l = 7$)
CT [CTTT]3 C [CTTT]22 CT [CTTT]3 CT [CTTT]2	24	15
CT [CTTT]3 CCTT C [CTTT]21 CT [CTTT]3 CT [CTTT]2	4	14
CT [CTTT]2 CCTT C [CTTT]12 TT [CTTT]10 CT [CTTT]5	1	8
CT [CTTT]2 C [CTTT]23 CT [CTTT]3 CT [CTTT]2	1	16

このとき、SE33 のアレル 22 に対する $wCA_{l,a}$ は、以下の通り計算される。

$$wCA_{l,a} = \frac{24 \cdot 15 + 4 \cdot 14 + 1 \cdot 8 + 1 \cdot 16}{24 + 4 + 1 + 1} \approx 14.66667 \tag{26}$$

実験データに基づくパラメータ推定

本項では、これまでに述べた stutter ratio に関する統計学的モデルを前提に、実験データから各ローカス、各アレルの「平均的な stutter ratio（$\hat{S}_{l,a}$）」を推定する方法について述べる。

実験的に取得した各プロファイルについて、ローカス l、アレル a の stutter ratio $S_{l,a}^{(\mathrm{back,obs})}, S_{l,a}^{(\mathrm{forward,obs})}, S_{l,a}^{(\mathrm{double-back,obs})}, S_{l,a}^{(\mathrm{minus\ 2-nt,obs})}$（観察値であることを示すために obs と表記）は、次の式で計算される。

$$S_{l,a}^{(\mathrm{back,obs})} = \frac{O_{l,a-1}}{O_{l,a}}$$

$$S_{l,a}^{(\mathrm{forward,obs})} = \frac{O_{l,a+1}}{O_{l,a}}$$

$$S_{l,a}^{(\mathrm{double-back,obs})} = \frac{O_{l,a-2}}{O_{l,a}}$$

$$S_{l,a}^{(\mathrm{minus\ 2-nt,obs})} = \frac{O_{l,a-0.2(\mathrm{or}\ 0.8)}}{O_{l,a}}$$

$O_{l,a}$ ：ローカス l、アレル a の観察ピーク高

$O_{l,a-1}$ ：ローカス l、アレル a の back stutter の観察ピーク高

$O_{l,a+1}$ ：ローカス l、アレル a の forward stutter の観察ピーク高

$O_{l,a-2}$ ：ローカス l、アレル a の double-back stutter の観察ピーク高

$O_{l,a-0.2(\mathrm{or}\ 0.8)}$ ：ローカス l、アレル a の minus 2-nt stutter の観察ピーク高

また、ローカス l、アレル a におけるアレル成分量とスタター成分量の合計値（$h_{l,a}^{(\mathrm{obs})}$）についても、実験データから得られたピーク高を使って計算する。

なお、実験的に取得したプロファイルがあるローカスでヘテロ接合体の場合は、アレル成分とスタター成分が混在したり、スタター成分同士が混在したりする場合がある。

そのようなデータは、「平均的な stutter ratio（$\hat{S}_{l,a}$）」の推定には使用しない。具体的には、以下の表で ✓ マークが付いている stutter ratio のデータのみ、「平均的な stutter ratio（$\hat{S}_{l,a}$）」の推定に使用する。

$a' - a$	アレル	$S_{l,a}^{(\text{back,obs})}$	$S_{l,a}^{(\text{forward,obs})}$	$S_{l,a}^{(\text{double-back,obs})}$	$S_{l,a}^{(\text{minus 2-nt,obs})}$
1	a				
1	a'				
2	a				
2	a'		✓		✓
3	a	✓		✓	✓
3	a'	✓	✓		✓
0.2 or 0.8	a				
0.2 or 0.8	a'		✓	✓	
1.2 or 1.8	a	✓		✓	
1.2 or 1.8	a'	✓	✓		
2.2 or 2.8	a	✓	✓	✓	✓
2.2 or 2.8	a'	✓	✓	✓	✓
3 >	a	✓	✓	✓	✓
3 >	a'	✓	✓	✓	✓

実験データ（$S_{l,a}^{(\text{back,obs})}, S_{l,a}^{(\text{forward,obs})}, S_{l,a}^{(\text{double-back,obs})}, S_{l,a}^{(\text{minus 2-nt,obs})}, h_{l,a}^{(\text{obs})}$）を取得したら、これまでに述べた統計学的モデルにおけるパラメータ $\hat{\sigma}_l^2$（式 (18)）、$\hat{\beta}_{0,l}$ および $\hat{\beta}_{1,l}$（式 (19)、式 (20)、式 (23)）、$\mu_{l,a}$（Uniform モデルと Uniform (Multiple loci) モデル）を CMA-ES 法による最尤推定により決定する。具体的な方法は、deconvolution

における最尤推定と同様である（詳細は、第 10.4 項を参照）。

各パラメータが推定できれば、Linear (Allele) モデルと Linear (Corrected Allele) モデルの場合は、式 (19)、式 (20)、あるいは式 (23) を用いて、アレル毎に $\mu_{l,a}$ を計算する。計算された値が、「平均的な stutter ratio（$\hat{S}_{l,a}$）」となる。

Uniform モデルと Uniform (Multiple loci) モデルについては、CMA-ES 法により推定された $\mu_{l,a}$ そのものが「平均的な stutter ratio（$\hat{S}_{l,a}$）」となる。

10.7.2. ローカス固有の PCR 増幅効率

本項では、全ローカスの相対的な増幅の強さをディリクレ分布を用いてモデル化し、実験データに基づいて各ローカスの平均的な増幅効率を推定・定数化する手法を定義する。

ローカス l の PCR 増幅効率 (A_l) は、全ローカスの平均増幅効率を 1 としたときに、そのローカスが相対的に何倍の増幅効率をもつかを表す指標である。増幅効率はプロファイル毎にばらつきを示すが、ここでは各ローカスにおける「平均的な増幅効率 ($\hat{A}_l$)」を推定することを目的とする。

統計学的モデル

KongohPlus では、全ローカスの増幅効率が合計で 1 になるように正規化した値 (A_l^*) を定義する。正規化は、各ローカスにおける「平均的な増幅効率（$\hat{A}_l$）」を推定する際に、そのままのスケールでは扱いにくいため行う。

$$A_l^* = \frac{A_l}{\sum_{l=1}^{L} A_l} \tag{27}$$

KongohPlus では、この正規化された増幅効率ベクトル（$A_1^*, A_2^*, \ldots, A_L^*$）がディリクレ分布に従うと仮定する。

$$(A_1^*, A_2^*, \ldots, A_L^*) \sim \mathrm{Dir}(\alpha_1, \alpha_2, \ldots, \alpha_L) \tag{28}$$

パラメータ $\alpha_1, \alpha_2, \ldots, \alpha_L$ は、実験データを基に推定するパラメータである。

各ローカスに対応する $\alpha_l\ (l = 1, 2, \ldots, L)$ が推定できれば、正規化された増幅効率 A_l^* の期待値を次の式により求める。

$$\hat{A}_l^* = \frac{\alpha_l + 1}{\sum_{l=1}^{L}(\alpha_l + 1)} \tag{29}$$

これは、一様事前分布 $\mathrm{Dir}(1, 1, \ldots, 1)$ を仮定したときの事後平均に対応する。

最後に、各ローカスにおける「平均的な増幅効率（$\hat{A}_l$）」は次の式で推定される。

$$\hat{A}_l = \hat{A}_l^* \times L \tag{30}$$

実験データに基づくパラメータ推定

実験的に取得した各プロファイルについて、全ローカスの増幅効率が合計で 1 になるように正規化した値（$\hat{A}_l^{*(\mathrm{obs})}$）は、次の式で計算される。

$$\hat{A}_l^{*(\mathrm{obs})} = \frac{\sum_a O_{l,a}}{\sum_l \sum_a O_{l,a}} \tag{31}$$

$O_{l,a}$ は、ローカス l のアレル a の位置にあるピーク高の観察値である。

実験的に取得した各プロファイルにつき $\hat{A}_l^{*(\mathrm{obs})}$ を計算したら、式 (28) におけるパラメータ $\alpha_1, \alpha_2, \ldots, \alpha_L$ を CMA-ES 法による最尤推定により決定する。具体的な方法は、deconvolution における最尤推定と同様である（詳細は、第 10.4 項を参照）。

各ローカスに対応する $\alpha_l\ (l = 1, 2, \ldots, L)$ が推定できれば、式 (29) および式 (30) に基づき、「平均的な増幅効率（$\hat{A}_l$）」を得る。

10.7.3. ガンマ分布の scale parameter

本項では、第 10.3.3 項で述べたガンマ分布モデルにおける scale parameter（$\hat{\eta}^{(\mathrm{allele})}$ および $\hat{\eta}^{(\mathrm{stutter})}$）を実験的に設定する方法について述べる。

実験データは、単一個人由来であること（$M_c = 1$）、および DNA の分解がないこと（$D_c = 1$）を前提とする。また、同一の DNA 溶液を複数回 PCR したものが実験データ

に含まれているとしても、それぞれ別の DNA 溶液から 1 回ずつ PCR したものとみなされる（$R_r = 1$）。

これらの条件を満たすとき、式 (3) に示すヘテロ接合体 1 本あたりのアレル成分のピーク高の期待値は、以下の式で表される。

$$E_{l,a} = \frac{T\hat{A}_l}{1 + \hat{S}_{l,a}^{(\mathrm{back})} + \hat{S}_{l,a}^{(\mathrm{forward})} + \hat{S}_{l,a}^{(\mathrm{double-back})} + \hat{S}_{l,a}^{(\mathrm{minus\ 2-nt})}} \tag{32}$$

この式は、T（ヘテロ接合体 1 本あたりのピーク高）を除き、laboratory-specific parameter から構成されている。

T については、実験的に取得した各プロファイルが上記 3 条件を満たす場合、観察されたピーク高を使って以下のように計算することができる。

$$T = \frac{1}{2L}\sum_{l=1}^{L}\sum_{a} O_{l,a} \tag{33}$$

すなわち、各ローカスにおけるピーク高の合計値を全ローカスについて平均し、さらにヘテロ接合体 1 本あたりの量に換算するために 2 で割った値とする。

よって、式 (32) に示すピーク高の期待値は、計算により得ることが可能である。

スタター成分についても同様の考え方に基づいて期待ピーク高を計算する。同一のピーク位置に複数のピーク成分が寄与する場合には、それぞれの成分の期待ピーク高を加算し、その和を当該ピーク位置における期待ピーク高とする。

$\hat{\eta}^{(\mathrm{allele})}$ および $\hat{\eta}^{(\mathrm{stutter})}$ については、CMA-ES 法による最尤推定により決定する。具体的な方法は、deconvolution における最尤推定と同様である（詳細は、第 10.4 項を参照）。

10.7.4. drop-in に関するパラメータ

第 10.3.5 項で述べた drop-in に関する統計学的モデルにおいて、drop-in の発生頻度やピーク高の分布を規定する $\hat{\xi}^{(\mathrm{dropin})}, \hat{\eta}^{(\mathrm{dropin})}, \hat{F}^{(\mathrm{dropin})}$ を実験的に取得した non-template control に基づき設定する方法について述べる。

$\hat{F}^{(\mathrm{dropin})}$ は、以下の式で計算される。

$$\hat{F}^{(\mathrm{dropin})} = \frac{n^{(\mathrm{dropin})}}{n^{(\mathrm{sample})} \times n^{(\mathrm{marker})}} \tag{34}$$

$n^{(\mathrm{dropin})}$: drop-in の発生数

$n^{(\mathrm{sample})}$: 分析した non-template control の総数

$n^{(\mathrm{marker})}$: ローカス数

$\hat{\xi}^{(\mathrm{dropin})}, \hat{\eta}^{(\mathrm{dropin})}$ については、実験データより得られた drop-in のピーク高を基に、CMA-ES 法による最尤推定により決定する。具体的な方法は、deconvolution における最尤推定と同様である（詳細は、第 10.4 項を参照）。

11. 参考文献

[1] M.D. Coble, J.-A. Bright, Probabilistic genotyping software: An overview, Forensic Sci. Int. Genet. 38 (2019) 219–224. https://doi.org/10.1016/j.fsigen.2018.11.009.

[2] D. Taylor, J.-A. Bright, J. Buckleton, Interpreting forensic DNA profiling evidence without specifying the number of contributors, Forensic Sci. Int. Genet. 13 (2014) 269–280. https://doi.org/10.1016/j.fsigen.2014.08.014.

[3] D. Taylor, J.-A. Bright, J. Buckleton, The interpretation of single source and mixed DNA profiles, Forensic Sci. Int. Genet. 7 (2013) 516–528. https://doi.org/10.1016/j.fsigen.2013.05.011.

[4] D.J. Balding, R.A. Nichols, DNA profile match probability calculation: how to allow for population stratification, relatedness, database selection and single bands, Forensic Sci. Int. 64 (1994) 125–140. https://doi.org/10.1016/0379-0738(94)90222-4.

[5] C. Morimoto, H. Tsujii, S. Manabe, S. Fujimoto, E. Hirai, Y. Hamano, K. Tamaki, Development of a software for kinship analysis considering linkage and mutation based on a Bayesian network, Forensic Sci. Int. Genet. 47 (2020) 102279. https://doi.org/10.1016/j.fsigen.2020.102279.

[6] Ø. Bleka, G. Storvik, P. Gill, EuroForMix: An open source software based on a continuous model to evaluate STR DNA profiles from a mixture of contributors with artefacts, Forensic Sci. Int. Genet. 21 (2016) 35–44. https://doi.org/10.1016/j.fsigen.2015.11.008.

[7] C.C.G. Benschop, J. Hoogenboom, P. Hovers, M. Slagter, D. Kruise, R. Parag, K. Steensma, K. Slooten, J.H.A. Nagel, P. Dieltjes, V. van Marion, H. van Paassen, J. de Jong, C. Creeten, T. Sijen, A.L.J. Kneppers, DNAxs/DNAStatistX:

Development and validation of a software suite for the data management and probabilistic interpretation of DNA profiles, Forensic Sci. Int. Genet. 42 (2019) 81–89. https://doi.org/10.1016/j.fsigen.2019.06.015.

[8] C. Brookes, J.-A. Bright, S. Harbison, J. Buckleton, Characterising stutter in forensic STR multiplexes, Forensic Sci. Int. Genet. 6 (2012) 58–63. https://doi.org/10.1016/j.fsigen.2011.02.001.

[9] S. Manabe, K. Fujii, T. Fukagawa, N. Mizuno, K. Sekiguchi, K. Inoue, M. Hashiyada, A. Akane, K. Tamaki, Evaluation of probability distribution models for stutter ratios in the typing system of GlobalFiler and 3500xL Genetic Analyzer, Leg. Med. Tokyo Jpn. 52 (2021) 101906. https://doi.org/10.1016/j.legalmed.2021.101906.

[10] D. Taylor, J.-A. Bright, C. McGoven, C. Hefford, T. Kalafut, J. Buckleton, Validating multiplexes for use in conjunction with modern interpretation strategies, Forensic Sci. Int. Genet. 20 (2016) 6–19. https://doi.org/10.1016/j.fsigen.2015.09.011.

[11] K.B. Gettings, L.A. Borsuk, C.R. Steffen, K.M. Kiesler, P.M. Vallone, Sequence-based U.S. population data for 27 autosomal STR loci, Forensic Sci. Int. Genet. 37 (2018) 106–115. https://doi.org/10.1016/j.fsigen.2018.07.013.

[12] L.A. Borsuk, K.B. Gettings, C.R. Steffen, K.M. Kiesler, P.M. Vallone, Sequence-based U.S. population data for the SE33 locus, Electrophoresis 39 (2018) 2694–2701. https://doi.org/10.1002/elps.201800091.